รายงานโครงงาน

การพยากรณ์ความผันผวนของกองทุน QQQ ล่วงหน้า 5 วันทำการ

Forecasting the 5-Day-Ahead Volatility of the QQQ ETF with Machine Learning

จัดทำโดย

[กรอกชื่อ–นามสกุล และรหัสนักศึกษา คนที่ 1]

[กรอกชื่อ–นามสกุล และรหัสนักศึกษา คนที่ 2]

เสนอ

[กรอกชื่ออาจารย์ผู้สอน]

รายงานนี้เป็นส่วนหนึ่งของการศึกษารายวิชา 01076641 [กรอกชื่อรายวิชา]

ภาคเรียนที่ 1 ปีการศึกษา 2569

[กรอกชื่อภาควิชา คณะ และสถาบัน]

รายงานโครงงาน

การพยากรณ์ความผันผวนของกองทุน QQQ ล่วงหน้า 5 วันทำการ

Forecasting the 5-Day-Ahead Volatility of the QQQ ETF with Machine Learning

จัดทำโดย

[กรอกชื่อ–นามสกุล และรหัสนักศึกษา คนที่ 1]

[กรอกชื่อ–นามสกุล และรหัสนักศึกษา คนที่ 2]

เสนอ

[กรอกชื่ออาจารย์ผู้สอน]

รายงานนี้เป็นส่วนหนึ่งของการศึกษารายวิชา 01076641 [กรอกชื่อรายวิชา]

ภาคเรียนที่ 1 ปีการศึกษา 2569

[กรอกชื่อภาควิชา คณะ และสถาบัน]

คำนำ

รายงานฉบับนี้เป็นส่วนหนึ่งของการศึกษารายวิชา 01076641 ภาคเรียนที่ 1 ปีการศึกษา 2569 จัดทำขึ้นเพื่อนำเสนอโครงงานการพยากรณ์ความผันผวนของกองทุน QQQ ล่วงหน้า 5 วันทำการด้วย machine learning เนื้อหาครอบคลุมการตั้งปัญหา ทฤษฎีและงานวิจัยที่เกี่ยวข้อง การเตรียมข้อมูล การเขียนโมเดลด้วยตนเอง 19 ตัว การวัดผล และการอภิปรายผล

ผู้จัดทำตั้งใจรายงานผลตามจริง รวมถึงผลที่ไม่เป็นไปตามที่คาดไว้ และระบุทุกครั้งว่าข้อสรุปใดมีหลักฐานทางสถิติรองรับ ข้อใดเป็นเพียงข้อสังเกต โค้ด ข้อมูล และผลการทดลองทั้งหมดอยู่ใน repository ของโครงงาน และทำซ้ำได้ตามขั้นตอนในภาคผนวก ค

ผู้จัดทำขอขอบคุณอาจารย์ผู้สอนที่ให้ความรู้และคำแนะนำตลอดการทำโครงงาน หากรายงานฉบับนี้มีข้อผิดพลาดประการใด ผู้จัดทำขออภัยไว้ ณ ที่นี้

คณะผู้จัดทำ

ตุลาคม 2569

บทคัดย่อ

โครงงานนี้ศึกษาการพยากรณ์ความผันผวนของกองทุน QQQ ล่วงหน้า 5 วันทำการ จากข้อมูลราคารายวัน 2,512 วันทำการ ตั้งแต่ 31 สิงหาคม 2016 ถึง 28 สิงหาคม 2026 ในสองรูปแบบ คือการทำนายค่าความผันผวน (regression) และการทำนายว่าจะเป็นช่วงผันผวนสูงหรือไม่ (classification) โดยมีคำถามวิจัยว่า การตัดช่วงที่ราคากระชากแรง (spike) ออกจากข้อมูลเทรน ทำให้โมเดลทำนายได้ดีขึ้นหรือแย่ลง

ผู้จัดทำสร้างฟีเจอร์ 8 ตัวจากราคาและปริมาณซื้อขายย้อนหลัง แบ่งข้อมูลตามลำดับเวลาเป็น Train 1,733 แถว Validation 371 แถว และ Test 373 แถว โดยเว้นช่องว่าง 5 วันทำการระหว่างชุด นิยาม spike ด้วยเกณฑ์ Q3 + 3 × IQR ของขนาดผลตอบแทนรายวันบน Train แล้วเขียนโมเดล 19 ตัวด้วย NumPy ทั้งหมด ได้แก่ regression 4 ตัว classification 13 ตัว และ clustering 2 ตัว ในจำนวนนี้มีโมเดลนอกเนื้อหาที่เรียนสองตัว คือ Elastic Net และ AdaBoost ทุกโมเดลถูกยืนยันผลเทียบกับ scikit-learn และ XGBoost การตั้งค่าของโมเดลถูกเลือกบน Validation โมเดลถูกล็อกก่อนเปิด Test และ Test ถูกอ่านเพียงครั้งเดียว ความไม่แน่นอนของผลวัดด้วย moving-block bootstrap 2,000 รอบ

ผลการศึกษาพบว่า (1) บน Test โมเดลตัวแทนของงาน classification คือ Multi-Layer Perceptron ได้ average precision 0.599 สูงกว่าการเดาสุ่ม (0.196) ชัดเจน แต่สูงกว่ากฎ "เท่ากับ 5 วันที่ผ่านมา" (0.536) เพียงเล็กน้อย ส่วน Elastic Net ได้ RMSE 0.117 ดีกว่าการทายค่าเฉลี่ย (0.138) (2) ผลต่างระหว่างการเทรนแบบมีและไม่มีช่วง spike มีช่วงความเชื่อมั่น 95% คร่อมศูนย์ใน 16 จาก 17 โมเดลบน Validation และ 14 จาก 17 โมเดลบน Test จึงยังสรุปไม่ได้ว่าการตัดช่วง spike ช่วยหรือทำร้ายโมเดล (3) โมเดลทำงานได้ในช่วงตลาดปกติ แต่ภายในช่วงรอบวัน spike แยกวันผันผวนสูงไม่ได้ และ (4) โมเดลที่ซับซ้อนไม่ได้ดีกว่าโมเดลพื้นฐานอย่างมีนัยสำคัญ

คำสำคัญ: การพยากรณ์ความผันผวน, กองทุน QQQ, machine learning, Elastic Net, AdaBoost, block bootstrap

สารบัญ

คำนำ.....ก
บทคัดย่อ.....ข
สารบัญรูป.....จ
สารบัญตาราง.....ฉ
บทที่ 1 บทนำ.....1
1.1 ความเป็นมาและความสำคัญของปัญหา.....1
1.2 วัตถุประสงค์ของการศึกษา.....1
1.3 ขอบเขตของการศึกษา.....2
1.4 ประโยชน์ที่คาดว่าจะได้รับ.....2
1.5 นิยามศัพท์เฉพาะ.....2
บทที่ 2 เอกสารและงานวิจัยที่เกี่ยวข้อง.....4
2.1 แนวคิด ทฤษฎี และหลักการที่เกี่ยวข้อง.....4
2.2 งานวิจัยที่เกี่ยวข้อง.....8
บทที่ 3 วิธีดำเนินการศึกษา.....9
3.1 แหล่งข้อมูล.....9
3.2 เครื่องมือที่ใช้ในการศึกษา.....9
3.3 วิธีการเก็บรวบรวมและเตรียมข้อมูล.....9
3.4 การวิเคราะห์ข้อมูลและสถิติที่ใช้.....14
บทที่ 4 ผลการวิเคราะห์ข้อมูล.....17
4.1 ผลการวิเคราะห์ฟีเจอร์.....17
4.2 ผลบน Validation.....19
4.3 ผลของโมเดลนอกเนื้อหาที่เรียน.....26
4.4 ผลบน Test.....27
4.5 ผลการเปรียบเทียบ with_spike กับ non_spike.....32
4.6 ผลเทียบกับโมเดลพื้นฐานที่สอนในห้อง.....34
4.7 การวิเคราะห์ความผิดพลาดของโมเดล.....36
4.8 ความเสถียรของอันดับข้ามช่วงเวลา.....36
บทที่ 5 สรุปผล อภิปรายผล และข้อเสนอแนะ.....37
5.1 สรุปผลการศึกษา.....37
5.2 อภิปรายผล.....37
5.3 ข้อจำกัดของการศึกษา.....39
5.4 ข้อเสนอแนะ.....39
บรรณานุกรม.....41
ภาคผนวก ก การตั้งค่าที่ถูกเลือกของทุกโมเดล.....43
ภาคผนวก ข ตารางเพิ่มเติม.....46
ข.1 Validation ของแบบ non_spike.....46

ข.2 ตัวชี้วัดครบทุกตัวบน Test....49
ข.3 Walk-forward และ feature importance ของแบบ non_spike....50
ภาคผนวก ค หลักฐานการเปิด Test และวิธีทำซ้ำ....51
ภาคผนวก ง การทดลอง RBF Kernel Perceptron หลังส่งงาน....52
ง.1 การตรวจความทนทานและความไม่แน่นอนเพิ่มเติม....54

สารบัญรูป

รูปที่ 3.1 ค่า target ตามเวลา การแบ่งข้อมูล ช่องว่างระหว่างชุด และวันที่เกิด spike....11
รูปที่ 3.2 ผลตอบแทนรายวันและวันที่ถูกจัดเป็น spike....12
รูปที่ 3.3 ตัวอย่างหน้าต่างที่ถูกตัดรอบ spike วันที่ 26 ธันวาคม 2018 พื้นที่แรเงาคือ 25 แถวที่ถูกตัด....13
รูปที่ 3.4 เปรียบเทียบข้อมูลเทรนสองแบบ....13
รูปที่ 4.1 สหสัมพันธ์ระหว่างฟีเจอร์บนข้อมูลเทรน....17
รูปที่ 4.2 Permutation importance ของ classifier แต่ละตัว (with_spike)....18
รูปที่ 4.3 ค่าทำนายเทียบค่าจริงบน Validation (with_spike)....20
รูปที่ 4.4 Confusion matrix ของ classifier ทั้ง 13 ตัวบน Validation (with_spike)....23
รูปที่ 4.5 ROC ของ classifier ทั้ง 13 ตัวบน Validation (with_spike)....24
รูปที่ 4.6 Precision-recall ของ classifier ทั้ง 13 ตัวบน Validation (with_spike)....25
รูปที่ 4.7 Loss ระหว่างเทรน (with_spike)....26
รูปที่ 4.8 คะแนนของโมเดลเดียวกันบน Validation เทียบกับบน Test....30
รูปที่ 4.9 ROC-AUC บน Test แยกตามช่วงตลาด....32
รูปที่ 4.10 ผลต่างของ AP เมื่อตัด spike ออก พร้อมช่วงความเชื่อมั่น 95% (Validation)....33

สารบัญตาราง

ตารางที่ 2.1 ตัวชี้วัดที่ใช้ประเมินโมเดล....7
ตารางที่ 3.1 เครื่องมือที่ใช้ในการศึกษา....9
ตารางที่ 3.2 ฟีเจอร์ 8 ตัว นิยาม และเหตุผลที่เลือก....10
ตารางที่ 3.3 การแบ่งข้อมูลตามลำดับเวลา....10
ตารางที่ 3.4 ข้อมูลเทรนที่เหลือเมื่อใช้เกณฑ์ spike แต่ละแบบ....11
ตารางที่ 3.5 โมเดลทั้ง 19 ตัว....14
ตารางที่ 3.6 เส้นฐานเปรียบเทียบที่ไม่ต้องเทรน....15
ตารางที่ 3.7 ผลต่างระหว่างโมเดลที่เขียนเองกับ library บน Validation....15
ตารางที่ 4.1 Permutation importance เฉลี่ยข้ามโมเดล แบบ with_spike....18
ตารางที่ 4.2 ผลของโมเดล regression บน Validation แบบ with_spike....19
ตารางที่ 4.3 ผลของโมเดล regression บน Validation แบบ non_spike....20
ตารางที่ 4.4 ผลของโมเดล classification บน Validation แบบ with_spike....21
ตารางที่ 4.5 ตัวชี้วัดครบทุกตัวที่โจทย์กำหนด บน Validation แบบ with_spike....22
ตารางที่ 4.6 ผลของโมเดล clustering บน Validation แบบ with_spike....26
ตารางที่ 4.7 ผลของ Elastic Net บน Validation และ Test....27
ตารางที่ 4.8 ผลของ AdaBoost บน Validation และ Test....27
ตารางที่ 4.9 โมเดลตัวแทนที่ล็อกไว้: คะแนนบน Validation คะแนนบน Test และเส้นฐานที่ดีที่สุด....27
ตารางที่ 4.10 ผลของโมเดล classification บน Test แบบ with_spike....28
ตารางที่ 4.11 ผลของโมเดล classification บน Test แบบ non_spike....28
ตารางที่ 4.12 ผลของโมเดล regression บน Test แบบ with_spike....29
ตารางที่ 4.13 ผลของโมเดล regression บน Test แบบ non_spike....30
ตารางที่ 4.14 ผลบน Test แยกตามช่วงตลาด งาน classification....31
ตารางที่ 4.15 ผลบน Test แยกตามช่วงตลาด งาน regression....31
ตารางที่ 4.16 ผลต่างแบบจับคู่ non_spike − with_spike บน Validation....32
ตารางที่ 4.17 โมเดลเดียวกันที่เทรนแบบมีและไม่มีช่วง spike บน Test....33
ตารางที่ 4.18 โมเดลตัวแทนเทียบกับโมเดลพื้นฐานที่สอนในห้อง บน Validation....35
ตารางที่ 4.19 โมเดลตัวแทนเทียบกับโมเดลพื้นฐานที่สอนในห้อง บน Test....35
ตารางที่ 4.20 Average precision ของ walk-forward ภายใน Train แบบ with_spike....36
ตารางที่ ก.1 รายการโมเดลและการตั้งค่าที่ถูกเลือก....44
ตารางที่ ข.1 ผลของโมเดล classification บน Validation แบบ non_spike....47
ตารางที่ ข.2 ตัวชี้วัดครบทุกตัวที่โจทย์กำหนด บน Validation แบบ non_spike....48
ตารางที่ ข.3 ผลของโมเดล clustering บน Validation แบบ non_spike....49
ตารางที่ ข.4 ตัวชี้วัดครบทุกตัวที่โจทย์กำหนด บน Test แบบ with_spike....49
ตารางที่ ข.5 ตัวชี้วัดครบทุกตัวที่โจทย์กำหนด บน Test แบบ non_spike....49
ตารางที่ ข.6 Average precision ของ walk-forward ภายใน Train แบบ non_spike....50
ตารางที่ ข.7 Permutation importance เฉลี่ยข้ามโมเดล แบบ non_spike....50

ตารางที่ ค.1 ใบรับรองการเปิด Test (outputs/modeling/finalize_receipt.json).....51
ตารางที่ ง.1 ผล RBF Kernel Perceptron บน Train, Validation และ Test แยกตาม variant.....53

บทที่ 1

บทนำ

1.1 ความเป็นมาและความสำคัญของปัญหา

ความผันผวน (volatility) คือขนาดของการแกว่งตัวของราคา เราวัดจากส่วนเบี่ยงเบนมาตรฐานของผลตอบแทนรายวัน แล้วคูณ √252 เพื่อแปลงเป็นหน่วยต่อปี เช่น ค่า 0.20 หมายถึงราคาแกว่งราว 20% ต่อปี

ความผันผวนเป็นตัวแปรที่ใช้ตรง ๆ ในงานการเงินสามอย่าง คือการตั้งราคา option การกำหนดขนาดการลงทุน และการบริหารความเสี่ยง การรู้ล่วงหน้าแม้เพียง 5 วันว่าตลาดกำลังเข้าสู่ช่วงปั่นป่วน ช่วยให้ลดขนาดการลงทุนหรือป้องกันความเสี่ยงได้ทัน

โครงงานนี้พยากรณ์ความผันผวนของ **QQQ** (กองทุน ETF ที่ลงทุนตามดัชนี Nasdaq-100) ล่วงหน้า 5 วันทำการในสองรูปแบบ

- **Regression** ทำนายค่าความผันผวนของ 5 วันข้างหน้า (`target_volatility_5d`)
- **Classification** ทำนายว่า 5 วันข้างหน้าจะเป็นช่วง "ผันผวนสูง" หรือไม่ (`target_high_volatility`) โดยนิยามว่าผันผวนสูงเมื่อค่าเกินควอร์ไทล์ที่ 3 (Q75) ของข้อมูลเทรน

การพยากรณ์ความผันผวนเป็นปัญหาที่เหมาะกับ machine learning ด้วยเหตุผลสามข้อ

1. **ความสัมพันธ์ไม่ใช่เส้นตรงและเปลี่ยนตามสภาพตลาด** ความผันผวนกระจุกตัวเป็นช่วง (volatility clustering) และการกระจายของ target เบ้ขวามาก (skewness 2.80, excess kurtosis 16.26) ซึ่งต่างจากสมมติฐานของวิธีทางสถิติพื้นฐาน
2. **มีฟีเจอร์หลายตัวที่ทำงานร่วมกัน** เช่น ราคาร่วงพร้อมปริมาณซื้อขายสูงให้ความหมายต่างจากราคาร่วงเฉย ๆ การเขียนกฎ if-then ด้วยมือให้ครอบคลุมทุกกรณีทำได้ยาก
3. **มีข้อมูลพอให้เรียนรู้** 1,733 วันสำหรับเทรน

ตลาดหุ้นมีวันที่ราคากระชากแรงผิดปกติ เช่น ช่วงเดือนมีนาคม 2020 วันเหล่านี้มีจำนวนน้อยแต่มีค่าสุดโต่ง โครงงานนี้ตั้งคำถามว่า

> **การตัดช่วงที่ราคากระชากแรง (spike) ออกจากข้อมูลเทรน ทำให้โมเดลทำนายได้ดีขึ้นหรือแย่ลง**

เราตอบด้วยการทดลองแบบจับคู่: เทรนโมเดลทุกตัวสองครั้ง ครั้งหนึ่งด้วยข้อมูลเทรนเต็ม (`with_spike`) อีกครั้งด้วยข้อมูลเทรนที่ตัดช่วง spike ออก (`non_spike`) แล้ววัดผลบนข้อมูลชุดเดียวกันทุกประการ

1.2 วัตถุประสงค์ของการศึกษา

1. เพื่อพยากรณ์ความผันผวนของกองทุน QQQ ล่วงหน้า 5 วันทำการจากข้อมูลราคารายวัน ทั้งแบบ regression และ classification
2. เพื่อเขียนโมเดล machine learning 19 ตัวด้วยตนเอง และยืนยันความถูกต้องเทียบกับ library มาตรฐาน
3. เพื่อศึกษาและอธิบายกลไกภายในของโมเดลนอกเนื้อหาที่เรียนสองตัว คือ Elastic Net สำหรับ regression และ AdaBoost สำหรับ classification

4. เพื่อตอบคำถามวิจัยว่า การตัดช่วงที่ราคากระชากแรง (spike) ออกจากข้อมูลเทรน ทำให้โมเดลทำนายได้ดีขึ้นหรือแย่ลง
5. เพื่อเปรียบเทียบโมเดลด้วยตัวชี้วัดที่โจทย์กำหนด พร้อมช่วงความเชื่อมั่น และเทียบกับเส้นฐานที่ไม่ต้องเทรน

1.3 ขอบเขตของการศึกษา

1. **ข้อมูล** ราคารายวัน (Open, High, Low, Close, Volume) ของกองทุน QQQ จำนวน 2,512 วันทำการ ตั้งแต่ 31 สิงหาคม 2016 ถึง 28 สิงหาคม 2026 จาก Nasdaq
2. **ตัวแปรที่ใช้ทำนาย** ฟีเจอร์ 8 ตัวที่คำนวณจากราคาและปริมาณซื้อขายย้อนหลัง ไม่ใช้ข่าว ดัชนี VIX หรือปฏิทินเหตุการณ์
3. **สิ่งที่พยากรณ์** ความผันผวนของ 5 วันทำการข้างหน้า ทั้งเป็นค่าตัวเลข และเป็นคำตอบว่าผันผวนสูงหรือไม่
4. **โมเดล** 19 ตัว แบ่งเป็น regression 4 ตัว classification 13 ตัว และ clustering 2 ตัว เขียนด้วย NumPy ทั้งหมด ส่วน scikit-learn และ XGBoost ใช้เพื่อยืนยันผลเท่านั้น
5. **การวัดผล** เลือกการตั้งค่าของโมเดลบน Validation และวัดผลสุดท้ายบน Test ซึ่งเปิดเพียงครั้งเดียว
6. **สิ่งที่ไม่ครอบคลุม** การทดสอบกลยุทธ์การลงทุน ต้นทุนการซื้อขาย และสินทรัพย์อื่นนอกจาก QQQ

1.4 ประโยชน์ที่คาดว่าจะได้รับ

1. ได้แนวทางพยากรณ์ความผันผวนระยะสั้นจากข้อมูลราคาที่หาได้ทั่วไป พร้อมหลักฐานว่าดีกว่ากฎง่าย ๆ มากน้อยเพียงใด
2. ได้คำตอบเชิงประจักษ์ว่าควรตัดช่วง spike ออกจากข้อมูลเทรนหรือไม่ พร้อมระดับความไม่แน่นอนของคำตอบ
3. ได้ความเข้าใจกลไกภายในของโมเดล จากการเขียนเองและเทียบกับ library ทีละแถว
4. ได้ขั้นตอนการทดลองกับข้อมูลอนุกรมเวลาที่กันการรั่วของข้อมูลและทำซ้ำได้ ซึ่งนำไปใช้กับสินทรัพย์หรือโจทย์อื่นได้

1.5 นิยามศัพท์เฉพาะ

- **ผลตอบแทนรายวัน (daily return)** อัตราการเปลี่ยนแปลงของราคาปิดเทียบกับวันทำการก่อนหน้า
- **ความผันผวน (volatility)** ส่วนเบี่ยงเบนมาตรฐานของผลตอบแทนรายวันในช่วงเวลาหนึ่ง คูณ √252 เพื่อแปลงเป็นหน่วยต่อปี
- **target** ค่าที่โมเดลต้องทำนาย คือความผันผวนของ 5 วันทำการข้างหน้า (`target_volatility_5d`) และป้ายว่าผันผวนสูงหรือไม่ (`target_high_volatility`)
- **วันผันผวนสูง** วันที่ target มากกว่า 0.2531 ซึ่งเป็นควอร์ไทล์ที่ 3 (Q75) ของ target ในข้อมูลเทรน
- **ฟีเจอร์ (feature)** ข้อมูลที่ป้อนให้โมเดล ทุกตัวคำนวณจากข้อมูลถึงสิ้นวันที่ทำนายเท่านั้น
- **spike** วันที่ขนาดของผลตอบแทนรายวันมากกว่า Q3 + 3 × IQR ของข้อมูลเทรน ซึ่งเท่ากับ 4.65%
- **with_spike และ non_spike** ข้อมูลเทรนสองแบบ แบบแรกใช้ข้อมูลเทรนครบทุกแถว แบบหลังตัดแถวในช่วงรอบวัน spike ออก

- **Train, Validation และ Test** ข้อมูลสามชุดที่แบ่งตามลำดับเวลา ใช้ให้โมเดลเรียนรู้ ใช้เลือกการตั้งค่า และใช้วัดผลสุดท้าย ตามลำดับ
- **เส้นฐานเปรียบเทียบ (baseline)** กฎที่ไม่ต้องเทรน ใช้เป็นจุดเทียบว่าคะแนนของโมเดลดีหรือไม่
- **average precision (AP)** ตัวชี้วัดคุณภาพของการจัดอันดับวันที่น่าจะผันผวนสูง ค่าของการเดาสุ่มเท่ากับสัดส่วนวันผันผวนสูงของชุดข้อมูล
- **RMSE** รากที่สองของค่าเฉลี่ยความผิดพลาดกำลังสอง ใช้วัดงาน regression ยิ่งต่ำยิ่งดี
- **ช่วงความเชื่อมั่น 95% และคำว่า "คร่อมศูนย์"** ช่วงที่ค่าจริงน่าจะอยู่ ถ้าช่วงของผลต่างระหว่างสองโมเดลมีทั้งค่าบวกและค่าลบ เรียกว่าคร่อมศูนย์ และถือว่ายังบอกไม่ได้ว่าโมเดลใดดีกว่า
- **โมเดลตัวแทน (headline model)** โมเดลที่ได้คะแนนสูงสุดบน Validation ของแต่ละงาน ซึ่งถูกล็อกชื่อไว้ก่อนเปิด Test

บทที่ 2

เอกสารและงานวิจัยที่เกี่ยวข้อง

2.1 แนวคิด ทฤษฎี และหลักการที่เกี่ยวข้อง

2.1.1 ความผันผวนและลักษณะของผลตอบแทนทางการเงิน

ความผันผวนที่เกิดขึ้นจริง (realized volatility) ของช่วงเวลาหนึ่งวัดจากส่วนเบี่ยงเบนมาตรฐานของผลตอบแทนในช่วงนั้น โครงงานนี้ใช้ผลตอบแทนรายวัน 5 วัน แล้วคูณ √252 ให้เป็นหน่วยต่อปี

Cont (2001) รวบรวมลักษณะร่วมของผลตอบแทนสินทรัพย์ทางการเงิน (stylized facts) ซึ่งมีสี่ข้อที่เกี่ยวข้องกับโครงงานนี้โดยตรง

- **ความผันผวนกระจุกตัว (volatility clustering)** วันที่ราคาแกว่งแรงมักตามด้วยวันที่แกว่งแรง ความผันผวนในอดีตจึงมีข้อมูลเกี่ยวกับความผันผวนในอนาคต
- **หางหนา (heavy tails)** ผลตอบแทนขนาดใหญ่มากเกิดบ่อยกว่าที่การแจกแจงปกติทำนาย
- **leverage effect** ความผันผวนมีแนวโน้มสูงขึ้นเมื่อราคาลดลง
- **ความสัมพันธ์ระหว่างปริมาณซื้อขายกับความผันผวน** ปริมาณซื้อขายสัมพันธ์กับความผันผวนทุกแบบที่วัด

ข้อแรกเป็นพื้นฐานของฟีเจอร์ความผันผวนย้อนหลัง และของเส้นฐานที่ทายว่า "5 วันข้างหน้าจะผันผวนเท่ากับ 5 วันที่ผ่านมา" ข้อสองเป็นเหตุผลที่โครงงานนี้ใช้ควอร์ไทล์แทนส่วนเบี่ยงเบนมาตรฐานในการนิยาม spike (หัวข้อ 3.3.4) ข้อสามและข้อสี่เป็นเหตุผลของฟีเจอร์ผลตอบแทน ตัวชี้แนวโน้มราคา และปริมาณซื้อขาย

2.1.2 โมเดล regression เชิงเส้นและการปรับค่าน้ำหนัก

Linear regression หาน้ำหนักของฟีเจอร์ที่ทำให้ผลรวมความผิดพลาดกำลังสองต่ำที่สุด (least squares) โครงงานนี้ใช้สามรูปแบบที่สอนในห้องเรียน (Hastie et al., 2009)

- **Simple Linear** เส้นตรงจากฟีเจอร์เดียว แก้ด้วยสูตรปิด โปรแกรมลองทั้ง 8 ฟีเจอร์แล้วเลือกตัวที่ดีที่สุด
- **Multiple Linear** เส้นตรงจากทั้ง 8 ฟีเจอร์ แก้ด้วย least squares
- **Polynomial** ยกกำลังฟีเจอร์เดียว (ดีกรี 2 หรือ 3) แล้วทำ linear regression

เมื่อฟีเจอร์สัมพันธ์กันสูง น้ำหนักจาก least squares จะไม่นิ่ง วิธีแก้ที่ใช้กันคือเพิ่มค่าปรับ (penalty) ให้น้ำหนักที่มีขนาดใหญ่ Hoerl และ Kennard (1970) เสนอ ridge regression ซึ่งใช้ค่าปรับแบบ L2 คือผลรวมกำลังสองของน้ำหนัก ทำให้น้ำหนักทุกตัวเล็กลงแต่ไม่เป็นศูนย์ Tibshirani (1996) เสนอ lasso ซึ่งใช้ค่าปรับแบบ L1 คือผลรวมค่าสัมบูรณ์ของน้ำหนัก ทำให้น้ำหนักบางตัวเป็นศูนย์พอดี จึงคัดฟีเจอร์ได้ในตัว แต่เมื่อฟีเจอร์สัมพันธ์กันเป็นกลุ่ม lasso มักเลือกเพียงตัวเดียวจากกลุ่ม

2.1.3 Elastic Net: โมเดลนอกเนื้อหาที่เรียนสำหรับงาน regression

Zou และ Hastie (2005) เสนอ Elastic Net ซึ่งรวมค่าปรับของ lasso และ ridge ไว้ด้วยกัน เพื่อให้คัดฟีเจอร์ได้เหมือน lasso และให้ฟีเจอร์ที่สัมพันธ์กันได้น้ำหนักใกล้เคียงกันเหมือน ridge

แนวคิด linear regression ธรรมดาหาน้ำหนัก (coefficient) ที่ทำให้ความผิดพลาดต่ำที่สุดเพียงอย่างเดียว เมื่อฟีเจอร์ซ้ำซ้อนกัน น้ำหนักจะไม่นิ่ง: ขยับข้อมูลเล็กน้อย น้ำหนักเปลี่ยนมาก Elastic Net แก้ด้วยการเพิ่ม "ค่าปรับ" เมื่อน้ำหนักมีขนาดใหญ่

สิ่งที่โมเดลทำให้ต่ำที่สุด

$$J(w) = (1/2n)\cdot\|y - Xw\|^2 + \alpha\cdot\rho\cdot\|w\|_1 + \alpha\cdot(1-\rho)/2\cdot\|w\|^2$$

- พจน์แรกคือความผิดพลาดกำลังสองเฉลี่ย
- α (alpha) คือความแรงของค่าปรับ ยิ่งมากน้ำหนักยิ่งถูกบีบเข้าหาศูนย์
- ρ (l1_ratio) คือสัดส่วนของค่าปรับแบบ L1
- **L1** ($\|w\|_1$ = ผลรวมค่าสัมบูรณ์ของน้ำหนัก) ทำให้น้ำหนักบางตัว **เป็นศูนย์พอดี** เท่ากับคัดฟีเจอร์นั้นทิ้ง
- **L2** ($\|w\|^2$ = ผลรวมกำลังสองของน้ำหนัก) ทำให้น้ำหนักทุกตัวเล็กลงแต่ไม่เป็นศูนย์ และทำให้ฟีเจอร์ที่ซ้ำซ้อนกันแบ่งน้ำหนักกันอย่างนิ่ง

วิธีหาคำตอบ: coordinate descent พจน์ L1 หาอนุพันธ์ที่ศูนย์ไม่ได้ จึงใช้ gradient descent ธรรมดาไม่ได้ เราปรับน้ำหนักทีละตัวโดยตรึงตัวอื่นไว้ ซึ่งมีคำตอบแบบสูตรปิดสำหรับแต่ละตัว

1. คำนวณ ρ_j = ความสัมพันธ์ระหว่างฟีเจอร์ j กับส่วนที่โมเดลยังอธิบายไม่ได้เมื่อไม่นับฟีเจอร์ j
2. ผ่าน **soft-threshold**: $S(v, \gamma) = \text{sign}(v)\cdot\max(|v| - \gamma, 0)$ ถ้า $|\rho_j|$ เล็กกว่า $\alpha\cdot\rho$ น้ำหนักจะกลายเป็นศูนย์ นี่คือกลไกที่คัดฟีเจอร์ทิ้ง
3. หารด้วย $(z_j + \alpha\cdot(1-\rho))$ โดย z_j คือขนาดของฟีเจอร์ j ตัวหารนี้คือจุดที่ L2 ทำงาน
4. วนทุกฟีเจอร์ซ้ำจนน้ำหนักเปลี่ยนน้อยกว่าค่าที่กำหนด

รวมเป็นสูตร: $w_j = S(\rho_j, \alpha\cdot\rho) / (z_j + \alpha\cdot(1-\rho))$ โค้ดอยู่ที่ `src/ml/regression/elastic_net.py`

วิธี coordinate descent สำหรับโมเดลกลุ่มนี้อธิบายไว้โดย Friedman et al. (2010) ซึ่งเป็นวิธีเดียวกับที่ scikit-learn ใช้ โครงงานนี้จึงเทียบผลกับ `ElasticNet` ของ scikit-learn ได้โดยตรง

ทำไมเหมาะกับข้อมูลนี้ ฟีเจอร์ความผันผวนย้อนหลัง 5 วันกับ 20 วันมีสหสัมพันธ์ 0.80 (หัวข้อ 4.1)

2.1.4 โมเดล classification และ clustering

โมเดล classification 13 ตัวและ clustering 2 ตัวที่ใช้มีหลักการโดยย่อดังนี้

- **Logistic Regression** แปลงผลรวมถ่วงน้ำหนักเป็นความน่าจะเป็นด้วย sigmoid เทรนด้วย gradient descent
- **Gaussian Naive Bayes** สมมติว่าแต่ละฟีเจอร์กระจายแบบปกติและอิสระต่อกันภายในคลาส แล้วใช้กฎของ Bayes
- **k-Nearest Neighbors** ดูคลาสของเพื่อนบ้านที่ใกล้ที่สุด k ตัว ถ่วงน้ำหนักด้วยระยะทาง
- **Perceptron** ปรับน้ำหนักเมื่อทายผิด ลู่เข้าเฉพาะเมื่อข้อมูลแยกด้วยเส้นตรงได้
- **Single-Layer Perceptron (SLP)** โหนด sigmoid หนึ่งชั้น เทรนแบบ mini-batch
- **Multi-Layer Perceptron (MLP)** โครงข่ายประสาทที่มีชั้นซ่อน ใช้ ReLU และ backpropagation
- **Decision Tree** แบ่งข้อมูลด้วยคำถามทีละข้อ เลือกคำถามที่ลด Gini impurity มากที่สุด
- **Random Forest** ต้นไม้หลายต้นจากข้อมูลที่สุ่มซ้ำและสุ่มฟีเจอร์ แล้วเฉลี่ยผล (ทดลองร่วมกับ PCA ตามโจทย์)

- **Gradient Boosting** ต้นไม้ต่อกันทีละต้น แต่ละต้นแก้ความผิดพลาดของต้นก่อนหน้า
- **XGBoost** gradient boosting ที่ใช้อนุพันธ์อันดับสองและมี regularization
- **AdaBoost ★** โมเดลอ่อนต่อกัน โดยเพิ่มน้ำหนักให้ตัวอย่างที่ทายผิด (หัวข้อ 2.1.5)
- **Stacking** ใช้คำทำนายของโมเดลฐานหลายตัวเป็น input ของโมเดลชั้นบน โดยสร้างคำทำนายแบบ out-of-fold ตามลำดับเวลาเพื่อกันข้อมูลรั่ว
- **Support Vector Machine** หาเส้นแบ่งที่มีระยะขอบกว้างที่สุด (linear kernel ทดลองร่วมกับ PCA ตามโจทย์)
- **k-Means** และ **Agglomerative** จัดกลุ่มวันที่มีฟีเจอร์คล้ายกันโดยไม่ใช้ label

หลักการของโมเดลกลุ่มนี้อ้างอิงจาก Hastie et al. (2009) ส่วน Random Forest, Gradient Boosting, XGBoost, Stacking และ Support Vector Machine อ้างอิงงานต้นฉบับของ Breiman (2001), Friedman (2001), Chen และ Guestrin (2016), Wolpert (1992) และ Cortes และ Vapnik (1995) ตามลำดับ

2.1.5 AdaBoost: โมเดลนอกเนื้อหาที่เรียนสำหรับงาน classification

Freund และ Schapire (1997) เสนอ AdaBoost ซึ่งรวมโมเดลอ่อนหลายตัวเป็นโมเดลที่แม่นขึ้น โครงงานนี้ใช้อัลกอริทึม SAMME ของ Zhu et al. (2009) ซึ่งเป็นรูปทั่วไปสำหรับหลายคลาส และเมื่อมีสองคลาสจะเท่ากับ AdaBoost ดั้งเดิม

แนวคิด AdaBoost สร้างโมเดลอ่อน (weak learner) ต่อกันทีละตัว โดย **ตัวถัดไปตั้งใจแก้จุดที่ตัวก่อนหน้าทำผิด** โมเดลอ่อนที่ใช้คือ decision stump หรือต้นไม้ที่ถามคำถามเดียว เช่น "ความผันผวน 20 วันเกิน 0.25 หรือไม่"

ขั้นตอน (อัลกอริทึม SAMME)

1. ให้น้ำหนักทุกตัวอย่างเท่ากัน `w_i = 1/n`
2. ในรอบที่ m เทรน stump บนข้อมูลที่ถ่วงน้ำหนัก
3. คำนวณความผิดพลาดแบบถ่วงน้ำหนัก ε_m = ผลรวมน้ำหนักของตัวอย่างที่ stump ทายผิด
4. คำนวณสิทธิ์ออกเสียงของ stump: $\alpha_m = \text{learning_rate} \cdot \ln((1 - \varepsilon_m) / \varepsilon_m)$ ยิ่งผิดน้อย สิทธิ์ออกเสียงยิ่งมาก ถ้า ε_m เท่ากับ 0.5 (ไม่ดีกว่าเดาสุ่ม) สิทธิ์ออกเสียงจะเป็นศูนย์
5. ปรับน้ำหนักตัวอย่าง: ตัวที่ทายผิดถูกคูณด้วย $\exp(\alpha_m)$ แล้วปรับให้ผลรวมเป็น 1 stump ตัวถัดไปจึงให้ความสนใจกับตัวอย่างที่ยากมากขึ้น
6. คำตอบสุดท้ายคือผลโหวตถ่วงน้ำหนัก α_m ของ stump ทั้งหมด

Friedman et al. (2000) แสดงว่า AdaBoost เทียบเท่ากับการสร้างโมเดลแบบบวกทีละขั้น (forward stagewise additive modeling) ที่ลด exponential loss $L(y, F) = \exp(-y \cdot F)$ โดย y เป็น +1 หรือ −1 และ F คือผลโหวตรวม loss ชนิดนี้เพิ่มขึ้นแบบทวีคูณเมื่อทายผิดด้วยความมั่นใจสูง

ทำไมเลือกโมเดลนี้ AdaBoost เทียบเท่ากับการลด exponential loss ซึ่งลงโทษตัวอย่างที่ทายผิดหนัก ๆ แบบทวีคูณ ตัวอย่างสุดโต่งจึงถูกเพิ่มน้ำหนักซ้ำแล้วซ้ำอีก เราตั้งสมมติฐานไว้ก่อนทดลองว่า **AdaBoost น่าจะเป็นโมเดลที่ได้ประโยชน์มากที่สุดเมื่อตัด spike ออก** (ผลอยู่ในหัวข้อ 4.5)

2.1.6 ตัวชี้วัดที่ใช้ประเมินโมเดล

งาน classification นับผลการทำนายเป็นสี่กลุ่มใน confusion matrix คือ TP (ทายว่าผันผวนสูงและถูก), FP (ทายว่าผันผวนสูงแต่ผิด), TN (ทายว่าไม่ผันผวนสูงและถูก) และ FN (ทายว่าไม่ผันผวนสูงแต่ผิด) ตัวชี้วัดที่โจทย์กำหนดคำนวณจากสี่ค่านี้

ตารางที่ 2.1 ตัวชี้วัดที่ใช้ประเมินโมเดล

ตัวชี้วัด	สูตร	ความหมาย
Accuracy	`(TP + TN) / n`	สัดส่วนที่ทายถูกทั้งหมด
Precision	`TP / (TP + FP)`	เมื่อทายว่าผันผวนสูง ถูกกี่ส่วน
Sensitivity (recall)	`TP / (TP + FN)`	วันผันผวนสูงจริง จับได้กี่ส่วน
Specificity (true negative rate)	`TN / (TN + FP)`	วันปกติจริง ทายถูกกี่ส่วน
F1-score	`2 · precision · recall / (precision + recall)`	ค่าเฉลี่ยฮาร์มอนิกของ precision และ recall
ROC-AUC	พื้นที่ใต้ ROC curve	โอกาสที่วันผันผวนสูงได้คะแนนสูงกว่าวันปกติ
Average precision (AP)	พื้นที่ใต้ precision-recall curve	คุณภาพของการจัดอันดับเมื่อคลาสไม่สมดุล
RMSE	`sqrt(mean((y − ŷ)²))`	ขนาดความผิดพลาดเฉลี่ยของงาน regression
R-Square	`1 − SS_res / SS_tot`	สัดส่วนความแปรปรวนของ target ที่โมเดลอธิบายได้
Silhouette	ค่าเฉลี่ยของ `(b − a) / max(a, b)`	กลุ่มแยกจากกันชัดเพียงใด (งาน clustering)

ROC curve พล็อตอัตราจับได้เทียบกับอัตราเตือนผิดเมื่อไล่ค่า threshold ส่วน precision-recall curve พล็อต precision เทียบกับ recall งานของ Davis และ Goadrich (2006) และของ Saito และ Rehmsmeier (2015) แสดงว่าเมื่อคลาสไม่สมดุล precision-recall curve ให้ภาพของผลงานที่ตรงกว่า ROC curve เพราะจำนวนวันปกติที่มากทำให้การเตือนผิดจำนวนมากดูเล็กใน ROC โครงงานนี้จึงใช้ AP เป็นตัวชี้วัดหลักของงาน classification

2.1.7 การประเมินโมเดลกับข้อมูลอนุกรมเวลา

ข้อมูลอนุกรมเวลามีลำดับ และค่าของวันใกล้กันสัมพันธ์กัน วิธีประเมินที่ใช้กับข้อมูลทั่วไปจึงต้องปรับสามเรื่อง

- **การแบ่งข้อมูล** ต้องแบ่งตามลำดับเวลา ถ้าสุ่มแบ่ง ข้อมูลของอนาคตจะปนเข้าไปในข้อมูลเทรน (look-ahead leakage) เมื่อ target ของแต่ละวันใช้ข้อมูลของหลายวันข้างหน้า ต้องเว้นช่องว่างระหว่างชุดข้อมูลให้ target ไม่ซ้อนกัน ซึ่ง López de Prado (2018) เรียกว่า purging
- **การวัดความไม่แน่นอน** bootstrap แบบสุ่มทีละแถวถือว่าทุกแถวอิสระต่อกัน ซึ่งไม่จริงกับอนุกรมเวลา Künsch (1989) เสนอ block bootstrap ที่สุ่มเป็นก้อนของข้อมูลติดกัน เพื่อรักษาความสัมพันธ์ภายในก้อน
- **การหาค่าผิดปกติ** Tukey (1977) เสนอกฎที่ใช้ควอร์ไทล์ คือค่าที่อยู่ไกลจาก Q3 เกิน 1.5 เท่าของ IQR ถือเป็นค่าผิดปกติ และเกิน 3 เท่าถือเป็นค่าผิดปกติรุนแรง กฎนี้ไม่ถูกดึงโดยค่าสุดโต่ง เพราะควอร์ไทล์ขึ้นกับลำดับของข้อมูลเท่านั้น

การวัดความสำคัญของฟีเจอร์ใช้ permutation importance ตามแนวคิดของ Breiman (2001) คือสลับลำดับค่าของฟีเจอร์หนึ่งตัว แล้วดูว่าคะแนนของโมเดลแย่ลงเท่าไร

2.2 งานวิจัยที่เกี่ยวข้อง

โมเดลความผันผวนแบบดั้งเดิม Engle (1982) เสนอโมเดล ARCH ซึ่งให้ความแปรปรวน ณ เวลาหนึ่งขึ้นกับขนาดของความผิดพลาดในอดีต และ Bollerslev (1986) ขยายเป็น GARCH ซึ่งให้ความแปรปรวนขึ้นกับค่าของตัวเองในอดีตด้วย โมเดลกลุ่มนี้จับลักษณะความผันผวนกระจุกตัวได้ และเป็นมาตรฐานของการพยากรณ์ความผันผวนมาหลายทศวรรษ

การวัดความผันผวนที่เกิดขึ้นจริง Andersen และ Bollerslev (1998) ชี้ว่างานที่สรุปว่าโมเดลกลุ่ม GARCH พยากรณ์ได้ไม่ดีนั้น ใช้ผลตอบแทนกำลังสองของวันเดียวเป็นค่าจริง ซึ่งมีสัญญาณรบกวนสูง เมื่อวัดค่าจริงด้วย realized volatility ที่รวมจากผลตอบแทนความถี่สูง โมเดลเดิมพยากรณ์ได้ดีกว่าที่เคยรายงานมาก ข้อสังเกตนี้เกี่ยวข้องกับโครงงานนี้เพราะ target ของเราคำนวณจากผลตอบแทนรายวันเพียง 5 ค่า จึงมีสัญญาณรบกวนสูงเช่นกัน

โมเดลเชิงเส้นบนความผันผวนย้อนหลัง Corsi (2009) เสนอโมเดล HAR-RV ซึ่งเป็น linear regression ของ realized volatility บนค่าเฉลี่ยของตัวเองย้อนหลังหนึ่งวัน หนึ่งสัปดาห์ และหนึ่งเดือน โมเดลนี้เรียบง่ายแต่พยากรณ์ได้ดี ฟีเจอร์ความผันผวนย้อนหลัง 5 วันและ 20 วันของโครงงานนี้ใช้แนวคิดเดียวกัน คือมองความผันผวนในอดีตหลายช่วงเวลา

การเปรียบเทียบวิธีพยากรณ์ Poon และ Granger (2003) ทบทวนงานวิจัย 93 ชิ้นที่เปรียบเทียบวิธีพยากรณ์ความผันผวน และพบว่าความผันผวนที่แฝงอยู่ในราคา option (implied volatility) มักให้ผลพยากรณ์ดีที่สุด ส่วนวิธีที่ใช้ความผันผวนในอดีตกับโมเดลกลุ่ม GARCH ให้ผลใกล้เคียงกัน โครงงานนี้ไม่ใช้ implied volatility ซึ่งเป็นข้อจำกัดที่ระบุไว้ในบทที่ 5

Machine learning กับการพยากรณ์ความผันผวน Christensen et al. (2023) เปรียบเทียบ machine learning หลายกลุ่ม ได้แก่ regression ที่มีค่าปรับ โมเดลต้นไม้ และโครงข่ายประสาท กับโมเดลตระกูล HAR ในการพยากรณ์ realized variance ของหุ้นในดัชนี Dow Jones และพบว่า machine learning ให้ผลดีกว่า โดยได้เปรียบมากขึ้นเมื่อพยากรณ์ไกลขึ้นและเมื่อมีตัวแปรเพิ่มเติม

ตำแหน่งของโครงงานนี้ โครงงานนี้ต่างจากงานข้างต้นสามเรื่อง คือ (1) ใช้เฉพาะข้อมูลราคารายวัน ไม่มีข้อมูลความถี่สูงหรือ implied volatility (2) เขียนโมเดลทุกตัวเองและยืนยันผลกับ library เพื่อให้เข้าใจกลไกภายใน และ (3) ตั้งคำถามเรื่องการตัดช่วงราคากระชากแรงออกจากข้อมูลเทรน ซึ่งทดสอบด้วยการทดลองแบบจับคู่บนข้อมูลวัดผลชุดเดียวกัน

บทที่ 3

วิธีดำเนินการศึกษา

3.1 แหล่งข้อมูล

ประชากรของการศึกษาคือราคารายวันของกองทุน QQQ ซึ่งเป็นกองทุน ETF ที่ลงทุนตามดัชนี Nasdaq-100 กลุ่มตัวอย่างคือข้อมูล 2,512 วันทำการ ตั้งแต่ 31 สิงหาคม 2016 ถึง 28 สิงหาคม 2026 จากหน้าข้อมูลย้อนหลังของ Nasdaq (Nasdaq, 2026) แต่ละวันมีราคาเปิด ราคาสูงสุด ราคาต่ำสุด ราคาปิด และปริมาณซื้อขาย

ข้อมูลมาจาก Nasdaq ซึ่งให้ดาวน์โหลดย้อนหลังได้ 10 ปีแบบเลื่อนไปทุกวัน ถ้าดาวน์โหลดใหม่ทุกครั้งที่รัน ข้อมูลจะไม่เหมือนเดิมและทำซ้ำผลไม่ได้ เราจึง **ตรึงข้อมูลชุดเดียว** (snapshot) ไว้ใน repo ที่ `data/raw/qqq_daily.csv` พร้อมบันทึกค่า SHA-256 ใน `data/manifests/qqq_daily_snapshot.json` โปรแกรมจะปฏิเสธการเขียนทับไฟล์นี้

3.2 เครื่องมือที่ใช้ในการศึกษา

ตารางที่ 3.1 เครื่องมือที่ใช้ในการศึกษา

เครื่องมือ	รุ่น	ใช้ทำอะไร
Python	3.14.8	ภาษาที่ใช้เขียนโปรแกรมทั้งหมด
NumPy	2.5.3	เขียนโมเดลทั้ง 19 ตัวและการคำนวณตัวชี้วัด
pandas	3.0.6	อ่านและจัดการตารางข้อมูล
Matplotlib	3.11.2	สร้างรูปทั้งหมด
scikit-learn	1.9.1	โมเดลอ้างอิงสำหรับยืนยันผลเท่านั้น
XGBoost	3.4.1	โมเดลอ้างอิงของ `xgboost` สำหรับยืนยันผลเท่านั้น
pytest	9.1.1	โปรแกรมทดสอบอัตโนมัติ 1,308 ข้อ
Jupyter Notebook	—	notebook 6 เล่มที่แสดงผลพร้อมคำอธิบาย
Git และ GitHub	—	เก็บประวัติของโค้ด ข้อมูล และผลการทดลอง

ที่มา: `requirements-lock.txt` โมเดลอ้างอิงมาจาก scikit-learn (Pedregosa et al., 2011) และ XGBoost (Chen & Guestrin, 2016)

โจทย์กำหนดให้เขียนโมเดลเอง (from scratch) และอนุญาตให้ใช้ library เพื่อยืนยันผลเท่านั้น โมเดลทั้ง 19 ตัวจึงเขียนด้วย NumPy ล้วนใต้ `src/ml/` ทุกตัวมี interface เดียวกัน (`fit`, `predict`, `state_dict`, `load_state`, `reference`) เพื่อให้เทรน บันทึก โหลด และเทียบกับ library ได้ด้วยโค้ดชุดเดียว

3.3 วิธีการเก็บรวบรวมและเตรียมข้อมูล

3.3.1 ขั้นตอนเตรียมข้อมูล

ข้อมูลถูกเก็บครั้งเดียวจากหน้าข้อมูลย้อนหลังของ Nasdaq แล้วตรึงไว้ตามหัวข้อ 3.1 จากนั้นผ่านขั้นตอนห้าขั้น

1. **ทำความสะอาด** ตรวจวันที่ซ้ำ ค่าว่าง และความสมเหตุสมผลของราคา
2. **สร้างฟีเจอร์** 8 ตัวจากข้อมูลถึงวัน t

3. **สร้าง target** จากผลตอบแทนของวัน t+1 ถึง t+5
4. **ตัดแถวที่คำนวณไม่ครบ** 20 แถวแรก (ฟีเจอร์ต้องใช้ข้อมูลย้อนหลัง 20 วัน) และ 5 แถวท้าย (target ต้องใช้ข้อมูลอนาคต 5 วัน) เหลือ 2,487 แถว
5. **แบ่งข้อมูลตามเวลา** 70% / 15% / 15%

3.3.2 ฟีเจอร์ 8 ตัว

ฟีเจอร์ (feature) คือข้อมูลที่ป้อนให้โมเดล ทุกตัวคำนวณจากข้อมูลถึงสิ้นวัน t เท่านั้น โมเดลจึงไม่เห็นอนาคต นิยามอยู่ใน `src/build_features.py`

ตารางที่ 3.2 ฟีเจอร์ 8 ตัว นิยาม และเหตุผลที่เลือก

ฟีเจอร์	นิยาม	เหตุผลที่เลือก
`return_1d`	ผลตอบแทนของวันนี้เทียบกับเมื่อวาน	วันที่ราคาร่วงแรงมักตามด้วยความผันผวน
`return_5d`	ผลตอบแทนสะสม 5 วัน	บอกทิศทางระยะสั้น ตลาดขาลงมักผันผวนกว่าขาขึ้น
`historical_volatility_5d`	ความผันผวนของ 5 วันที่ผ่านมา	ความผันผวนมักต่อเนื่อง ช่วงปั่นป่วนตามด้วยช่วงปั่นป่วน
`historical_volatility_20d`	ความผันผวนของ 20 วันที่ผ่านมา	บอกสภาพตลาดระยะกลาง นิ่งกว่าแบบ 5 วัน
`intraday_range`	(ราคาสูงสุด − ต่ำสุด) ÷ ราคาปิด ของวันนี้	วัดการแกว่งตัวภายในวัน ซึ่งผลตอบแทนรายวันมองไม่เห็น
`sma_ratio_5_20`	ค่าเฉลี่ยราคา 5 วัน ÷ ค่าเฉลี่ย 20 วัน	บอกว่าราคาอยู่เหนือหรือใต้แนวโน้ม
`rsi_14`	ดัชนี RSI 14 วัน	บอกภาวะซื้อมากหรือขายมากเกินไป
`volume_zscore_20`	ปริมาณซื้อขายวันนี้เทียบกับค่าเฉลี่ย 20 วัน	ปริมาณซื้อขายที่ผิดปกติมักมาพร้อมข่าวสำคัญ

โจทย์กำหนดให้ใช้ฟีเจอร์อย่างน้อย 5 ตัว โครงงานนี้ใช้ 8 ตัว

3.3.3 target และการแบ่งข้อมูล

target ของงาน regression คือความผันผวนของผลตอบแทนรายวันของวัน t+1 ถึง t+5 ส่วน target ของงาน classification คือป้ายว่าค่านั้นเกินเส้นแบ่ง "ผันผวนสูง" หรือไม่ ข้อมูล 2,487 แถวถูกแบ่งตามลำดับเวลาเป็นสามชุด

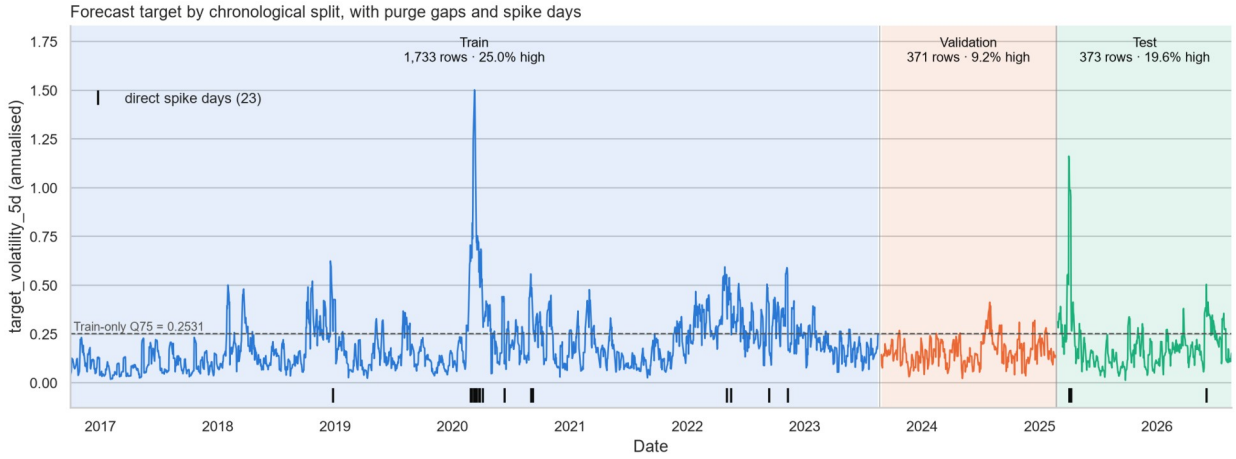
ตารางที่ 3.3 การแบ่งข้อมูลตามลำดับเวลา

ชุดข้อมูล	ช่วงวันที่	จำนวนแถว	วันผันผวนสูง	ใช้ทำอะไร
Train	29 ก.ย. 2016 – 18 ส.ค. 2023	1,733	433 (25.0%)	ให้โมเดลเรียนรู้
Validation	28 ส.ค. 2023 – 19 ก.พ. 2025	371	34 (9.2%)	เลือกการตั้งค่าของโมเดล
Test	27 ก.พ. 2025 – 21 ส.ค. 2026	373	73 (19.6%)	วัดผลสุดท้าย ครั้งเดียว

ที่มา: `outputs/reports/data_split_report.json` และ `docs/audit/DATA_FLOW.md`

ทำไมไม่สุ่มแบ่งข้อมูล ถ้าสุ่ม วันในอนาคตจะปนเข้าไปในข้อมูลเทรน โมเดลจะ "เห็นอนาคต" และได้คะแนนสูงเกินจริง (look-ahead leakage) เราจึงแบ่งตามลำดับเวลา และ **เว้นช่องว่าง 5 วันทำการ** (purge gap) ระหว่างชุด เพราะ target ของวันสุดท้ายในชุดหนึ่งใช้ข้อมูลของ 5 วันถัดไป ซึ่งมิฉะนั้นจะซ้อนกับชุดถัดไป

เส้นแบ่ง "ผันผวนสูง" คือ Q75 ของ target บน Train เท่านั้น ได้ค่า 0.2531 แล้วใช้เส้นเดียวกันกับ Validation และ Test สัดส่วนวันผันผวนสูงของสองชุดหลังจึงไม่ใช่ 25% และต่างกันเอง ซึ่งมีผลต่อการอ่านคะแนน (หัวข้อ 4.4)



รูปที่ 3.1 ค่า target ตามเวลา การแบ่งข้อมูล ช่องว่างระหว่างชุด และวันที่เกิด spike

3.3.4 การวิเคราะห์ spike

นิยาม spike คือวันที่ขนาดของผลตอบแทนรายวัน **มากกว่า** Q3 + 3 × IQR ของข้อมูลเทรน โดย Q1 และ Q3 คือค่าที่ 25% และ 75% ของวันในข้อมูลเทรนขยับน้อยกว่า และ IQR = Q3 − Q1 คือความกว้างของช่วงกลางที่วันครึ่งหนึ่งอยู่ บนข้อมูลเทรนได้ Q1 = 0.298%, Q3 = 1.387% และ IQR = 1.089% เส้นแบ่งจึงอยู่ที่ 1.387% + 3 × 1.089% = 4.65% เส้นนี้คำนวณจาก Train เท่านั้น แล้วใช้ค่าเดียวกันกับ Validation และ Test

ทำไมเลือกเกณฑ์นี้ มีเหตุผลสามข้อ หลักฐานทั้งหมดอยู่ใน `notebooks/06_spike_analysis.ipynb`

1. **กำหนดก่อนเห็นผลของโมเดล** เกณฑ์ถูกเลือกจากหลักการและตรึงไว้ก่อนเทรนโมเดลตัวแรก จึงไม่ได้ถูกปรับเพื่อให้ผลการทดลองออกมาทางใดทางหนึ่ง
2. **ควอร์ไทล์ไม่ถูกดึงโดยค่าที่กำลังตามหา** วิธีที่คุ้นกันคือ "ห่างจากค่าเฉลี่ยเกิน 3 เท่าของส่วนเบี่ยงเบนมาตรฐาน (SD)" แต่ SD ใหญ่ขึ้นตามวันสุดโต่ง เมื่อนำวัน spike 19 วันออกจากข้อมูลเทรน เส้นแบ่งแบบ 3 × SD ขยับ 11.8% (จาก 4.44% เป็น 3.92%) ส่วนเส้นแบ่งแบบ Q3 + 3 × IQR ขยับเพียง 3.0% (จาก 4.65% เป็น 4.51%)
3. **ตัวคูณ 3 จับเฉพาะวันที่สุดโต่งจริง** กฎ IQR ที่ John Tukey เสนอไว้ในหนังสือ Exploratory Data Analysis (1977) มีสองระดับ ตัวคูณ 1.5 ใช้หาค่าผิดปกติทั่วไป ตัวคูณ 3 ใช้หาค่าผิดปกติรุนแรง คำถามวิจัยพูดถึงวันที่ราคากระชากแรงผิดปกติ จึงใช้ระดับหลัง

ตารางถัดไปแสดงว่าถ้าใช้เกณฑ์อื่น ข้อมูลเทรนจะเหลือเท่าไร ข้อมูลเทรนเดิมมี 1,733 แถว และมีวันผันผวนสูง 433 วัน

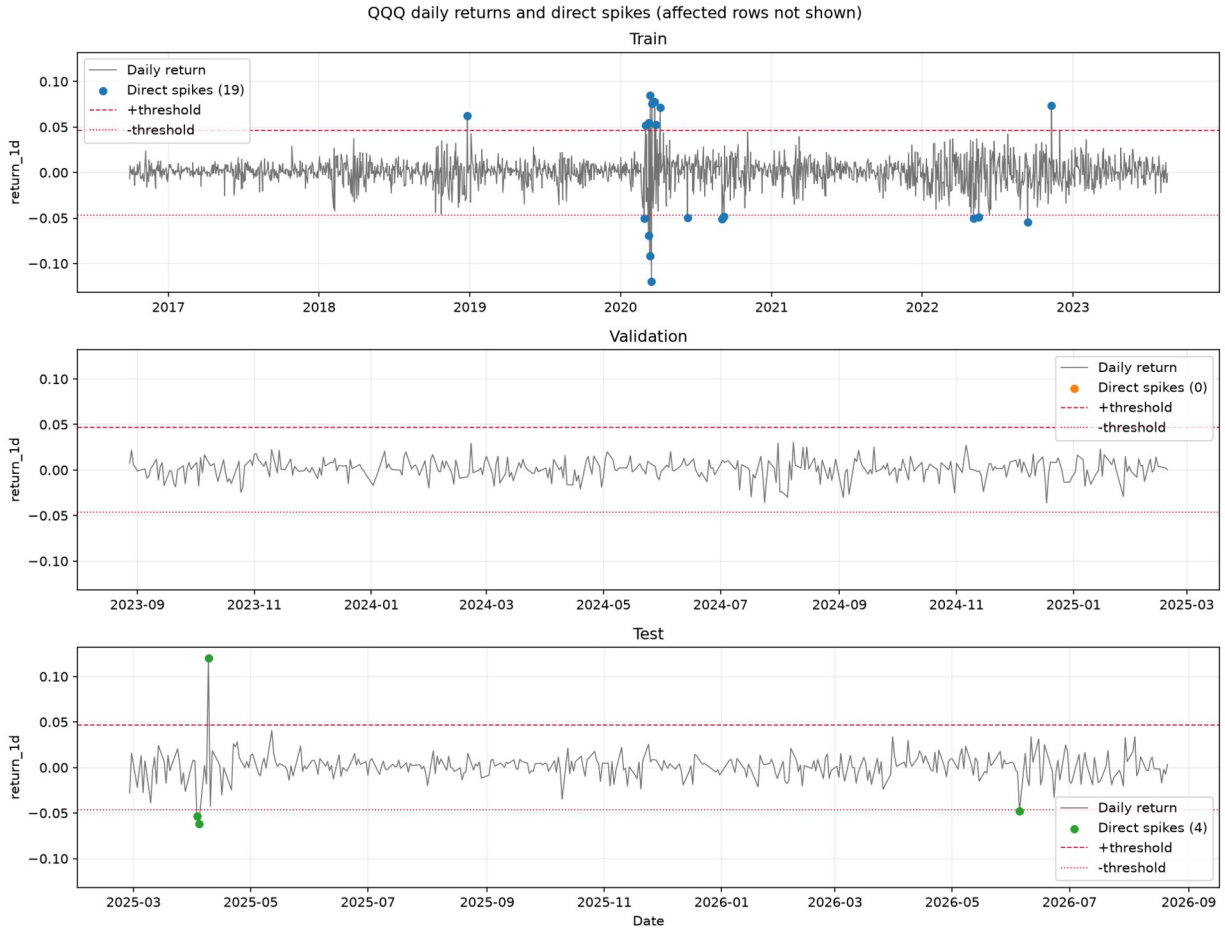
ตารางที่ 3.4 ข้อมูลเทรนที่เหลือเมื่อใช้เกณฑ์ spike แต่ละแบบ

เกณฑ์	เส้นแบ่ง	วัน spike	แถวที่ถูกตัด	วันผันผวนสูงที่เหลือ
Q3 + 1.5 × IQR	3.02%	91	690 (39.8%)	52
Q3 + 3 × IQR (เกณฑ์ที่ใช้)	4.65%	19	213 (12.3%)	280
เปอร์เซ็นไทล์ที่ 99	4.88%	18	211 (12.2%)	281
ห่างจากค่าเฉลี่ยเกิน 3 SD	4.44%	24	282 (16.3%)	237
robust z-score เกิน 3.5	3.21%	72	638 (36.8%)	60

ที่มา: `notebooks/06_spike_analysis.ipynb` หัวข้อ 3 คำนวณจากข้อมูลเทรนเท่านั้น

ตัวคูณ 1.5 จะตัดข้อมูลเทรนเกือบ 40% และเหลือวันผันผวนสูงเพียง 52 จาก 433 วัน ชุด "ไม่มี spike" จะกลายเป็นชุด "แทบไม่มีวันผันผวนสูง" และการทดลองจะไม่ได้ตอบคำถามเรื่อง spike อีกต่อไป ส่วนเปอร์เซ็นไทล์ที่ 99 ให้ผลแทบเท่ากับเกณฑ์ที่ใช้ ข้อสรุปจึงไม่ขึ้นกับการเลือกระหว่างสองนิยามนี้ ตารางนี้แสดงเฉพาะผลต่อจำนวนข้อมูล เกณฑ์ทางเลือกไม่ได้ถูกนำไปเทรนโมเดล และเราไม่ได้อ้างว่าตัวคูณ 3 เป็นเกณฑ์ที่ดีที่สุด

ผลการตรวจ พบ spike 23 วัน: Train 19 วัน หรือ 1.1% ของข้อมูลเทรน (11 วันอยู่ในช่วงกุมภาพันธ์ถึงเมษายน 2020), Validation 0 วัน, Test 4 วัน (3 วันในเดือนเมษายน 2025 และ 1 วันในเดือนมิถุนายน 2026) ทุกวันถูกตรวจย้อนถึงไฟล์ราคาดิบ และจัดเป็นการเคลื่อนไหวของตลาดจริง ไม่ใช่ข้อมูลผิดพลาด ที่มา: `outputs/reports/spike_event_audit.csv`

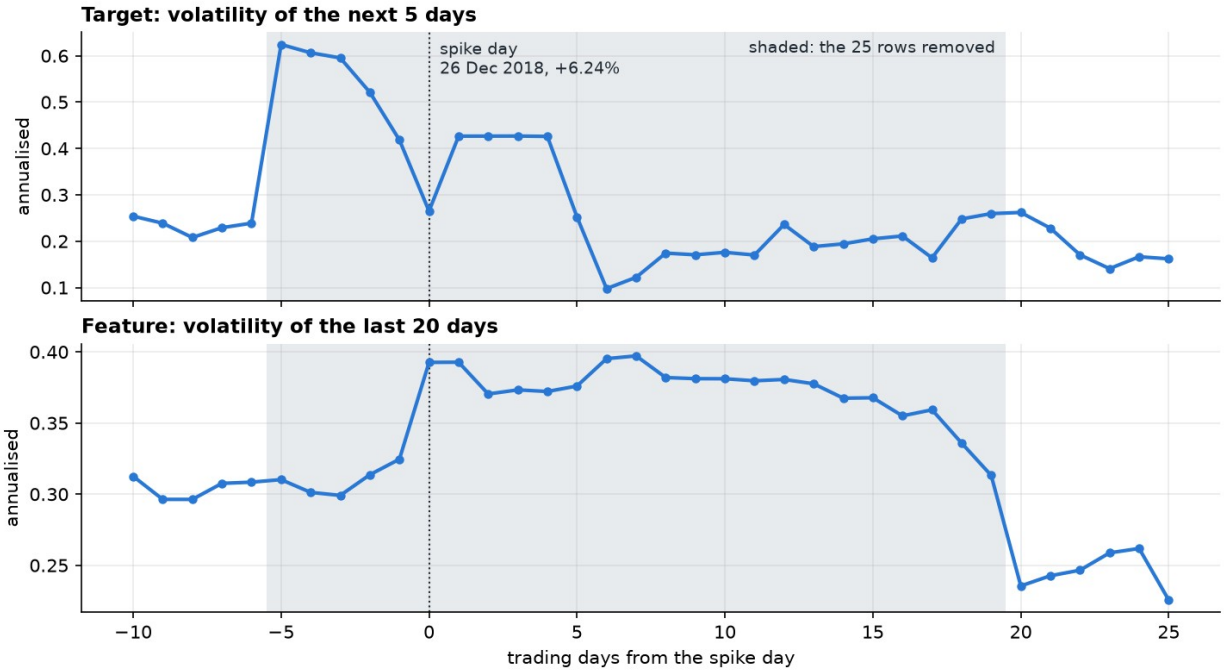


รูปที่ 3.2 ผลตอบแทนรายวันและวันที่ถูกจัดเป็น spike

การสร้างชุดข้อมูลแบบไม่มี spike spike หนึ่งวันกระทบแถวรอบข้างด้วย เพราะฟีเจอร์ย้อนหลัง 20 วันและ target ล่วงหน้า 5 วันของแถวใกล้เคียงใช้ผลตอบแทนของวันนั้น เราจึงตัดทั้งหน้าต่าง ตั้งแต่ 5 วันก่อนถึง 19 วันหลังวัน spike คือ 25 แถวต่อ spike หนึ่งวัน หน้าต่างที่ซ้อนกันนับแต่ละแถวครั้งเดียว รวม 213 แถว ชุด `non_spike` จึงมีข้อมูลเทรน 1,520 แถว

รูปที่ 3.3 แสดงตัวอย่างจริงรอบวันที่ 26 ธันวาคม 2018 ซึ่งราคาขึ้น 6.24% target ของแถวที่อยู่ก่อน spike 6 วันยังเป็น 0.24 แต่แถวที่อยู่ก่อน 5 วันกระโดดเป็น 0.62 เพราะ 5 วันข้างหน้าของแถวนั้นเริ่มรวมวัน spike ส่วนความผันผวนย้อนหลัง 20 วันค้างสูงจนถึงวันที่ 19 หลัง spike แล้วลดจาก 0.31 เหลือ 0.24 ในวันถัดไป ขอบของหน้าต่างจึงตรงกับจุดที่ข้อมูล

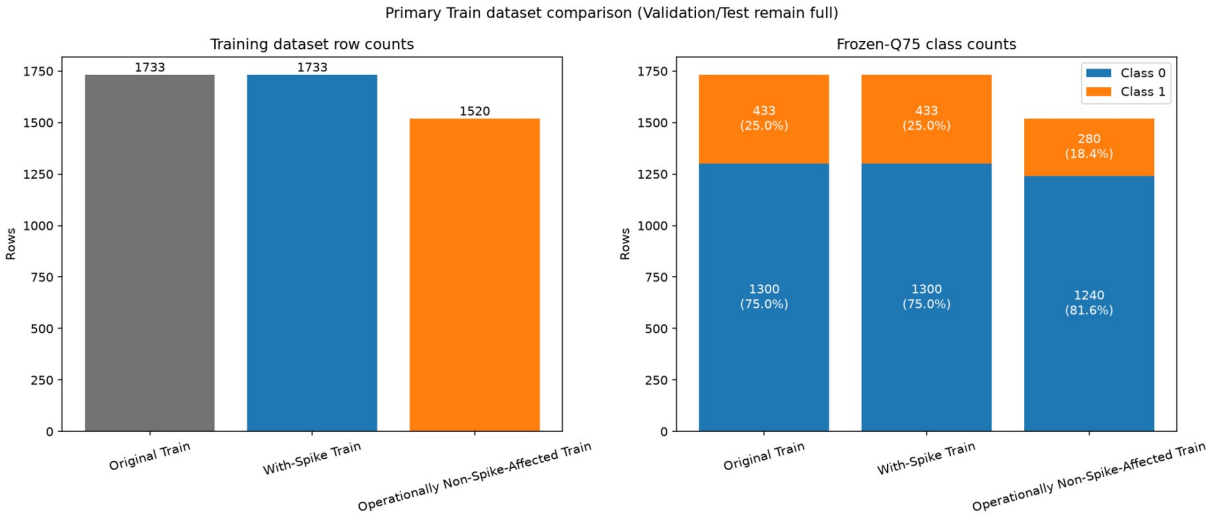
ของวัน spike เข้าและออกจากการคำนวณ ข้อยกเว้นคือ `rsi_14` ซึ่งคำนวณแบบเฉลี่ยสะสม อิทธิพลของวัน spike จึงค่อย ๆ จางลง และอาจเหลืออยู่บ้างหลังหน้าต่าง



รูปที่ 3.3 ตัวอย่างหน้าต่างที่ถูกตัดรอบ spike วันที่ 26 ธันวาคม 2018 พื้นที่แรเงาคือ 25 แถวที่ถูกตัด

สิ่งสำคัญสองข้อของการออกแบบ

- ตัดเฉพาะข้อมูล **เทรน** ส่วน Validation และ Test เหมือนกันทั้งสองแบบ จึงเทียบกันได้ตรง ๆ
- แถวที่ถูกตัด 213 แถว เป็นวันผันผวนสูงถึง 153 แถว (71.8%) การตัดจึงเปลี่ยนสามอย่างพร้อมกัน: จำนวนแถว (1,733 เป็น 1,520), สัดส่วนวันผันผวนสูง (25.0% เป็น 18.4%) และช่วงตลาดที่โมเดลได้เห็น ผลต่างระหว่างสองแบบจึงเป็นผลของ **นโยบายตัดแถวทั้งชุด** เราแยกไม่ได้ว่ามาจากตัว spike เอง หรือจากสองปัจจัยที่เหลือ



รูปที่ 3.4 เปรียบเทียบข้อมูลเทรนสองแบบ

3.3.5 การตรวจสอบความถูกต้องของข้อมูล

ก่อนสรุปผล เราตรวจสอบสายการเตรียมข้อมูลทั้งหมด (`docs/audit/DATA_PIPELINE_AUDIT.md`) ข้อสรุปคือข้อมูลใช้เทรนได้อย่างปลอดภัย ไม่มีการรั่วของข้อมูลอนาคต การตรวจที่สำคัญถูกเขียนเป็น test อัตโนมัติใน `tests/test_audit_guards.py` เช่น

- ตัดข้อมูลอนาคตออกแล้วคำนวณฟีเจอร์ใหม่ ค่าของวันในอดีตต้องไม่เปลี่ยน
- เส้นแบ่ง Q75 และเส้นแบ่ง spike ต้องคำนวณจาก Train เท่านั้น แม้จะแก้ค่าใน Validation หรือ Test
- ไม่มีโค้ดส่วนใดสุ่มสลับลำดับข้อมูล และมีเพียง 3 ไฟล์ที่อ้างถึง Test ได้

3.4 การวิเคราะห์ข้อมูลและสถิติที่ใช้

3.4.1 โมเดลที่ใช้ในการศึกษา

ตารางที่ 3.5 โมเดลทั้ง 19 ตัว

งาน	โมเดล	จำนวน
Regression	Simple Linear, Multiple Linear, Polynomial, **Elastic Net ★**	4
Classification	Logistic Regression, Gaussian Naive Bayes, k-Nearest Neighbors, Perceptron, Single-Layer Perceptron, Multi-Layer Perceptron, Decision Tree, Random Forest, Gradient Boosting, XGBoost, **AdaBoost ★**, Stacking, Support Vector Machine	13
Clustering	k-Means, Agglomerative	2

★ คือโมเดลนอกเนื้อหาที่เรียน ซึ่งอธิบายกลไกอย่างละเอียดในหัวข้อ 2.1.3 และ 2.1.5 การตั้งค่าที่ถูกเลือกของทุกโมเดลอยู่ในภาคผนวก ก

3.4.2 ขั้นตอนการทดลอง

1. **เทรนบน Train** ของแต่ละแบบ (`with_spike` หรือ `non_spike`) การปรับสเกลข้อมูล (standardize) และ PCA คำนวณจาก Train เท่านั้น
2. **เลือกการตั้งค่าบน Validation** ลองทุกค่าใน grid แล้วเลือกชุดที่ได้คะแนนดีที่สุด: regression ใช้ RMSE, classification ใช้ average precision (AP)
3. **ไม่ปรับ threshold** classifier ตัดสินที่ความน่าจะเป็น 0.5 คงที่ เพื่อไม่เพิ่มการเลือกบน Validation อีกชั้น
4. **ล็อกก่อนเปิด Test** บันทึก hash ของไฟล์โมเดลทั้ง 38 ชุดและชื่อ "โมเดลตัวแทน" (headline) ของแต่ละงานลง `outputs/modeling/selection_lock.json` แล้ว commit
5. **เปิด Test ครั้งเดียว** ไม่เทรนใหม่บน Train+Validation และไม่เปลี่ยนอะไรหลังเห็นผล โปรแกรมบันทึกใบรับรอง `outputs/modeling/finalize_receipt.json` และปฏิเสธการรันซ้ำ

3.4.3 ตัวชี้วัด

ตัวชี้วัดทั้งหมดในตารางที่ 2.1 ถูกคำนวณและรายงานครบ โดยมีตัวชี้วัดหลักที่ใช้เลือกการตั้งค่าและจัดอันดับสองตัว

- **RMSE** (regression): ขนาดความผิดพลาดเฉลี่ย ยิ่งต่ำยิ่งดี
- **Average precision หรือ AP** (classification): คุณภาพของการจัดอันดับวันที่น่าจะผันผวนสูง ยิ่งสูงยิ่งดี ค่าของการเดาสุ่มเท่ากับสัดส่วนวันผันผวนสูงของชุดนั้น เราใช้ AP แทน accuracy เพราะคลาสไม่สมดุล (หัวข้อ 4.2.2)

3.4.4 การวัดความไม่แน่นอน

target ของวันติดกันใช้ผลตอบแทนช่วงเดียวกัน 4 ใน 5 วัน ค่าของวันติดกันจึงคล้ายกันมาก (autocorrelation ที่ lag 1 เท่ากับ 0.92) ข้อมูล 371 แถวจึงมีข้อมูลจริงเทียบเท่าตัวอย่างอิสระเพียงราว 50 ถึง 200 ตัว

เราจึงคำนวณช่วงความเชื่อมั่น 95% ด้วย **moving-block bootstrap**: สุ่มข้อมูลซ้ำเป็นก้อน 20 วันติดกัน 2,000 รอบ แทนการสุ่มทีละวันซึ่งจะให้ช่วงแคบเกินจริง

การเปรียบเทียบสองโมเดลใช้แบบ **จับคู่ (paired)**: คำนวณผลต่างบนแถวที่สุ่มชุดเดียวกันทุกรอบ ถ้าช่วง 95% ของผลต่าง **คร่อมศูนย์** ถือว่ายังบอกไม่ได้ว่าโมเดลใดดีกว่า กฎข้อนี้ใช้ตลอดทั้งรายงาน

3.4.5 เส้นฐานเปรียบเทียบ

ตัวเลขคะแนนเดี่ยว ๆ บอกไม่ได้ว่าดีหรือแย่ เราจึงเทียบกับกฎที่ไม่ต้องเทรน

ตารางที่ 3.6 เส้นฐานเปรียบเทียบที่ไม่ต้องเทรน

ชื่อ	งาน	กฎ
`baseline_train_mean`	regression	ทายค่าเฉลี่ยของ target ใน Train ทุกวัน
`baseline_persistence`	regression	ทายว่า 5 วันข้างหน้าจะผันผวนเท่ากับ 5 วันที่ผ่านมา
`baseline_majority`	classification	ทายว่า "ไม่ผันผวนสูง" ทุกวัน
`baseline_persistence`	classification	ใช้ความผันผวน 5 วันที่ผ่านมาเป็นคะแนนโดยตรง

3.4.6 การยืนยันผลเทียบกับ library

ทุกโมเดลมีเมธอด `reference()` ที่สร้างโมเดลของ scikit-learn หรือ XGBoost ด้วยการตั้งค่าเดียวกัน test ของแต่ละโมเดลเทรนทั้งสองฝั่งบนข้อมูลเดียวกันแล้วเทียบคำทำนายทีละแถว

ตารางที่ 3.7 ผลต่างระหว่างโมเดลที่เขียนเองกับ library บน Validation

กลุ่มโมเดล	ผลต่างจาก library บน Validation
`simple_linear`, `multiple_linear`, `polynomial`, `gaussian_nb`, `knn`, `adaboost`, `mlp`	ไม่เกิน 2e-15 (ตรงกันถึงทศนิยมสุดท้ายของ float64)
`perceptron`, `decision_tree`, `random_forest`, `gradient_boosting`, `xgboost`	0 (ตรงกันทุกแถว)
`kmeans`, `agglomerative`	แบ่งกลุ่มตรงกัน 100%
`elastic_net`	ไม่เกิน 3e-06 (ใช้กฎหยุดวนรอบต่างจาก scikit-learn)
`svm`	ค่า objective ต่างไม่เกิน 3e-06
`logistic`	ไม่เกิน 1e-03 (หยุดที่ 5,000 รอบ ก่อนลู่เข้าสมบูรณ์)
`slp`	0.07 ถึง 0.29 (หยุดที่โควตา 1,000 รอบ ขณะที่โมเดลอ้างอิงลู่เข้าแล้ว)
`stacking`	ไม่มี library ที่ทำแบบเดียวกัน ตรวจด้วยการสร้าง fold ซ้ำทีละ fold และ test กันข้อมูลรั่ว

ที่มา: `docs/models/PROGRESS_INDEX.md` และ test ใต้ `tests/ml/`

รายละเอียดที่ทำให้ผลตรงกันได้คือ โมเดลที่มีการสุ่มต้องใช้ตัวสุ่มชนิดเดียวกับ scikit-learn (`numpy.random.RandomState`) และเรียกใช้ตามลำดับเดียวกัน

สามโมเดลที่ผลขึ้นกับโควตาการเทรน `slp`, `perceptron` และ `logistic` หยุดเพราะครบจำนวนรอบที่กำหนด ไม่ใช่เพราะลู่เข้า โดยเฉพาะ `perceptron` ซึ่งไม่มีวันลู่เข้าเมื่อข้อมูลแยกด้วยเส้นตรงไม่ได้ คะแนนของสามตัวนี้จึงเป็นคะแนนของ "อัลกอริทึมภายใต้โควตาที่กำหนด"

3.4.7 จำนวนรอบการเทรน และการบันทึก โหลด ทดสอบซ้ำ

แต่ละโมเดลถูกลองหลายการตั้งค่า (grid search) รวม 140 การตั้งค่าต่อแบบข้อมูล หรือ 280 ครั้งของการเทรน สำหรับทั้งสองแบบ เหลือผู้ชนะ 38 ชุด (19 โมเดล × 2 แบบ) ทั้งหมดสั่งรันได้ด้วยคำสั่งเดียว `python -m src.ml.run train --all --variant <variant>` รายการค่าที่ลองอยู่ใน `configs/modeling.json`

โจทย์กำหนดให้บันทึกโมเดล โหลดกลับ แล้วทดสอบซ้ำ เราพิสูจน์สามชั้น

1. ตอนเทรน โปรแกรมบันทึกโมเดลเป็น `model.npz` โหลดกลับทันที แล้วเทียบคำทำนายกับก่อนบันทึก ผลอยู่ใน `load_verification.json` ซึ่งผ่านครบ 38 ชุด
2. test `tests/ml/core/test_artifacts.py` โหลดโมเดลทั้ง 38 ชุดจากดิสก์แล้วทำนาย Validation ใหม่ ต้องได้ค่าเดียวกับที่บันทึกไว้
3. notebook 03 และ 04 ทำซ้ำขั้นตอนเดียวกันให้เห็นเป็นตาราง

ผลบน Test ทั้งหมดในรายงานนี้มาจากโมเดลที่ **โหลดจากไฟล์** ไม่ใช่โมเดลที่ค้างอยู่ในหน่วยความจำ

3.4.8 การวิเคราะห์ความสำคัญของฟีเจอร์และความเสถียรของอันดับ

Permutation importance สลับลำดับค่าของฟีเจอร์หนึ่งตัวบน Validation เพื่อทำลายข้อมูลในฟีเจอร์นั้น แล้วดูว่าคะแนนของโมเดลแย่ลงเท่าไร ยิ่งแย่ลงมากฟีเจอร์นั้นยิ่งสำคัญ เราสลับเป็นก้อน 20 วันติดกันเพื่อรักษารูปแบบตามเวลา และทำซ้ำ 30 รอบ

Walk-forward เพื่อดูว่าอันดับของโมเดลขึ้นกับช่วงเวลาที่วัดมากแค่ไหน เราเทรนด้วยข้อมูลช่วงต้นของ Train ทดสอบกับช่วงถัดไป แล้วขยายหน้าต่างไปเรื่อย ๆ 4 รอบ ครอบคลุมปี 2019 ถึง 2023 ใช้การตั้งค่าเดิมของแต่ละโมเดล และไม่มีการเลือกโมเดลใหม่จากผลนี้

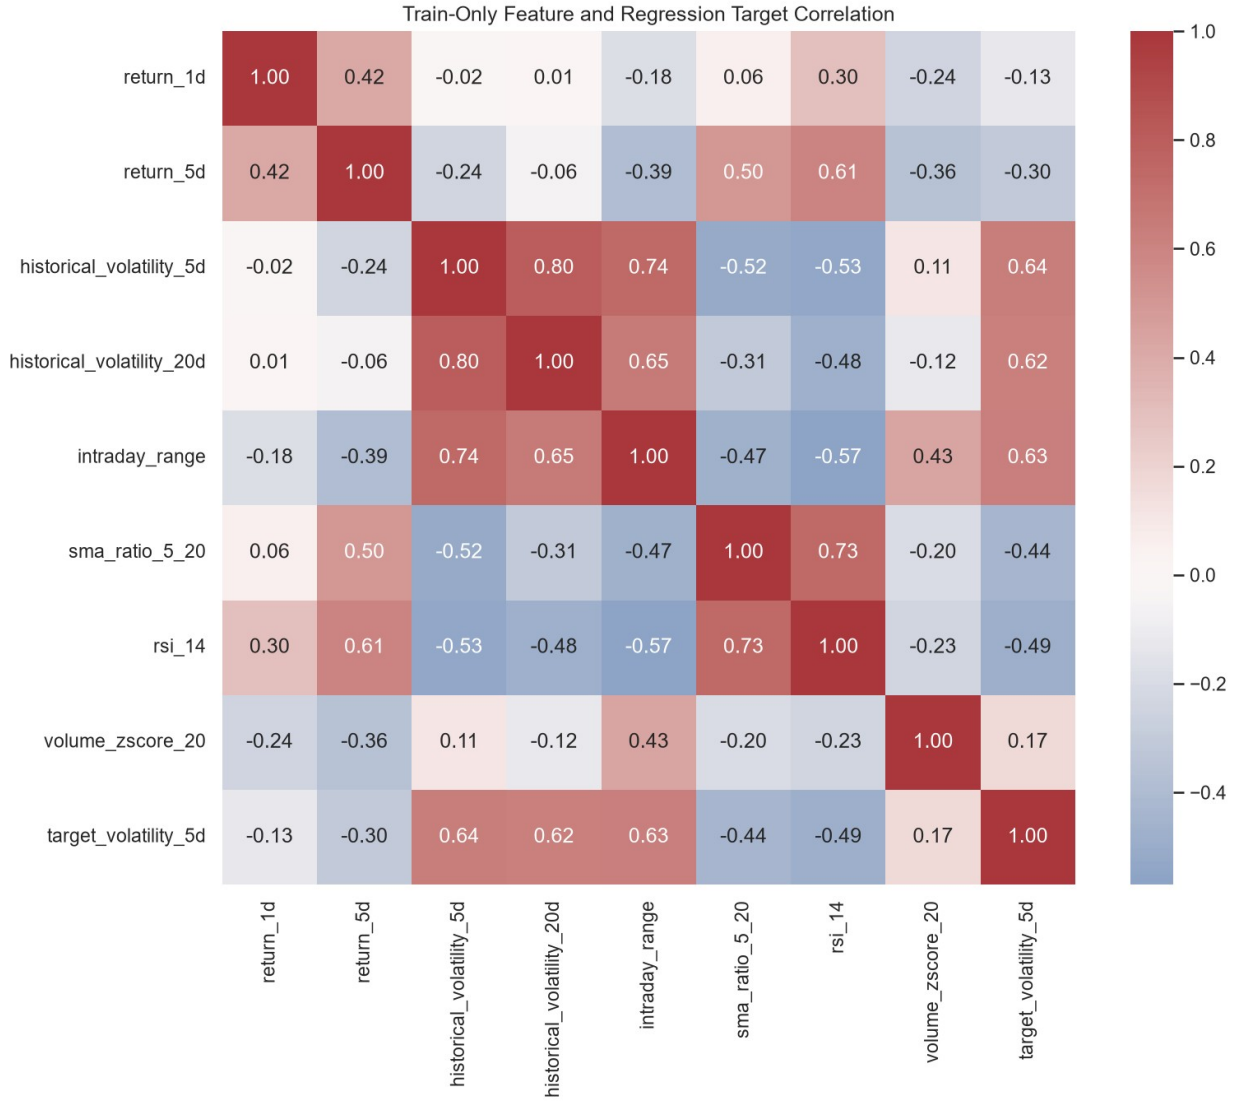
บทที่ 4

ผลการวิเคราะห์ข้อมูล

4.1 ผลการวิเคราะห์ฟีเจอร์

ความสัมพันธ์กับ target บนข้อมูลเทรน ฟีเจอร์กลุ่มความผันผวนย้อนหลังสัมพันธ์กับ target มากที่สุด: `historical_volatility_5d` (r = 0.64), `intraday_range` (0.63), `historical_volatility_20d` (0.62) รองลงมาคือ `rsi_14` (−0.49) และ `sma_ratio_5_20` (−0.44) ส่วน `return_1d` (−0.13) และ `volume_zscore_20` (0.17) สัมพันธ์น้อย เครื่องหมายลบของ `rsi_14` และ `sma_ratio_5_20` สอดคล้องกับข้อเท็จจริงที่ว่าตลาดขาลงผันผวนกว่าขาขึ้น

ฟีเจอร์ซ้ำซ้อนกัน `historical_volatility_5d` กับ `historical_volatility_20d` มีสหสัมพันธ์กัน 0.80 เพราะวัดสิ่งเดียวกันคนละช่วงเวลา ข้อนี้เป็นเหตุผลที่เลือก Elastic Net เป็นโมเดลนอกห้องเรียนฝั่ง regression (หัวข้อ 2.1.3)



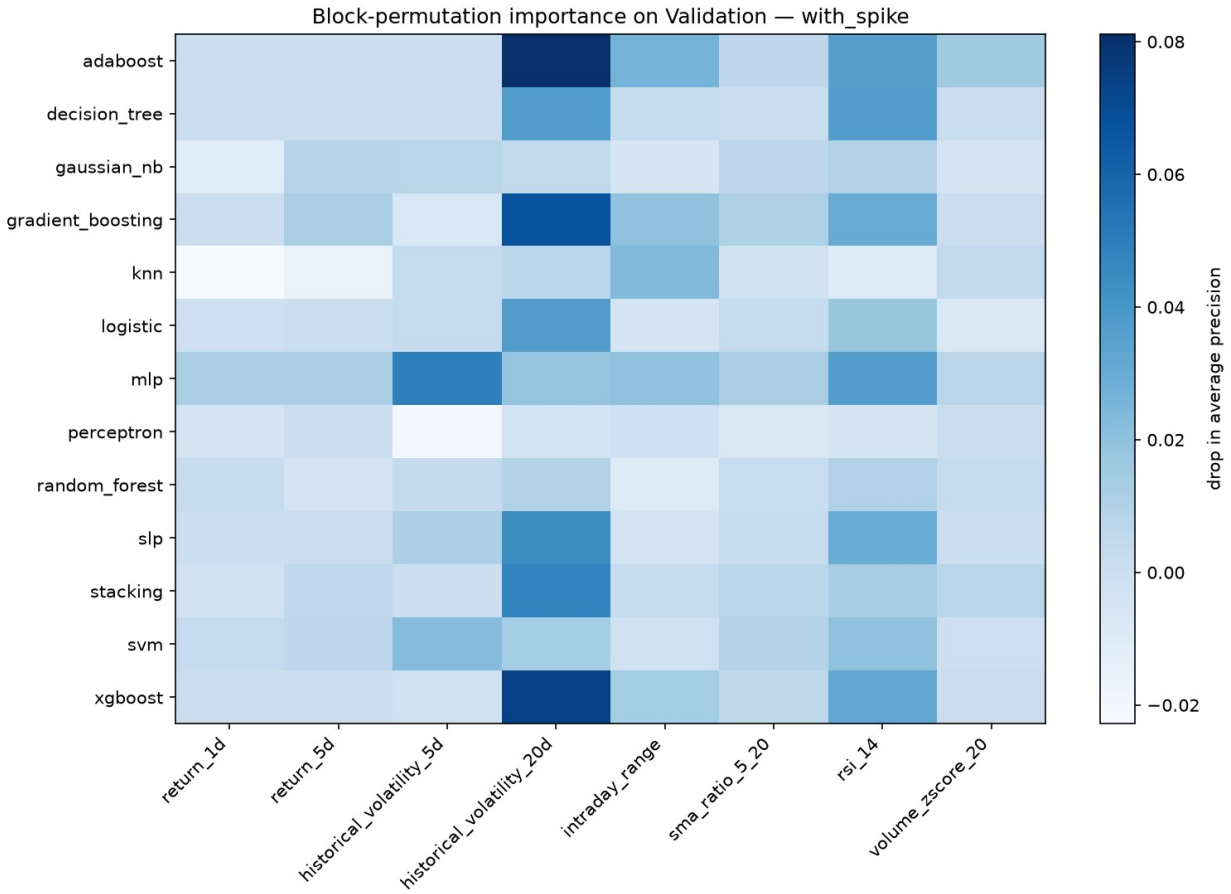
รูปที่ 4.1 สหสัมพันธ์ระหว่างฟีเจอร์บนข้อมูลเทรน

ฟีเจอร์ที่โมเดลใช้จริง ตารางที่ 4.1 แสดง permutation importance เฉลี่ยข้ามโมเดล (วิธีคำนวณอยู่ในหัวข้อ 3.4.8)

ตารางที่ 4.1 Permutation importance เฉลี่ยข้ามโมเดล แบบ with_spike

feature	drop_in_ap_mean	drop_in_ap_std_across_models	rise_in_rmse_mean	rise_in_rmse_std_across_models
return_1d	-0.0019	0.0081	0.0001	0.0001
return_5d	0.0017	0.0074	-0.0001	0.0003
historical_volatility_5d	0.0053	0.0165	-0.0004	0.0007
historical_volatility_20d	0.0336	0.0282	0.0038	0.0034
intraday_range	0.0060	0.0127	-0.0005	0.0015
sma_ratio_5_20	0.0040	0.0054	0.0002	0.0003
rsi_14	0.0197	0.0155	0.0010	0.0019
volume_zscore_20	0.0017	0.0057	-0.0003	0.0007

`historical_volatility_20d` สำคัญที่สุด ตามด้วย `rsi_14` ส่วน `return_1d` และ `volume_zscore_20` แทบไม่มีผล ค่าในคอลัมน์ `std_across_models` ใหญ่พอ ๆ กับค่าเฉลี่ย แปลว่าโมเดลแต่ละตัวพึ่งฟีเจอร์ต่างกันมาก ข้อจำกัดของวิธีนี้คือ ฟีเจอร์ที่สัมพันธ์กันจะแบ่งความสำคัญกัน เมื่อสลับตัวหนึ่ง อีกตัวยังให้ข้อมูลเดิมได้



รูปที่ 4.2 Permutation importance ของ classifier แต่ละตัว (with_spike)

4.2 ผลบน Validation

หัวข้อนี้เป็นผลบน **Validation** ซึ่งเป็น **selection score** คือการตั้งค่าของทุกโมเดลถูกเลือกบนข้อมูลชุดนี้เอง ตัวเลขจึงดูดีกว่าความเป็นจริงเล็กน้อย ผลที่ไม่ลำเอียงคือผลบน Test ในหัวข้อ 4.4

วิธีอ่านตาราง คอลัมน์ที่ลงท้ายด้วย `_ci` เขียนเป็น `ค่า [ต่ำ, สูง]` คือค่าที่วัดได้และช่วงความเชื่อมั่น 95% · `tied_with_leader = yes` คือแยกจากอันดับหนึ่งไม่ได้ทางสถิติ · `beats_best_baseline` คือคะแนนดีกว่า baseline ตัวที่ดีที่สุดหรือไม่

4.2.1 Regression

ตารางที่ 4.2 ผลของโมเดล regression บน Validation แบบ with_spike

model	kind	rmse_ci	mae	r2_ci	tied_with_leader	beats_best_baseline
elastic_net	model	0.0668 [0.0610, 0.0739]	0.0539	0.0169 [-0.2649, 0.2159]	yes	yes
multiple_linear	model	0.0689 [0.0617, 0.0779]	0.0542	-0.0446 [-0.3994, 0.2085]	yes	yes
simple_linear	model	0.0690 [0.0609, 0.0789]	0.0557	-0.0498 [-0.2829, 0.0997]	yes	yes
polynomial	model	0.0691 [0.0606, 0.0797]	0.0552	-0.0507 [-0.2579, 0.0879]	yes	yes
baseline_train_mean	baseline	0.0751 [0.0673, 0.0837]	0.0623	-0.2430 [-0.6975, -0.0225]	no	n/a
baseline_persistence	baseline	0.0826 [0.0750, 0.0901]	0.0673	-0.5032 [-1.0576, -0.0677]	no	n/a

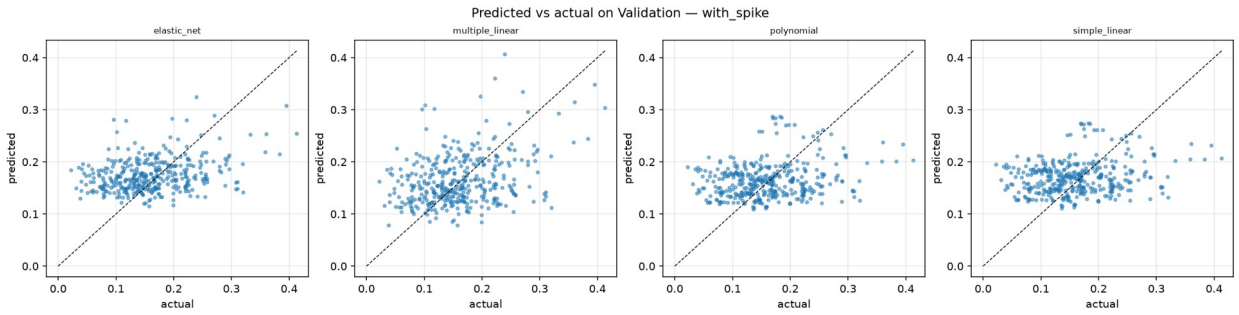
ตัวเลขบน Validation เป็น selection score: hyperparameter ของทุกโมเดลถูกเลือกบนแถวชุดนี้ จึงมองโลกในแง่ดีเกินจริง และโมเดลที่ `tied_with_leader = yes` แยกจากอันดับ 1 ไม่ได้ที่ระดับ 95% (moving-block bootstrap, block 20 วัน) ห้ามอ้างอันดับภายในกลุ่มนั้น 4 จาก 4 โมเดลอยู่ในกลุ่มที่แยกจากอันดับ 1 ไม่ได้

ตารางที่ 4.3 ผลของโมเดล regression บน Validation แบบ non_spike

model	kind	rmse_ci	mae	r2_ci	tied_with_leader	beats_best_baseline
elastic_net	model	0.0643 [0.0572, 0.0741]	0.0510	0.0906 [-0.0841, 0.2010]	yes	yes
polynomial	model	0.0661 [0.0596, 0.0755]	0.0509	0.0389 [-0.1903, 0.1745]	yes	yes
simple_linear	model	0.0665 [0.0582, 0.0783]	0.0527	0.0265 [-0.1099, 0.0616]	yes	yes
multiple_linear	model	0.0668 [0.0597, 0.0761]	0.0530	0.0165 [-0.2942, 0.2361]	yes	yes
baseline_train_mean	baseline	0.0676 [0.0585, 0.0805]	0.0535	-0.0076 [-0.1436, -0.0000]	yes	n/a
baseline_persistence	baseline	0.0826 [0.0750, 0.0901]	0.0673	-0.5032 [-1.0576, -0.0677]	no	n/a

ตัวเลขบน Validation เป็น selection score: hyperparameter ของทุกโมเดลถูกเลือกบนแถวชุดนี้ จึงมองโลกในแง่ดีเกินจริง และโมเดลที่ `tied_with_leader = yes` แยกจากอันดับ 1 ไม่ได้ที่ระดับ 95% (moving-block bootstrap, block 20 วัน) ห้ามอ้างอันดับภายในกลุ่มนั้น 4 จาก 4 โมเดลอยู่ในกลุ่มที่แยกจากอันดับ 1 ไม่ได้

- โมเดลทั้ง 4 ตัวได้ RMSE ต่ำกว่า baseline ทั้งสองตัว
- ทั้ง 4 ตัวอยู่ในกลุ่มที่แยกจากอันดับหนึ่งไม่ได้ จึงไม่อ้างว่าโมเดลใดดีที่สุด
- **R^2** อยู่ใกล้ศูนย์หรือติดลบ R^2 ติดลบแปลว่าแย่กว่าการทายค่าเฉลี่ยของ Validation เอง สาเหตุคือ Validation สงบกว่า Train มาก (ส่วนเบี่ยงเบนมาตรฐานของ target 0.068 เทียบกับ 0.144) เมื่อค่าจริงแกว่งน้อย การทายค่าเฉลี่ยก็ผิดไม่มาก



รูปที่ 4.3 ค่าทำนายเทียบค่าจริงบน Validation (with_spike)

4.2.2 Classification

ทำไมไม่ใช้ accuracy เป็นหลัก Validation มีวันผันผวนสูงเพียง 34 จาก 371 วัน ถ้าทายว่า "ไม่ผันผวนสูง" ทุกวันจะได้ accuracy 90.8% ทั้งที่จับวันผันผวนสูงไม่ได้เลย (แถว `baseline_majority`) เราจึงรายงาน accuracy คู่กับ AP, ROC-AUC, F1 และ recall เสมอ

ตารางที่ 4.4 ผลของโมเดล classification บน Validation แบบ with_spike

model	kind	average_ precision_ci	roc_auc_ci	f1_ci	recall_ci	precision	specificity	accuracy	loss_name	loss	tied_ with_ leader	beats_best_ baseline
mlp	model	0.2668 [0.0579, 0.4724]	0.6757 [0.3961, 0.8474]	0.3200 [0.0000, 0.5556]	0.2353 [0.0000, 0.4889]	0.5000	0.9763	0.9084	binary_cross_ entropy	0.3359	yes	yes
random_forest	model	0.2548 [0.0603, 0.4586]	0.6862 [0.4634, 0.8323]	0.2917 [0.0000, 0.5051]	0.2059 [0.0000, 0.4255]	0.5000	0.9792	0.9084	log_loss	0.3131	yes	yes
gradient_boosting	model	0.2531 [0.0548, 0.4746]	0.6754 [0.4075, 0.8409]	0.2449 [0.0000, 0.4330]	0.1765 [0.0000, 0.3674]	0.4000	0.9733	0.9003	binary_logistic_loss	0.3075	yes	yes
svm	model	0.2514 [0.0514, 0.4651]	0.6786 [0.4339, 0.8404]	0.2553 [0.0000, 0.4445]	0.1765 [0.0000, 0.3674]	0.4615	0.9792	0.9057	hinge_loss	0.2688	yes	yes
xgboost	model	0.2508 [0.0559, 0.4681]	0.6693 [0.4080, 0.8368]	0.2449 [0.0000, 0.4424]	0.1765 [0.0000, 0.3674]	0.4000	0.9733	0.9003	binary_logistic_loss	0.3263	yes	yes
baseline_ persistence	baseline	0.2474 [0.0545, 0.5002]	0.7214 [0.5384, 0.8407]	0.2899 [0.0000, 0.5589]	0.2941 [0.0000, 0.5601]	0.2857	0.9258	0.8679	n/a	n/a	yes	n/a
slp	model	0.2427 [0.0545, 0.4432]	0.6803 [0.4458, 0.8289]	0.2609 [0.0000, 0.4615]	0.1765 [0.0000, 0.3674]	0.5000	0.9822	0.9084	binary_cross_ entropy	0.3046	yes	no
adaboost	model	0.2363 [0.0626, 0.4381]	0.6768 [0.4602, 0.8196]	0.2222 [0.0000, 0.4226]	0.1765 [0.0000, 0.3674]	0.3000	0.9585	0.8868	exponential_loss	0.5771	yes	no
logistic	model	0.2330 [0.0526, 0.4301]	0.6732 [0.4224, 0.8305]	0.2609 [0.0000, 0.4615]	0.1765 [0.0000, 0.3674]	0.5000	0.9822	0.9084	binary_cross_ entropy	0.3089	yes	no
stacking	model	0.2262 [0.0551, 0.4176]	0.6641 [0.4218, 0.8155]	0.2353 [0.0000, 0.4000]	0.1765 [0.0000, 0.3674]	0.3529	0.9674	0.8949	log_loss	0.3455	yes	no
gaussian_nb	model	0.2218 [0.0464, 0.4333]	0.6665 [0.4217, 0.8214]	0.2812 [0.0000, 0.5001]	0.2647 [0.0000, 0.5228]	0.3000	0.9377	0.8760	log_loss	0.6203	yes	no
knn	model	0.2037 [0.0610, 0.4015]	0.6987 [0.5068, 0.8179]	0.2000 [0.0000, 0.3509]	0.1471 [0.0000, 0.3077]	0.3125	0.9674	0.8922	log_loss	0.6345	yes	no
decision_tree	model	0.1732 [0.0494, 0.3562]	0.6418 [0.4752, 0.7795]	0.3099 [0.0000, 0.5094]	0.3235 [0.0000, 0.5610]	0.2973	0.9228	0.8679	log_loss	0.3350	yes	no
baseline_majority	baseline	0.0916 [0.0350, 0.1779]	0.5000 [0.5000, 0.5000]	0.0000 [0.0000, 0.0000]	0.0000 [0.0000, 0.0000]	n/a	1.0000	0.9084	n/a	n/a	no	n/a
perceptron	model	0.0648 [0.0310, 0.1334]	0.2993 [0.1807, 0.4718]	0.0000 [0.0000, 0.0000]	0.0000 [0.0000, 0.0000]	0.0000	0.9644	0.8760	perceptron_ criterion	0.0008	yes	no

ตัวเลขบน Validation เป็น selection score: hyperparameter ของทุกโมเดลถูกเลือกบนแถวชุดนี้ จึงมองโลกในแง่ดีเกินจริง และโมเดลที่ `tied_with_leader = yes` *แยกจากอันดับ 1 ไม่ได้ที่ระดับ 95% (moving-block bootstrap, block 20 วัน) ห้ามอ้างอันดับภายในกลุ่มนั้น*

13 จาก 13 โมเดลอยู่ในกลุ่มที่แยกจากอันดับ 1 ไม่ได้

ตารางถัดไปแสดง metric ครบทุกตัวที่โจทย์ระบุ โดย `sensitivity` คือค่าเดียวกับ recall และ `specificity` คือค่าเดียวกับ `tnr` (true negative rate) โจทย์ระบุสองชื่อนี้แยกกัน จึงแสดงทั้งสองคอลัมน์ คอลัมน์ `loss` เทียบข้ามโมเดลที่ใช้ loss ต่างชนิดไม่ได้ (ดู `loss_name`) ค่าของ `adaboost` คือ exponential loss ตัวเดียวกับที่โมเดลลดระหว่างเทรน (เส้นในรูปที่ 4.7) วัดบน Validation

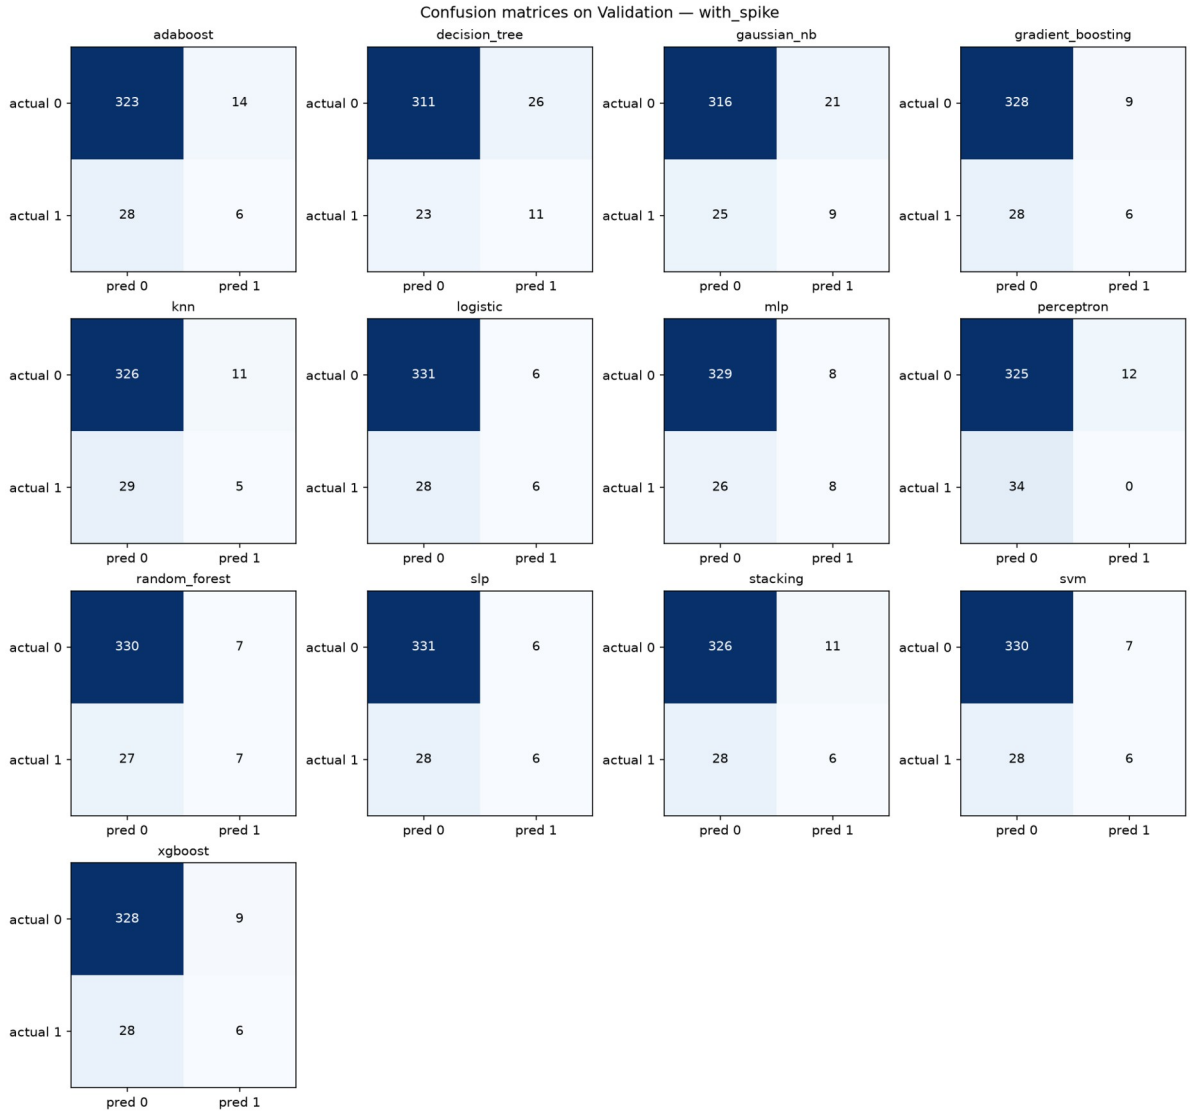
ตารางที่ 4.5 ตัวชี้วัดครบทุกตัวที่โจทย์กำหนด บน Validation แบบ with_spike

model	loss_name	loss	tn	fp	fn	tp	accuracy	precision	sensitivity	specificity	tnr	f1	roc_auc	average_ precision
mlp	binary_cross_entropy	0.3359	329	8	26	8	0.9084	0.5000	0.2353	0.9763	0.9763	0.3200	0.6757	0.2668
random_forest	log_loss	0.3131	330	7	27	7	0.9084	0.5000	0.2059	0.9792	0.9792	0.2917	0.6862	0.2548
gradient_boosting	binary_logistic_loss	0.3075	328	9	28	6	0.9003	0.4000	0.1765	0.9733	0.9733	0.2449	0.6754	0.2531
svm	hinge_loss	0.2688	330	7	28	6	0.9057	0.4615	0.1765	0.9792	0.9792	0.2553	0.6786	0.2514
xgboost	binary_logistic_loss	0.3263	328	9	28	6	0.9003	0.4000	0.1765	0.9733	0.9733	0.2449	0.6693	0.2508
baseline_persistence	n/a	n/a	312	25	24	10	0.8679	0.2857	0.2941	0.9258	0.9258	0.2899	0.7214	0.2474
slp	binary_cross_entropy	0.3046	331	6	28	6	0.9084	0.5000	0.1765	0.9822	0.9822	0.2609	0.6803	0.2427
adaboost	exponential_loss	0.5771	323	14	28	6	0.8868	0.3000	0.1765	0.9585	0.9585	0.2222	0.6768	0.2363
logistic	binary_cross_entropy	0.3089	331	6	28	6	0.9084	0.5000	0.1765	0.9822	0.9822	0.2609	0.6732	0.2330
stacking	log_loss	0.3455	326	11	28	6	0.8949	0.3529	0.1765	0.9674	0.9674	0.2353	0.6641	0.2262
gaussian_nb	log_loss	0.6203	316	21	25	9	0.8760	0.3000	0.2647	0.9377	0.9377	0.2812	0.6665	0.2218
knn	log_loss	0.6345	326	11	29	5	0.8922	0.3125	0.1471	0.9674	0.9674	0.2000	0.6987	0.2037
decision_tree	log_loss	0.3350	311	26	23	11	0.8679	0.2973	0.3235	0.9228	0.9228	0.3099	0.6418	0.1732
baseline_majority	n/a	n/a	337	0	34	0	0.9084	n/a	0.0000	1.0000	1.0000	0.0000	0.5000	0.0916
perceptron	perceptron_criterion	0.0008	325	12	34	0	0.8760	0.0000	0.0000	0.9644	0.9644	0.0000	0.2993	0.0648

สิ่งที่ตารางบอก

- classifier ส่วนใหญ่ได้ AP ราว 0.20 ถึง 0.27 สูงกว่าการเดาสุ่ม (0.092) แต่ช่วงความเชื่อมั่นกว้างมาก (ราว 0.05 ถึง 0.47) เพราะมีวันผันผวนสูงให้วัดเพียง 34 วัน
- **ทั้ง 13 โมเดลแยกจากอันดับหนึ่งไม่ได้** Validation จึงตัดสินผู้ชนะไม่ได้
- `baseline_persistence` ซึ่งไม่ได้เทรนอะไร อยู่กลางตารางด้าน AP และได้ ROC-AUC สูงกว่าทุกโมเดล มีเพียง 5 จาก 13 โมเดลที่ AP สูงกว่า baseline นี้
- โมเดลส่วนใหญ่ทำนายว่าผันผวนสูงน้อยเกินไป (recall 0.15 ถึง 0.32) เพราะเรียนจาก Train ที่ผันผวนกว่า Validation
- `perceptron` ได้ ROC-AUC ต่ำกว่า 0.5 เพราะไม่ลู่เข้า (หัวข้อ 3.4.6)

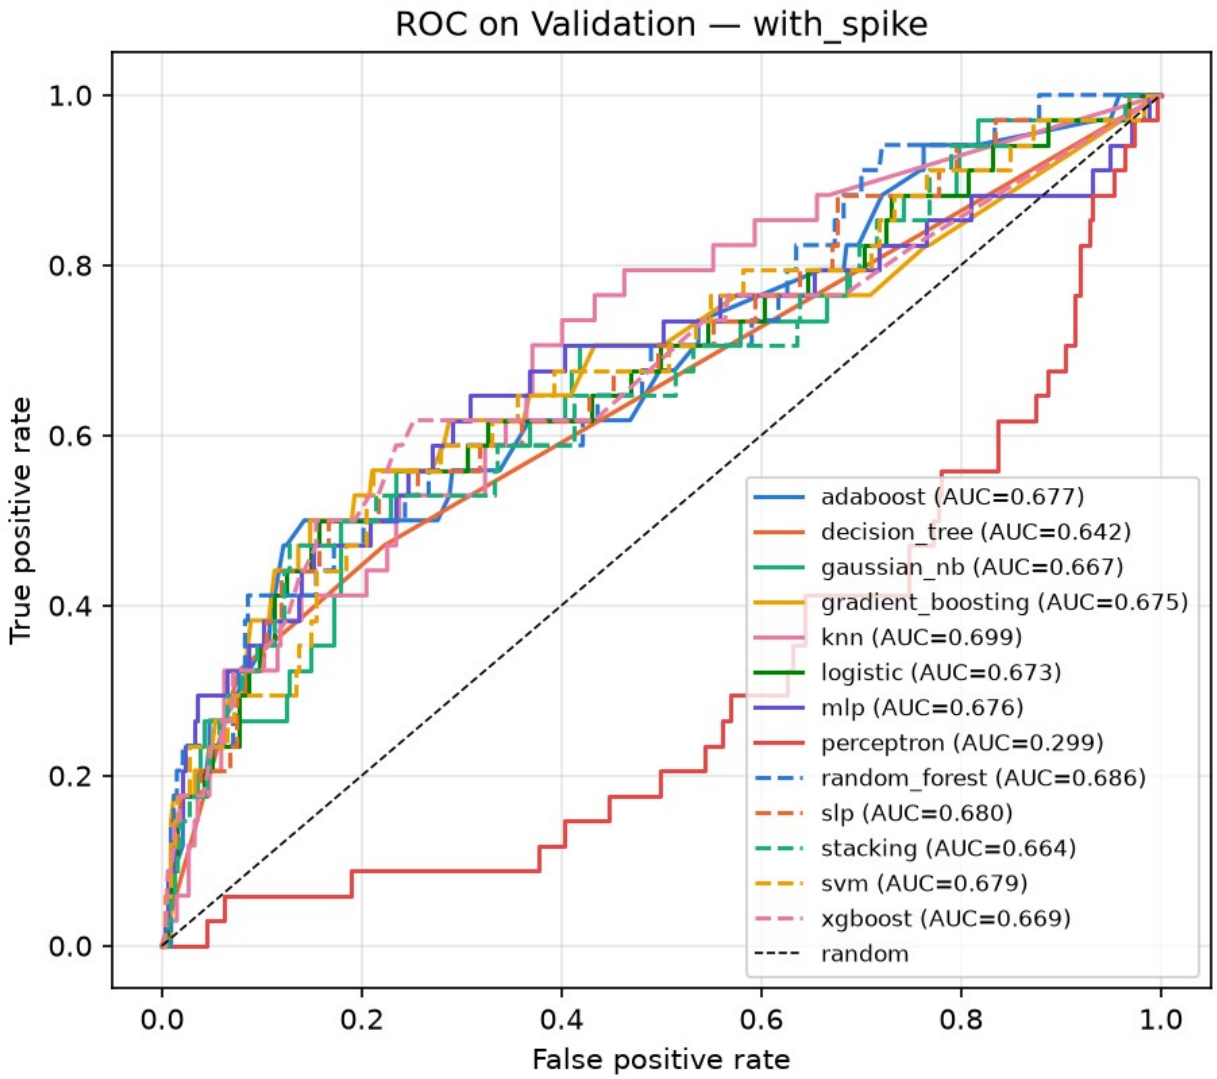
ตารางของแบบ `non_spike` อยู่ในภาคผนวก ข



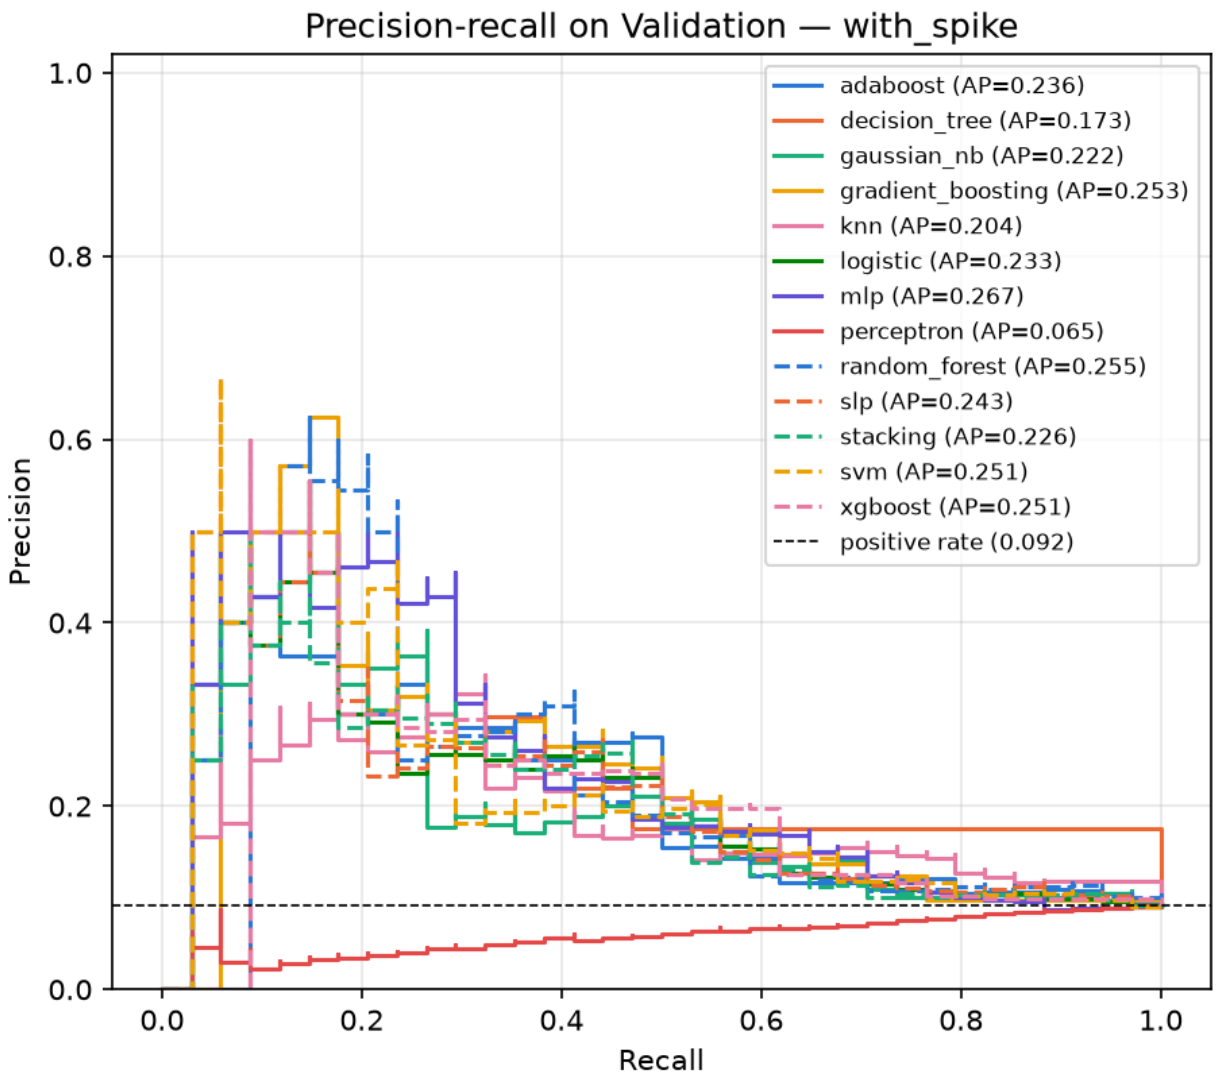
รูปที่ 4.4 Confusion matrix ของ classifier ทั้ง 13 ตัวบน Validation (with_spike)

4.2.3 ROC และ Precision-Recall

ROC curve พล็อตอัตราจับได้เทียบกับอัตราเตือนผิดเมื่อไล่ threshold เส้นทแยงคือการเดาสุ่ม พื้นที่ใต้กราฟคือ ROC-AUC **Precision-recall curve** เหมาะกับข้อมูลที่คลาสไม่สมดุลมากกว่า เพราะการเตือนผิดหลายสิบครั้งดูเล็กใน ROC แต่ทำให้ precision ตกชัดเจน



รูปที่ 4.5 ROC ของ classifier ทั้ง 13 ตัวบน Validation (with_spike)

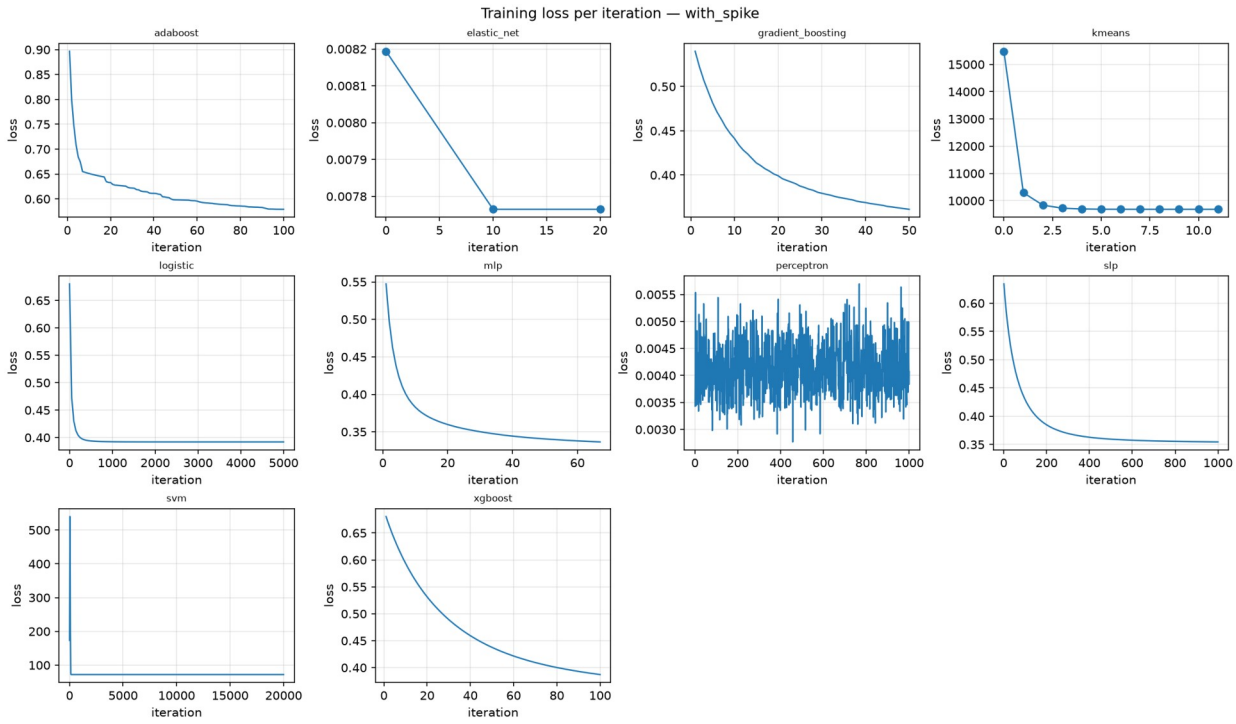


รูปที่ 4.6 Precision-recall ของ classifier ทั้ง 13 ตัวบน Validation (with_spike)

เส้นของโมเดลส่วนใหญ่เกาะกลุ่มกัน สอดคล้องกับตารางที่ว่าแยกอันดับไม่ได้

4.2.4 Performance curve

กราฟ loss ระหว่างเทรนของโมเดลที่เรียนแบบวนรอบ เส้นที่ลดลงแล้วราบแปลว่าลู่เข้าแล้ว ส่วน `perceptron` แกว่งไม่ลู่เข้า โมเดลที่ไม่ได้เทรนด้วยการลด loss ทีละรอบ (knn, `decision_tree`, `gaussian_nb`, `random_forest`, `stacking`) ไม่มีกราฟ



รูปที่ 4.7 Loss ระหว่างเทรน (with_spike)

4.2.5 Clustering

ตารางที่ 4.6 ผลของโมเดล clustering บน Validation แบบ with_spike

model	variant	k	silhouette	inertia	cluster_sizes
agglomerative	with_spike	2	0.3602	1070.4207	{"0": 293, "1": 78}
kmeans	with_spike	2	0.3666	1075.1372	{"0": 73, "1": 298}

silhouette/inertia คำนวณบน Validation ไม่มีช่วงความเชื่อมั่น

ทั้งสองวิธีเลือกจำนวนกลุ่ม k = 2 และได้ silhouette ราว 0.36 (ค่าอยู่ระหว่าง −1 ถึง 1 ยิ่งสูงกลุ่มยิ่งแยกชัด) เมื่อเทียบกลุ่มที่ได้กับ label จริงใน notebook 04 หัวข้อ 10 กลุ่มหนึ่งมีสัดส่วนวันผันผวนสูงราว 20% อีกกลุ่มราว 6% แปลว่าฟีเจอร์เพียงอย่างเดียวแยกสภาพตลาดได้ระดับหนึ่งโดยไม่ต้องมี label ข้อจำกัดคือ Agglomerative ไม่มีขั้นตอนทำนายข้อมูลใหม่โดยธรรมชาติ เราจึงจัดวันใน Validation เข้ากลุ่มที่จุดศูนย์กลางใกล้ที่สุด

4.3 ผลของโมเดลนอกเนื้อหาที่เรียน

4.3.1 Elastic Net

ผลที่ได้ การตั้งค่าที่ถูกเลือกคือ α = 0.1 และ l1_ratio = 0.25 ทั้งสองแบบข้อมูล โมเดลดันน้ำหนักเป็นศูนย์ 3 จาก 8 ฟีเจอร์ (`with_spike`) และ 4 จาก 8 (`non_spike`) ที่มา: `outputs/modeling/report/with_spike/linear_coefficients.csv` และ notebook 03 หัวข้อ 5 เมื่อเทียบกับ `ElasticNet` ของ scikit-learn คำทำนายต่างกันไม่เกิน 9e-07 (`with_spike`) และ 3e-06 (`non_spike`)

ตารางที่ 4.7 ผลของ Elastic Net บน Validation และ Test

variant	split	params	rmse	mae	r2
with_spike	validation (selection score)	{"alpha": 0.1, "l1_ratio": 0.25, "max_iter": 5000, "tol": 1e-06}	0.0668	0.0539	0.0169
with_spike	test (one-shot)	{"alpha": 0.1, "l1_ratio": 0.25, "max_iter": 5000, "tol": 1e-06}	0.1174	0.0731	0.2758
non_spike	validation (selection score)	{"alpha": 0.1, "l1_ratio": 0.25, "max_iter": 5000, "tol": 1e-06}	0.0643	0.0510	0.0906
non_spike	test (one-shot)	{"alpha": 0.1, "l1_ratio": 0.25, "max_iter": 5000, "tol": 1e-06}	0.1230	0.0736	0.2059

4.3.2 AdaBoost

ผลที่ได้ การตั้งค่าที่ถูกเลือกคือ stump 100 ตัว และ learning_rate 0.5 stump ตัวแรกมีความผิดพลาด 0.25 (`with_spike`) ส่วนตัวท้าย ๆ มีความผิดพลาดใกล้ 0.5 และมีสิทธิ์ออกเสียงเล็กมาก เพราะตัวอย่างที่เหลือให้แก้คือตัวอย่างที่ยากจริง ๆ (กราฟอยู่ใน notebook 04 หัวข้อ 8) คำทำนายตรงกับ `AdaBoostClassifier` ของ scikit-learn ทุกแถว

ตารางที่ 4.8 ผลของ AdaBoost บน Validation และ Test

variant	split	params	average_precision	roc_auc	f1	recall	precision	specificity	accuracy
with_spike	validation (selection score)	{"learning_rate": 0.5, "n_estimators": 100, "random_state": 42}	0.2363	0.6768	0.2222	0.1765	0.3000	0.9585	0.8868
with_spike	test (one-shot)	{"learning_rate": 0.5, "n_estimators": 100, "random_state": 42}	0.4858	0.7614	0.4853	0.4521	0.5238	0.9000	0.8123
non_spike	validation (selection score)	{"learning_rate": 0.5, "n_estimators": 100, "random_state": 42}	0.2407	0.6409	0.2353	0.1765	0.3529	0.9674	0.8949
non_spike	test (one-shot)	{"learning_rate": 0.5, "n_estimators": 100, "random_state": 42}	0.5443	0.7735	0.5000	0.4110	0.6383	0.9433	0.8391

4.4 ผลบน Test

Test ถูกเปิด **ครั้งเดียว** เมื่อ 11 ตุลาคม 2026 หลัง commit ไฟล์ล็อกแล้ว โมเดลทั้งหมดเทรนจาก Train และเลือกบน Validation ไม่มีการเทรนใหม่ ใบรับรองอยู่ในภาคผนวก ค

โมเดลตัวแทนที่ล็อกไว้ คือผู้ที่ได้คะแนนสูงสุดบน Validation ของแต่ละงาน (ตารางที่ 4.9) การล็อกชื่อไว้ก่อนมีไว้เพื่อไม่ให้เลือกโมเดลย้อนหลังจากผล Test ได้

ตารางที่ 4.9 โมเดลตัวแทนที่ล็อกไว้: คะแนนบน Validation คะแนนบน Test และเส้นฐานที่ดีที่สุด

task	variant	headline	metric	validation	test	test_low	test_high	rank_on_test	best_baseline	baseline_test	beats_baseline
classification	with_spike	mlp	average_precision	0.2668	0.5991	0.2605	0.7603	1 of 13	baseline_persistence	0.5365	yes
classification	non_spike	random_forest	average_precision	0.3010	0.5240	0.2161	0.6796	10 of 13	baseline_persistence	0.5365	no
regression	with_spike	elastic_net	rmse	0.0668	0.1174	0.0709	0.1746	2 of 4	baseline_train_mean	0.1380	yes
regression	non_spike	elastic_net	rmse	0.0643	0.1230	0.0688	0.1859	3 of 4	baseline_train_mean	0.1400	yes

ตารางที่ 4.10 ผลของโมเดล classification บน Test แบบ with_spike

model	kind	headline	validation_ average_ precision	average_ precision_ci	roc_auc_ci	f1_ci	recall_ci	tied_ with_ leader	beats_ best_ baseline
mlp	model	yes	0.2668	0.5991 [0.2605, 0.7603]	0.7930 [0.6103, 0.9031]	0.5714 [0.2104, 0.6929]	0.4932 [0.1429, 0.6505]	yes	yes
random_forest	model	no	0.2548	0.5775 [0.2366, 0.7393]	0.7866 [0.5922, 0.8920]	0.5000 [0.1764, 0.6047]	0.4247 [0.1333, 0.5424]	yes	yes
svm	model	no	0.2514	0.5716 [0.2402, 0.7438]	0.7835 [0.5935, 0.8955]	0.4874 [0.1176, 0.6102]	0.3973 [0.0789, 0.5536]	yes	yes
gaussian_nb	model	no	0.2218	0.5538 [0.2390, 0.7289]	0.7703 [0.5749, 0.8838]	0.5806 [0.3055, 0.6892]	0.6164 [0.3158, 0.7444]	yes	yes
slp	model	no	0.2427	0.5536 [0.2473, 0.7470]	0.7798 [0.5865, 0.8954]	0.5041 [0.1665, 0.6480]	0.4247 [0.1052, 0.6186]	yes	yes
logistic	model	no	0.2330	0.5518 [0.2482, 0.7452]	0.7822 [0.5936, 0.8978]	0.5203 [0.2083, 0.6564]	0.4384 [0.1351, 0.6211]	yes	yes
knn	model	no	0.2037	0.5472 [0.2187, 0.7309]	0.7847 [0.6241, 0.8634]	0.5512 [0.1886, 0.6804]	0.4795 [0.1350, 0.6579]	yes	yes
baseline_ persistence	baseline	no	n/a	0.5365 [0.1589, 0.7246]	0.7255 [0.5280, 0.8308]	0.4933 [0.1599, 0.6335]	0.5068 [0.1633, 0.6552]	yes	n/a
gradient_ boosting	model	no	0.2531	0.5332 [0.2223, 0.7096]	0.7665 [0.5798, 0.8803]	0.4390 [0.1591, 0.6000]	0.3699 [0.1190, 0.5539]	yes	no
xgboost	model	no	0.2508	0.5305 [0.2021, 0.7067]	0.7716 [0.5844, 0.8839]	0.4553 [0.1795, 0.6078]	0.3836 [0.1333, 0.5582]	yes	no
stacking	model	no	0.2262	0.5131 [0.2395, 0.7154]	0.7902 [0.6082, 0.8877]	0.5714 [0.2898, 0.6842]	0.5753 [0.2439, 0.7385]	yes	no
adaboost	model	no	0.2363	0.4858 [0.2145, 0.6807]	0.7614 [0.5710, 0.8785]	0.4853 [0.2268, 0.6555]	0.4521 [0.1852, 0.6775]	no	no
decision_tree	model	no	0.1732	0.3792 [0.1524, 0.5643]	0.7450 [0.6021, 0.8449]	0.4800 [0.2000, 0.6667]	0.4932 [0.1621, 0.7527]	no	no
baseline_ majority	baseline	no	n/a	0.1957 [0.0885, 0.3003]	0.5000 [0.5000, 0.5000]	0.0000 [0.0000, 0.0000]	0.0000 [0.0000, 0.0000]	no	n/a
perceptron	model	no	0.0648	0.1374 [0.0657, 0.2463]	0.2749 [0.1567, 0.4688]	0.0577 [0.0000, 0.1840]	0.0411 [0.0000, 0.1690]	no	no

ประเมินบน Test ครั้งเดียวด้วยโมเดลที่เทรนจาก Train และเลือกบน Validation (ไม่ refit) โมเดลเด่นของแต่ละ task ถูกระบุไว้ใน selection_lock.json ก่อนเปิด Test แถวอื่นในตารางเป็นข้อมูลประกอบ ห้ามเลือกโมเดลจากตารางนี้

ตารางที่ 4.11 ผลของโมเดล classification บน Test แบบ non_spike

model	kind	headline	validation_ average_ precision	average_ precision_ci	roc_auc_ci	f1_ci	recall_ci	tied_ with_ leader	beats_ best_ baseline
gaussian_nb	model	no	0.2292	0.5884 [0.2441, 0.7462]	0.7779 [0.5735, 0.8913]	0.5824 [0.3299, 0.6817]	0.7260 [0.4210, 0.8530]	yes	yes
xgboost	model	no	0.2652	0.5823 [0.2509, 0.7436]	0.7887 [0.6017, 0.8948]	0.5469 [0.2034, 0.7000]	0.4795 [0.1463, 0.6812]	yes	yes
svm	model	no	0.2501	0.5805 [0.2446, 0.7504]	0.7853 [0.5967, 0.8990]	0.4587 [0.0974, 0.5922]	0.3425 [0.0588, 0.5048]	yes	yes
gradient_ boosting	model	no	0.2525	0.5653 [0.2460, 0.7310]	0.7861 [0.6087, 0.8920]	0.3762 [0.1290, 0.5264]	0.2603 [0.0789, 0.4000]	yes	yes
mlp	model	no	0.2808	0.5639 [0.2507, 0.7235]	0.7894 [0.5922, 0.8906]	0.5039 [0.2127, 0.6449]	0.4384 [0.1578, 0.6165]	yes	yes
logistic	model	no	0.2513	0.5510 [0.2472, 0.7391]	0.7782 [0.5841, 0.8940]	0.5041 [0.1785, 0.6269]	0.4247 [0.1111, 0.5943]	yes	yes
stacking	model	no	0.2311	0.5499 [0.2440, 0.7150]	0.7890 [0.6135, 0.8828]	0.4853 [0.2432, 0.6016]	0.4521 [0.2057, 0.5843]	yes	yes

model	kind	headline	validation_ average_ precision	average_ precision_ci	roc_auc_ci	f1_ci	recall_ci	tied_ with_ leader	beats_ best_ baseline
adaboost	model	no	0.2407	0.5443 [0.2261, 0.7297]	0.7735 [0.5788, 0.8899]	0.5000 [0.2051, 0.6348]	0.4110 [0.1470, 0.5758]	yes	yes
knn	model	no	0.2082	0.5389 [0.2514, 0.7067]	0.8008 [0.6595, 0.8698]	0.4237 [0.0894, 0.5658]	0.3425 [0.0606, 0.4943]	yes	yes
baseline_ persistence	baseline	no	n/a	0.5365 [0.1589, 0.7246]	0.7255 [0.5280, 0.8308]	0.4933 [0.1599, 0.6335]	0.5068 [0.1633, 0.6552]	yes	n/a
random_forest	model	yes	0.3010	0.5240 [0.2161, 0.6796]	0.7814 [0.5879, 0.8807]	0.4715 [0.1667, 0.5556]	0.3973 [0.1249, 0.4923]	yes	no
slp	model	no	0.2474	0.4963 [0.2080, 0.6769]	0.7420 [0.5497, 0.8583]	0.5000 [0.2564, 0.6053]	0.4795 [0.2143, 0.6164]	no	no
decision_tree	model	no	0.1887	0.3844 [0.1761, 0.5137]	0.6916 [0.5598, 0.7827]	0.4310 [0.2142, 0.5246]	0.3425 [0.1579, 0.4272]	no	no
baseline_ majority	baseline	no	n/a	0.1957 [0.0885, 0.3003]	0.5000 [0.5000, 0.5000]	0.0000 [0.0000, 0.0000]	0.0000 [0.0000, 0.0000]	no	n/a
perceptron	model	no	0.0742	0.1328 [0.0624, 0.2276]	0.2626 [0.1410, 0.4434]	0.0813 [0.0000, 0.2460]	0.0685 [0.0000, 0.2817]	no	no

ประเมินบน Test ครั้งเดียวด้วยโมเดลที่เทรนจาก Train และเลือกบน Validation (ไม่ refit) โมเดลเด่นของแต่ละ task ถูกระบุไว้ใน selection_lock.json ก่อนเปิด Test แถวอื่นในตารางเป็นข้อมูลประกอบ ห้ามเลือกโมเดลจากตารางนี้

ตารางที่ 4.12 ผลของโมเดล regression บน Test แบบ with_spike

model	kind	headline	validation_ rmse	rmse_ci	r2_ci	tied_ with_ leader	beats_ best_ baseline
multiple_linear	model	no	0.0689	0.1158 [0.0711, 0.1680]	0.2959 [-0.1971, 0.3897]	yes	yes
elastic_net	model	yes	0.0668	0.1174 [0.0709, 0.1746]	0.2758 [-0.0402, 0.3258]	yes	yes
simple_linear	model	no	0.0690	0.1356 [0.0754, 0.1985]	0.0347 [-0.7702, 0.2310]	no	yes
baseline_train_ mean	baseline	no	n/a	0.1380 [0.0806, 0.2060]	-0.0006 [-0.2998, -0.0000]	yes	n/a
polynomial	model	no	0.0691	0.1401 [0.0754, 0.2037]	-0.0314 [-1.1539, 0.2401]	no	no
baseline_ persistence	baseline	no	n/a	0.1502 [0.0919, 0.2222]	-0.1855 [-1.2071, 0.1280]	no	n/a

ประเมินบน Test ครั้งเดียวด้วยโมเดลที่เทรนจาก Train และเลือกบน Validation (ไม่ refit) โมเดลเด่นของแต่ละ task ถูกระบุไว้ใน selection_lock.json ก่อนเปิด Test แถวอื่นในตารางเป็นข้อมูลประกอบ ห้ามเลือกโมเดลจากตารางนี้

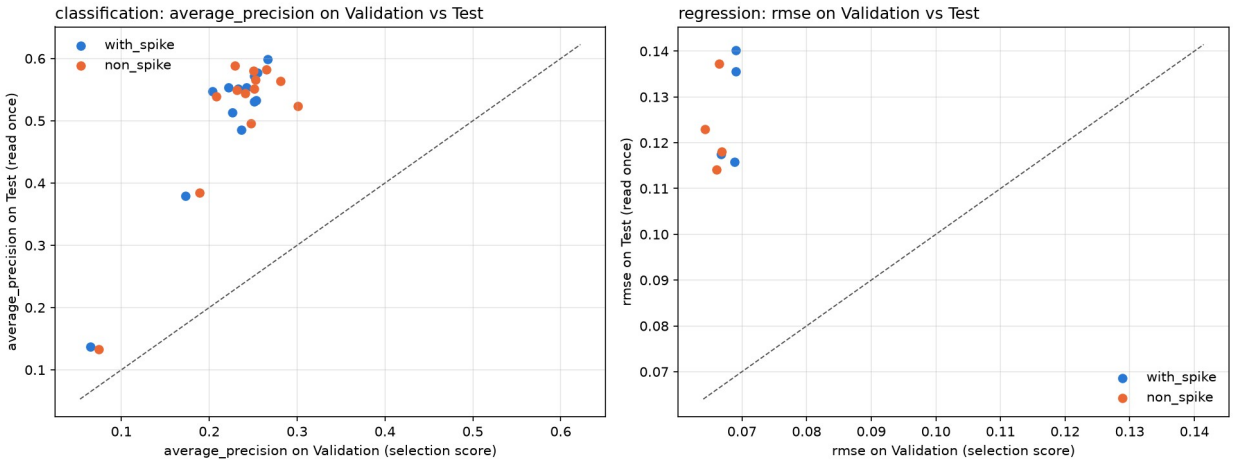
ตารางที่ 4.13 ผลของโมเดล regression บน Test แบบ non_spike

model	kind	headline	validation_rmse	rmse_ci	r2_ci	tied_with_leader	beats_best_baseline
polynomial	model	no	0.0661	0.1142 [0.0720, 0.1641]	0.3155 [-0.0360, 0.4224]	yes	yes
multiple_linear	model	no	0.0668	0.1180 [0.0705, 0.1732]	0.2684 [-0.1829, 0.3623]	yes	yes
elastic_net	model	yes	0.0643	0.1230 [0.0688, 0.1859]	0.2059 [0.0554, 0.2619]	yes	yes
simple_linear	model	no	0.0665	0.1372 [0.0733, 0.2087]	0.0114 [-0.1001, 0.0488]	yes	yes
baseline_train_mean	baseline	no	n/a	0.1400 [0.0745, 0.2132]	-0.0298 [-0.1430, -0.0001]	yes	n/a
baseline_persistence	baseline	no	n/a	0.1502 [0.0919, 0.2222]	-0.1855 [-1.2071, 0.1280]	no	n/a

ประเมินบน Test ครั้งเดียวด้วยโมเดลที่เทรนจาก Train และเลือกบน Validation (ไม่ refit) โมเดลเด่นของแต่ละ task ถูกระบุไว้ใน selection_lock.json ก่อนเปิด Test แถวอื่นในตารางเป็นข้อมูลประกอบ ห้ามเลือกโมเดลจากตารางนี้

อ่านผล

1. **Classification** โมเดลตัวแทนของ `with_spike` คือ `mlp` ได้ AP 0.599 และยังเป็นอันดับหนึ่งบน Test เทียบกับการเดาสุ่ม 0.196 และ `baseline_persistence` 0.536 แต่โมเดลตัวแทนของ `non_spike` คือ `random_forest` ได้ AP 0.524 ต่ำกว่า baseline และตกจากอันดับ 1 บน Validation ไปอยู่อันดับ 10 จาก 13 โมเดล นี่คือตัวอย่างของ selection bias: ผู้นำบน Validation ที่มีวันผันผวนสูงเพียง 34 วัน ไม่จำเป็นต้องเป็นผู้นำบนข้อมูลใหม่
2. **Regression** `elastic_net` ได้ RMSE 0.117 และ 0.123 ดีกว่า baseline ที่ทายค่าเฉลี่ย (0.138 และ 0.140) R^2 อยู่ที่ราว 0.2 ถึง 0.3 สูงกว่าบน Validation เพราะ Test มีช่วงผันผวนแรงให้โมเดลอธิบาย
3. **AP บน Test สูงกว่า Validation มาก** (0.6 เทียบกับ 0.27) ข้อนี้ไม่ได้แปลว่าโมเดลเก่งขึ้น AP ขึ้นกับสัดส่วนวันผันผวนสูง ซึ่ง Test มี 19.6% ส่วน Validation มี 9.2% จึงต้องเทียบกับ baseline ของชุดเดียวกันเสมอ



รูปที่ 4.8 คะแนนของโมเดลเดียวกันบน Validation เทียบกับบน Test

แยกผลตามช่วงตลาด Test มี 54 แถวที่อยู่ในหน้าต่างรอบวัน spike (เดือนเมษายน 2025 และมิถุนายน 2026) และ 319 แถวที่เป็นช่วงปกติ

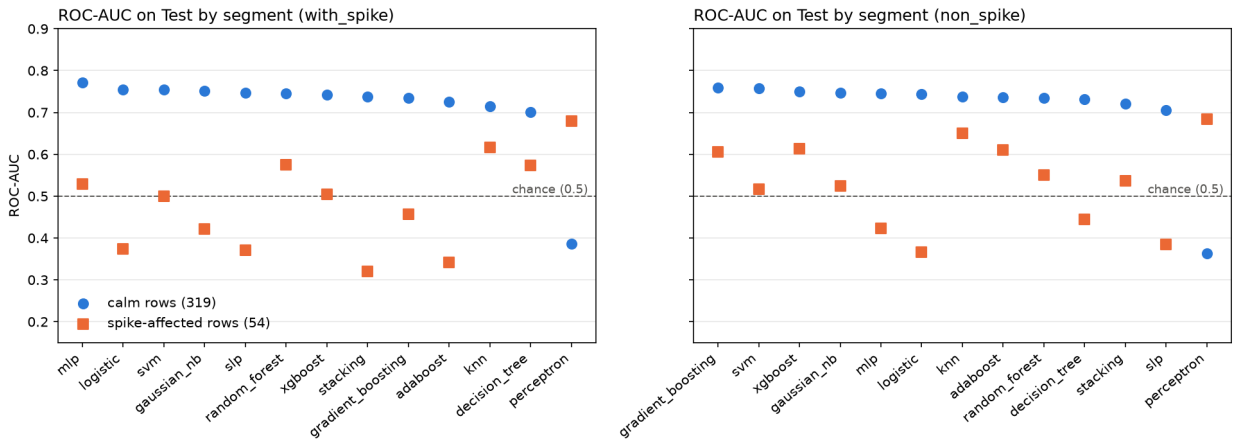
ตารางที่ 4.14 ผลบน Test แยกตามช่วงตลาด งาน classification

model	variant	segment	rows	positives	average_precision	roc_auc	recall	precision	f1
adaboost	non_spike	non_spike	319	35	0.3372	0.7370	0.3714	0.5200	0.4333
adaboost	non_spike	spike_affected	54	38	0.8281	0.6102	0.4474	0.7727	0.5667
adaboost	with_spike	non_spike	319	35	0.3212	0.7251	0.3429	0.4138	0.3750
adaboost	with_spike	spike_affected	54	38	0.6804	0.3413	0.5526	0.6176	0.5833
logistic	non_spike	non_spike	319	35	0.3639	0.7444	0.2000	0.5385	0.2917
logistic	non_spike	spike_affected	54	38	0.7200	0.3668	0.6316	0.6486	0.6400
logistic	with_spike	non_spike	319	35	0.3882	0.7545	0.2286	0.6154	0.3333
logistic	with_spike	spike_affected	54	38	0.7168	0.3734	0.6316	0.6486	0.6400
mlp	non_spike	non_spike	319	35	0.4048	0.7454	0.2857	0.5263	0.3704
mlp	non_spike	spike_affected	54	38	0.7310	0.4227	0.5789	0.6286	0.6027
mlp	with_spike	non_spike	319	35	0.4451	0.7709	0.3429	0.5714	0.4286
mlp	with_spike	spike_affected	54	38	0.7837	0.5296	0.6316	0.7500	0.6857
random_forest	non_spike	non_spike	319	35	0.3898	0.7344	0.3714	0.4815	0.4194
random_forest	non_spike	spike_affected	54	38	0.7664	0.5510	0.4211	0.6957	0.5246
random_forest	with_spike	non_spike	319	35	0.3782	0.7455	0.3429	0.4800	0.4000
random_forest	with_spike	spike_affected	54	38	0.8011	0.5757	0.5000	0.7308	0.5938

ตารางที่ 4.15 ผลบน Test แยกตามช่วงตลาด งาน regression

model	variant	segment	rows	rmse	mae	r2
elastic_net	non_spike	non_spike	319	0.0692	0.0550	0.1752
elastic_net	non_spike	spike_affected	54	0.2759	0.1838	-0.3351
elastic_net	with_spike	non_spike	319	0.0707	0.0564	0.1395
elastic_net	with_spike	spike_affected	54	0.2564	0.1722	-0.1526
multiple_linear	non_spike	non_spike	319	0.0683	0.0525	0.1972
multiple_linear	non_spike	spike_affected	54	0.2620	0.1880	-0.2042
multiple_linear	with_spike	non_spike	319	0.0694	0.0536	0.1714
multiple_linear	with_spike	spike_affected	54	0.2533	0.1819	-0.1253

- **ช่วงปกติ** (วันผันผวนสูง 35 จาก 319 วัน หรือ 11%): classifier ได้ ROC-AUC ราว 0.72 ถึง 0.77 และ AP ราว 0.32 ถึง 0.45 สูงกว่าการเดาสุ่ม (0.11) ชัดเจน regression ได้ RMSE ราว 0.07 ใกล้เคียงกับบน Validation
- **ช่วงรอบวัน spike** (วันผันผวนสูง 38 จาก 54 วัน หรือ 70%): ROC-AUC ของ classifier ในตารางอยู่ระหว่าง 0.34 ถึง 0.61 คือใกล้หรือต่ำกว่าการเดาสุ่ม **ภายในช่วงปั่นป่วน โมเดลแยกไม่ได้ว่าวันไหนจะผันผวนสูง** AP ที่ดูสูง (0.7 ถึง 0.8) มาจากการที่วันส่วนใหญ่ในช่วงนี้ผันผวนสูงอยู่แล้ว ส่วน regression ได้ RMSE ราว 0.25 ถึง 0.28 และ R^2 ติดลบ



รูปที่ 4.9 ROC-AUC บน Test แยกตามช่วงตลาด

สรุปคือ โมเดลรู้ว่า "ตอนนี้ตลาดกำลังปั่นป่วน" ซึ่งเป็นสิ่งที่ `baseline_persistence` ก็รู้ แต่ไม่รู้ว่าความปั่นป่วนจะเริ่มเมื่อไรหรือจะจบวันไหน ตาราง metric ครบทุกตัวบน Test อยู่ในภาคผนวก ข

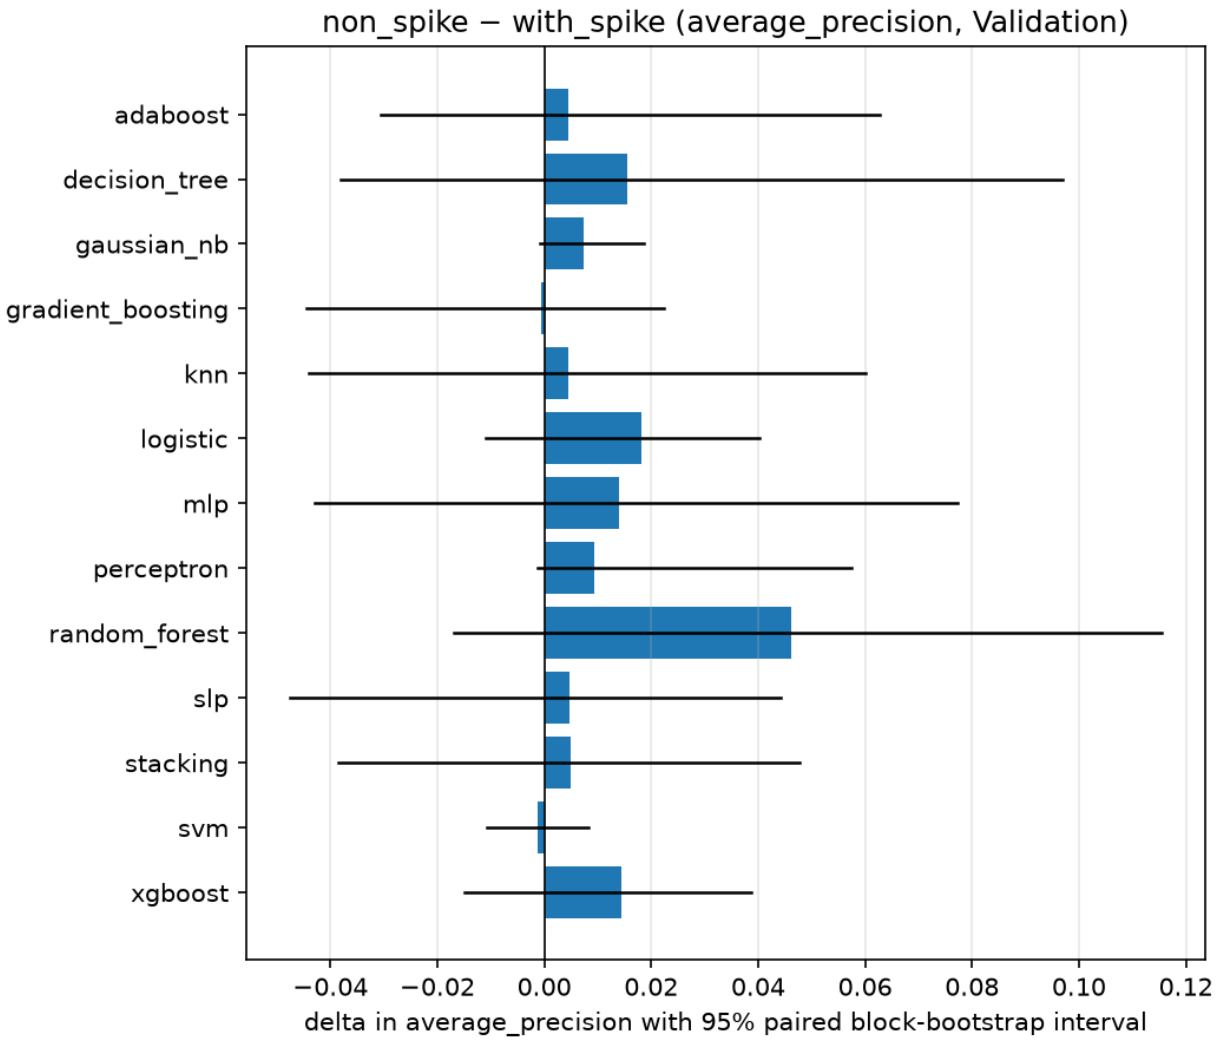
4.5 ผลการเปรียบเทียบ with_spike กับ non_spike

บน Validation `delta = non_spike − with_spike` สำหรับ AP ค่าบวกคือดีขึ้นเมื่อตัด spike สำหรับ RMSE ค่าลบคือดีขึ้น

ตารางที่ 4.16 ผลต่างแบบจับคู่ non_spike − with_spike บน Validation

model	task	metric	with_ spike	non_ spike	delta	delta_95	verdict
elastic_net	regression	rmse	0.0668	0.0643	-0.0026	[-0.0053, +0.0019]	inconclusive
multiple_linear	regression	rmse	0.0689	0.0668	-0.0020	[-0.0036, -0.0000]	non_spike better
polynomial	regression	rmse	0.0691	0.0661	-0.0030	[-0.0073, +0.0016]	inconclusive
simple_linear	regression	rmse	0.0690	0.0665	-0.0026	[-0.0066, +0.0026]	inconclusive
adaboost	classification	average_precision	0.2363	0.2407	0.0044	[-0.0307, +0.0627]	inconclusive
decision_tree	classification	average_precision	0.1732	0.1887	0.0155	[-0.0380, +0.0970]	inconclusive
gaussian_nb	classification	average_precision	0.2218	0.2292	0.0074	[-0.0007, +0.0187]	inconclusive
gradient_boosting	classification	average_precision	0.2531	0.2525	-0.0006	[-0.0445, +0.0223]	inconclusive
knn	classification	average_precision	0.2037	0.2082	0.0045	[-0.0441, +0.0601]	inconclusive
logistic	classification	average_precision	0.2330	0.2513	0.0183	[-0.0110, +0.0401]	inconclusive
mlp	classification	average_precision	0.2668	0.2808	0.0139	[-0.0429, +0.0772]	inconclusive
perceptron	classification	average_precision	0.0648	0.0742	0.0094	[-0.0012, +0.0575]	inconclusive
random_forest	classification	average_precision	0.2548	0.3010	0.0462	[-0.0168, +0.1155]	inconclusive
slp	classification	average_precision	0.2427	0.2474	0.0047	[-0.0477, +0.0441]	inconclusive
stacking	classification	average_precision	0.2262	0.2311	0.0049	[-0.0386, +0.0477]	inconclusive
svm	classification	average_precision	0.2514	0.2501	-0.0013	[-0.0108, +0.0082]	inconclusive
xgboost	classification	average_precision	0.2508	0.2652	0.0144	[-0.0148, +0.0386]	inconclusive
agglomerative	clustering	silhouette	0.3602	0.4642	0.1040	n/a	no interval
kmeans	clustering	silhouette	0.3666	0.3298	-0.0367	n/a	no interval

*ผลต่างในตารางนี้คือผลของ **นโยบายตัดแถวทั้งชุด** ไม่ใช่ผลของ spike เพียงอย่างเดียว: การตัด 213 แถวทำให้ class prior ของ Train เปลี่ยนจาก 25.0% เป็น 18.4%, จำนวนแถวลดจาก 1,733 เป็น 1,520 และ regime ที่ผันผวนสูงหายไปจาก Train พร้อมกัน ทั้งสาม confound นี้แยกจากกันไม่ได้ด้วยการทดลองนี้ delta = non_spike − with_spike บน Validation 371 แถวชุดเดียวกัน ช่วง 95% จาก paired moving-block bootstrap (block 20 วัน) และเมื่อเทียบ 17 โมเดลพร้อมกัน ควรคาดว่าจะมีราว 1 แถวที่ช่วงไม่คร่อมศูนย์โดยบังเอิญ*



รูปที่ 4.10 ผลต่างของ AP เมื่อตัด spike ออก พร้อมช่วงความเชื่อมั่น 95% (Validation)

โมเดลส่วนใหญ่ได้คะแนนดีขึ้นเล็กน้อยเมื่อตัด spike แต่ 16 จาก 17 โมเดลได้คำตัดสิน `inconclusive` มีเพียง `multiple_linear` ที่ช่วงไม่คร่อมศูนย์ ซึ่งเมื่อเทียบ 17 โมเดลพร้อมกัน การเจอราว 1 โมเดลโดยบังเอิญเป็นเรื่องที่คาดได้ นอกจากนี้ Validation ไม่มีวัน spike เลย จึงทดสอบไม่ได้ว่าโมเดลแต่ละแบบรับมือ spike ได้ดีแค่ไหน

บน Test ใช้คำทำนายที่บันทึกไว้ตอน finalize และวิธี paired block bootstrap เดียวกัน

ตารางที่ 4.17 โมเดลเดียวกันที่เทรนแบบมีและไม่มีช่วง spike บน Test

task	model	metric	with_ spike	non_ spike	delta	delta_ low	delta_ high	direction	interval_ excludes_ zero
classification	adaboost	average_ precision	0.4858	0.5443	0.0585	-0.0324	0.1168	non_spike better	no
classification	decision_tree	average_ precision	0.3792	0.3844	0.0052	-0.1502	0.1190	non_spike better	no
classification	gaussian_nb	average_ precision	0.5538	0.5884	0.0346	-0.0064	0.0632	non_spike better	no
classification	gradient_ boosting	average_ precision	0.5332	0.5653	0.0322	-0.0254	0.0891	non_spike better	no
classification	knn	average_ precision	0.5472	0.5389	-0.0083	-0.1005	0.0946	with_spike better	no

task	model	metric	with_spike	non_spike	delta	delta_low	delta_high	direction	interval_excludes_zero
classification	logistic	average_precision	0.5518	0.5510	-0.0008	-0.0184	0.0156	with_spike better	no
classification	mlp	average_precision	0.5991	0.5639	-0.0352	-0.0792	0.0276	with_spike better	no
classification	perceptron	average_precision	0.1374	0.1328	-0.0046	-0.0313	-0.0001	with_spike better	yes
classification	random_forest	average_precision	0.5775	0.5240	-0.0534	-0.1284	0.0106	with_spike better	no
classification	slp	average_precision	0.5536	0.4963	-0.0573	-0.1184	-0.0038	with_spike better	yes
classification	stacking	average_precision	0.5131	0.5499	0.0368	-0.0721	0.1233	non_spike better	no
classification	svm	average_precision	0.5716	0.5805	0.0088	-0.0015	0.0184	non_spike better	no
classification	xgboost	average_precision	0.5305	0.5823	0.0518	0.0163	0.0931	non_spike better	yes
regression	elastic_net	rmse	0.1174	0.1230	0.0055	-0.0045	0.0122	with_spike better	no
regression	multiple_linear	rmse	0.1158	0.1180	0.0022	-0.0017	0.0051	with_spike better	no
regression	polynomial	rmse	0.1401	0.1142	-0.0260	-0.0575	0.0041	non_spike better	no
regression	simple_linear	rmse	0.1356	0.1372	0.0016	-0.0288	0.0198	with_spike better	no

- ทิศทางบน Test **ไม่ตรงกับ Validation**: classifier 7 ตัวดีขึ้นและ 6 ตัวแย่ลงเมื่อตัด spike ส่วน regression 3 จาก 4 ตัวแย่ลงเล็กน้อย
- ช่วงความเชื่อมั่นคร่อมศูนย์ใน 14 จาก 17 โมเดล อีก 3 โมเดลชี้ไปคนละทาง: `slp` และ `perceptron` ดีกว่าเมื่อเก็บ spike ไว้ ส่วน `xgboost` ดีกว่าเมื่อตัดออก
- ข้อสังเกตจากตารางแยกช่วงในหัวข้อ 4.4 (ไม่มีช่วงความเชื่อมั่น): โมเดลเชิงเส้นที่เทรนแบบไม่มี spike ทำได้ดีกว่าเล็กน้อยในช่วงปกติ แต่แย่กว่าในช่วงรอบวัน spike ซึ่งสมเหตุสมผล เพราะไม่เคยเห็นตัวอย่างแบบนั้นตอนเทรน

สมมติฐานเรื่อง AdaBoost บน Validation `adaboost` แทบไม่เปลี่ยน (+0.004) บน Test เป็นโมเดลที่ดีขึ้นมากที่สุดเมื่อตัด spike (AP 0.486 เป็น 0.544) ซึ่งสอดคล้องกับสมมติฐานในหัวข้อ 2.1.5 แต่ช่วงความเชื่อมั่นยังคร่อมศูนย์ จึงเป็นเพียงข้อสังเกตที่ไปในทิศทางเดียวกับสมมติฐาน ยังไม่ใช่ข้อพิสูจน์

4.6 ผลเทียบกับโมเดลพื้นฐานที่สอนในห้อง

เราเทียบโมเดลตัวแทนกับโมเดลพื้นฐานที่สอนในห้อง คือ `logistic` สำหรับ classification และ `multiple_linear` สำหรับ regression แบบจับคู่ คอลัมน์ `improvement_percent` เป็นบวกเมื่อโมเดลตัวแทนดีกว่า

ตารางที่ 4.18 โมเดลตัวแทนเทียบกับโมเดลพื้นฐานที่สอนในห้อง บน Validation

task	variant	metric	classroom_model	classroom_score	headline	headline_score	delta	delta_low	delta_high	improvement_percent	interval_excludes_zero
classification	with_spike	average_precision	logistic	0.2330	mlp	0.2668	0.0338	-0.0038	0.0699	14.5214	no
classification	non_spike	average_precision	logistic	0.2513	random_forest	0.3010	0.0497	-0.0174	0.1004	19.7965	no
regression	with_spike	rmse	multiple_linear	0.0689	elastic_net	0.0668	-0.0021	-0.0059	0.0014	2.9883	no
regression	non_spike	rmse	multiple_linear	0.0668	elastic_net	0.0643	-0.0026	-0.0068	0.0020	3.8380	no

ตารางที่ 4.19 โมเดลตัวแทนเทียบกับโมเดลพื้นฐานที่สอนในห้อง บน Test

task	variant	metric	classroom_model	classroom_score	headline	headline_score	delta	delta_low	delta_high	improvement_percent	interval_excludes_zero
classification	with_spike	average_precision	logistic	0.5518	mlp	0.5991	0.0473	-0.0137	0.0766	8.5643	no
classification	non_spike	average_precision	logistic	0.5510	random_forest	0.5240	-0.0270	-0.1678	0.0793	-4.8974	no
regression	with_spike	rmse	multiple_linear	0.1158	elastic_net	0.1174	0.0016	-0.0092	0.0089	-1.4215	no
regression	non_spike	rmse	multiple_linear	0.1180	elastic_net	0.1230	0.0049	-0.0119	0.0158	-4.1832	no

บน Validation โมเดลตัวแทนดีกว่าโมเดลพื้นฐาน 3% ถึง 20% แต่ช่วงความเชื่อมั่นคร่อมศูนย์ทุกแถว บน Test มีเพียง `mlp` ที่ยังดีกว่า `logistic` (ราว 8.6% และช่วงยังคร่อมศูนย์) ส่วน `random_forest` และ `elastic_net` ทำได้แย่กว่าโมเดลพื้นฐานเล็กน้อย

4.7 การวิเคราะห์ความผิดพลาดของโมเดล

จากคำทำนายของโมเดลตัวแทนบน Validation (notebook 05 หัวข้อ 7) วันผันผวนสูง 20 จาก 34 วันอยู่ในไตรมาส 3 ปี 2024 ซึ่งตลาดปรับฐานแรงต้นเดือนสิงหาคม โมเดลจับได้ 7 ถึง 8 วัน ทั้งหมดอยู่ในไตรมาสนั้น ส่วนอีก 14 วันที่กระจายอยู่ในไตรมาสอื่นพลาดทั้งหมด

คะแนนของโมเดลขึ้นตาม **หลัง** ความผันผวนเริ่มแล้ว เพราะฟีเจอร์ทั้งหมดมองย้อนหลัง โมเดลจึงจับช่วงกลางและท้ายของเหตุการณ์ใหญ่ได้ แต่พลาดวันแรก ๆ และพลาดเหตุการณ์สั้น ๆ ผลบน Test (หัวข้อ 4.4) ยืนยันภาพเดียวกัน

4.8 ความเสถียรของอันดับข้ามช่วงเวลา

ผลของ walk-forward ภายในข้อมูลเทรน (วิธีอยู่ในหัวข้อ 3.4.8) ครอบคลุมวันผันผวนสูงรวม 353 วัน

ตารางที่ 4.20 Average precision ของ walk-forward ภายใน Train แบบ with_spike

model	fold_0_ap	fold_1_ap	fold_2_ap	fold_3_ap	folds_used	positives	pooled_ap	pooled_low	pooled_high
gaussian_nb	0.8282	0.6361	0.7775	0.4436	4	353	0.7124	0.5717	0.8151
gradient_boosting	0.8117	0.5722	0.8168	0.5522	4	353	0.7120	0.5857	0.8059
logistic	0.8173	0.6103	0.7847	0.4511	4	353	0.7030	0.5548	0.8083
random_forest	0.8079	0.6003	0.8018	0.5108	4	353	0.6833	0.5582	0.7797
svm	0.7946	0.6118	0.7839	0.4556	4	353	0.6718	0.5280	0.7842
slp	0.7946	0.5278	0.7658	0.4313	4	353	0.6717	0.5205	0.7813
adaboost	0.7998	0.5650	0.8330	0.4458	4	353	0.6708	0.5383	0.7772
xgboost	0.7604	0.5602	0.8042	0.5628	4	353	0.6690	0.5514	0.7645
mlp	0.7662	0.5310	0.8070	0.4385	4	353	0.6663	0.5203	0.7738
stacking	n/a	0.5861	0.8200	0.4417	3	273	0.6473	0.5119	0.7693
knn	0.7504	0.6400	0.7724	0.4553	4	353	0.6406	0.5153	0.7510
decision_tree	0.5803	0.4013	0.7242	0.3880	4	353	0.5750	0.4401	0.6958
perceptron	0.1852	0.5271	0.6226	0.2144	4	353	0.3337	0.2478	0.4690

คะแนนของโมเดลเดียวกันต่างกันระหว่างรอบมากกว่าที่ต่างกันระหว่างโมเดลในรอบเดียวกัน (เช่น รอบที่ 0 ได้ AP ราว 0.8 ส่วนรอบที่ 3 ได้ราว 0.45) สภาพตลาดจึงมีผลต่อคะแนนมากกว่าชนิดของโมเดล อันดับจาก walk-forward สัมพันธ์กับอันดับบน Validation เพียงบางส่วน (Spearman 0.49 สำหรับ `with_spike` และ 0.17 สำหรับ `non_spike` คำนวณใน notebook 05 หัวข้อ 5)

หมายเหตุ: `stacking` ไม่มีผลในรอบที่ 0 เพราะ 275 วันแรกของข้อมูลเทรนไม่มีวันผันผวนสูงเลย โมเดลซึ่งต้องแบ่งข้อมูลภายในอีกชั้นจึงเทรนบนประวัติที่สั้นที่สุดไม่ได้

บทที่ 5

สรุปผล อภิปรายผล และข้อเสนอแนะ

5.1 สรุปผลการศึกษา

ผลการศึกษาสรุปตามวัตถุประสงค์ทั้งห้าข้อได้ดังนี้

1. **การพยากรณ์** จากข้อมูลราคาย้อนหลังเพียงอย่างเดียว โมเดลทำนายความผันผวน 5 วันข้างหน้าได้ดีกว่าการเดาสุ่มชัดเจน แต่เหนือกว่ากฎ "เท่ากับ 5 วันที่ผ่านมา" เพียงเล็กน้อย บน Test โมเดลตัวแทนของงาน classification ได้ AP 0.599 เทียบกับการเดาสุ่ม 0.196 และเส้นฐาน 0.536 ส่วนโมเดลตัวแทนของงาน regression ได้ RMSE 0.117 เทียบกับเส้นฐาน 0.138 (ตารางที่ 4.9)
2. **การเขียนโมเดลเอง** โมเดลทั้ง 19 ตัวเขียนด้วย NumPy และให้ผลตรงกับ scikit-learn หรือ XGBoost ตามเกณฑ์ในตารางที่ 3.7 โมเดลทั้ง 38 ชุดถูกบันทึก โหลดกลับ และทำนายซ้ำได้ค่าเดิม
3. **โมเดลนอกเนื้อหาที่เรียน** Elastic Net ดันน้ำหนักของฟีเจอร์เป็นศูนย์ 3 ถึง 4 ตัวจาก 8 ตัว และเป็นโมเดลตัวแทนของงาน regression ส่วน AdaBoost ให้คำทำนายตรงกับ library ทุกแถว (หัวข้อ 4.3)
4. **คำถามวิจัย** การตัดช่วงราคากระชากแรงออกจากข้อมูลเทรนไม่ได้ทำให้โมเดลดีขึ้นหรือแย่ลงอย่างที่วัดได้ ผลต่างเล็กกว่าความไม่แน่นอนของการวัด และทิศทางบน Validation กับ Test ไม่ตรงกัน
5. **การเปรียบเทียบโมเดล** โมเดลเรียบง่ายทำได้ดีพอ ๆ กับโมเดลซับซ้อน และผู้นำบน Validation ไม่ได้เป็นผู้นำบน Test เสมอไป โมเดลทำงานได้ในช่วงตลาดปกติ แต่ภายในช่วงปั่นป่วนแยกวันผันผวนสูงไม่ได้ ซึ่งเป็นช่วงที่การเตือนล่วงหน้ามีค่ามากที่สุด

5.2 อภิปรายผล

ทำไมกฎง่าย ๆ จึงทำได้ใกล้เคียงโมเดล ผลนี้สอดคล้องกับลักษณะความผันผวนกระจุกตัว (Cont, 2001; Engle, 1982) เมื่อความผันผวนของวันใกล้กันคล้ายกันมาก ความผันผวนของ 5 วันที่ผ่านมาจึงเป็นตัวทำนายที่ดีอยู่แล้ว และเป็นข้อมูลชุดเดียวกับที่โมเดลของเราใช้ ผลของ permutation importance ยืนยันว่าฟีเจอร์ที่โมเดลพึ่งมากที่สุดคือความผันผวนย้อนหลัง (หัวข้อ 4.1) ข้อค้นพบนี้ไปทางเดียวกับ Corsi (2009) ซึ่งพบว่า linear regression บนความผันผวนย้อนหลังไม่กี่ช่วงเวลาก็พยากรณ์ได้ดี

โมเดลใดดีที่สุด

คำตอบที่ซื่อตรงคือ **ข้อมูลไม่พอจะบอก** บน Validation ทั้ง 13 classifier และทั้ง 4 โมเดล regression อยู่ในกลุ่มที่แยกจากอันดับหนึ่งไม่ได้ บน Test กลุ่มนำของ classification ยังมี 10 จาก 13 โมเดลในทั้งสองแบบข้อมูล สิ่งที่บอกได้คือ

- `perceptron` และ `decision_tree` อยู่ท้ายตารางอย่างสม่ำเสมอ ทั้งบน Validation, Test และ walk-forward
- โมเดลที่เหลือ ตั้งแต่ `logistic` ที่เรียบง่าย ไปจนถึง `xgboost` และ `mlp` ทำได้ใกล้เคียงกันในระดับที่ข้อมูลชุดนี้แยกไม่ออก

เหตุผลที่น่าจะเป็นคือ ข้อมูลที่ทำนายได้อยู่ในฟีเจอร์ความผันผวนย้อนหลังไม่กี่ตัว และความสัมพันธ์ค่อนข้างเรียบง่าย โมเดลที่ซับซ้อนจึงไม่มีอะไรให้เรียนรู้เพิ่มมากนัก

ผลนี้ต่างจาก Christensen et al. (2023) ซึ่งพบว่า machine learning ดีกว่าโมเดลเชิงเส้น เหตุผลที่น่าจะเป็นคือ งานดังกล่าววัดความผันผวนจากข้อมูลความถี่สูงของหุ้นหลายตัว ค่าจริงจึงมีสัญญาณรบกวนต่ำและมีตัวอย่างมากกว่า ขณะที่โครงงานนี้คำนวณ target จากผลตอบแทนรายวันเพียง 5 ค่า และมีวันผันผวนสูงให้วัดเพียง 34 วันบน Validation และ 73 วันบน Test ความต่างระหว่างโมเดลที่อาจมีอยู่จริงจึงเล็กกว่าความไม่แน่นอนของการวัด ซึ่งเป็นประเด็นเดียวกับที่ Andersen และ Bollerslev (1998) ชี้ไว้เรื่องสัญญาณรบกวนของค่าจริง

เราจึง **ไม่อ้าง** ว่าโมเดลที่ซับซ้อนกว่าดีกว่าโมเดลที่สอนในห้องอย่างมีนัยสำคัญ ข้อค้นพบที่มีหลักฐานรองรับมากกว่า คือ บนโจทย์นี้ โมเดลเรียบง่ายอย่าง `logistic` และ `multiple_linear` ทำได้ดีพอ ๆ กับโมเดลที่ซับซ้อนที่สุดที่เราเขียน

ทำไมยังสรุปเรื่อง spike ไม่ได้

คำตอบของคำถามวิจัย ข้อมูลชุดนี้ **ไม่สนับสนุน** ว่านโยบายตัดแถวรอบวัน spike ออกจากข้อมูลเทรนทำให้โมเดลทำนายดีขึ้น และไม่สนับสนุนว่าทำให้แย่ลงเช่นกัน ผลต่างที่วัดได้เล็กกว่าความไม่แน่นอนของการวัด ทั้งบน Validation และ Test และทิศทางของสองชุดไม่ตรงกัน

เหตุผลมีสามข้อ ข้อแรก ผลต่างที่วัดได้เล็กเมื่อเทียบกับความกว้างของช่วงความเชื่อมั่น ซึ่งกว้างเพราะตัวอย่างของวันติดกันไม่อิสระต่อกัน (หัวข้อ 3.4.4) ข้อสอง การตัดแถวเปลี่ยนจำนวนแถว สัดส่วนคลาส และสภาพตลาดในข้อมูลเทรนพร้อมกัน จึงแยกผลของ spike ออกมาไม่ได้ (หัวข้อ 3.3.4) ข้อสาม Validation ไม่มีวัน spike เลย จึงทดสอบการรับมือกับ spike ได้เฉพาะบน Test ซึ่งมีเพียง 54 แถวในช่วงรอบวัน spike

สำหรับสมมติฐานเรื่อง AdaBoost ทฤษฎีของ Friedman et al. (2000) ทำนายว่าโมเดลที่ลด exponential loss จะไวต่อตัวอย่างสุดโต่ง ผลบน Test ไปในทิศทางเดียวกับคำทำนายนี้ คือ AdaBoost เป็นโมเดลที่ดีขึ้นมากที่สุดเมื่อตัดช่วง spike แต่ช่วงความเชื่อมั่นยังคร่อมศูนย์ จึงเป็นข้อสังเกตที่สอดคล้องกับทฤษฎี ยังไม่ใช่ข้อพิสูจน์

ทำไมโมเดลพลาดในช่วงตลาดปั่นป่วน ฟีเจอร์ทั้งหมดมองย้อนหลัง โมเดลจึงรู้ว่าตลาดกำลังปั่นป่วนหลังจากความปั่นป่วนเริ่มแล้ว แต่ไม่มีข้อมูลที่บอกว่าจะเริ่มหรือจบเมื่อไร (หัวข้อ 4.7) ข้อนี้สอดคล้องกับ Poon และ Granger (2003) ซึ่งพบว่า implied volatility ที่สะท้อนความคาดหวังของตลาดต่ออนาคต มักพยากรณ์ได้ดีกว่าวิธีที่ใช้ข้อมูลในอดีตเพียงอย่างเดียว

ทำไมผู้นำบน Validation ไม่ได้นำบน Test Validation มีวันผันผวนสูงเพียง 34 วัน และ classifier ทั้ง 13 ตัวแยกจากอันดับหนึ่งไม่ได้ การเลือกผู้ที่ได้คะแนนสูงสุดจึงใกล้กับการเลือกแบบสุ่มในกลุ่มที่เสมอกัน ตัวอย่างคือ `random_forest` ซึ่งเป็นโมเดลตัวแทนของแบบ `non_spike` ตกไปอยู่อันดับ 10 จาก 13 โมเดลบน Test ปรากฏการณ์นี้เรียกว่า selection bias ผลของ walk-forward ชี้ทางเดียวกัน คือสภาพตลาดมีผลต่อคะแนนมากกว่าชนิดของโมเดล (หัวข้อ 4.8)

สิ่งที่ได้เรียนรู้จากการเขียนโมเดลเองทั้งหมด

- การทำให้ผลตรงกับ library ถึงทศนิยมสุดท้าย บังคับให้เข้าใจรายละเอียดที่ตำราข้ามไป เช่น ลำดับการสุ่ม กฎการหยุดวนรอบ และการตัดสินเมื่อคะแนนเท่ากัน
- กับข้อมูลอนุกรมเวลา ความถูกต้องของขั้นตอน (แบ่งตามเวลา เว้นช่องว่าง คำนวณทุกอย่างจาก Train ล็อกก่อนเปิด Test) สำคัญกว่าการเลือกโมเดล
- ช่วงความเชื่อมั่นเปลี่ยนข้อสรุปได้มาก ถ้าดูเฉพาะค่าที่วัดได้ เราคงสรุปว่า "ตัด spike แล้วดีขึ้น" และ "MLP ดีกว่า logistic 14%" ซึ่งทั้งสองข้อไม่มีหลักฐานรองรับเพียงพอ

5.3 ข้อจำกัดของการศึกษา

1. **ตัวอย่างไม่อิสระต่อกัน** ข้อมูลจริงมีน้อยกว่าจำนวนแถวมาก ช่วงความเชื่อมั่นจึงกว้าง และข้อสรุปส่วนใหญ่ของรายงานนี้คือ "ยังสรุปไม่ได้"
2. **Validation เป็นสภาพตลาดแบบเดียว** สงบ ไม่มี spike และมีวันผันผวนสูง 34 วัน จึงเลือกโมเดลได้ไม่แม่น
3. **การเทียบสองแบบข้อมูลถูก confound** จำนวนแถว สัดส่วนคลาส และสภาพตลาดเปลี่ยนพร้อมกัน การแยกผลของ spike ต้องใช้การทดลองเพิ่ม เช่น ตัดแถวปกติจำนวนเท่ากันออกเป็นกลุ่มควบคุม
4. **ช่วงรอบวัน spike ใน Test มีเพียง 54 แถวจากสองเหตุการณ์** ผลแยกช่วงจึงเป็นข้อสังเกต
5. **threshold คงที่ 0.5** ทำให้ recall ต่ำเมื่อสภาพตลาดเปลี่ยน การปรับ threshold หรือปรับเทียบความน่าจะเป็น (calibration) อาจช่วยได้ แต่ต้องมีข้อมูลแยกสำหรับเลือก
6. **ไม่มีฟีเจอร์ที่มองไปข้างหน้า** เช่น implied volatility (VIX) หรือปฏิทินประกาศตัวเลขเศรษฐกิจ ซึ่งน่าจะเป็นสิ่งที่ช่วยทำนายจุดเริ่มของความผันผวนได้
7. **สินทรัพย์เดียว ช่วงเวลาเดียว** ผลอาจไม่ใช้กับสินทรัพย์อื่น
8. **ค่า SHA-256 ของไฟล์ข้อมูลที่สร้างขึ้นผูกกับ Windows** เพราะรูปแบบการขึ้นบรรทัดใหม่ของไฟล์ต่างกันตามระบบปฏิบัติการ (`docs/audit/PATH_AUDIT.md`)
9. **ทดลองกับเกณฑ์ spike เดียว** เกณฑ์ Q3 + 3 × IQR ถูกกำหนดล่วงหน้า เกณฑ์ทางเลือกในหัวข้อ 3.3.4 ถูกเทียบเฉพาะจำนวนข้อมูลที่เหลือ ไม่ได้นำไปเทรนโมเดล ผลของการทดลองจึงใช้กับนิยามนี้เท่านั้น

5.4 ข้อเสนอแนะ

5.4.1 ข้อเสนอแนะในการนำผลการศึกษาไปใช้

1. ใช้คำทำนายของโมเดลคู่กับเส้นฐาน "เท่ากับ 5 วันที่ผ่านมา" เสมอ เพราะโมเดลให้ประโยชน์เพิ่มจากเส้นฐานเพียงเล็กน้อย
2. ใช้โมเดลเป็นตัวบอกสภาพตลาดปัจจุบัน มากกว่าเป็นสัญญาณเตือนล่วงหน้า เพราะโมเดลจับจุดเริ่มของช่วงปั่นป่วนไม่ได้
3. ไม่ควรตัดสินโมเดลด้วย accuracy เพียงอย่างเดียว เพราะคลาสไม่สมดุล ควรดู AP, precision และ recall ประกอบและเทียบกับเส้นฐานของชุดข้อมูลเดียวกัน
4. threshold คงที่ 0.5 ให้ recall ต่ำเมื่อสภาพตลาดเปลี่ยน ผู้ใช้ควรกำหนด threshold ตามต้นทุนของการเตือนผิดและการพลาดของตน โดยใช้ข้อมูลที่แยกไว้สำหรับเลือก
5. จากหลักฐานที่มี ยังไม่มีเหตุผลพอให้ตัดช่วง spike ออกจากข้อมูลเทรน การใช้ข้อมูลครบเป็นทางเลือกที่ง่ายกว่า และให้โมเดลได้เห็นสภาพตลาดครบกว่า

5.4.2 ข้อเสนอแนะสำหรับการศึกษาครั้งต่อไป

1. เพิ่มฟีเจอร์ที่มองไปข้างหน้า เช่น implied volatility (VIX) และปฏิทินประกาศตัวเลขเศรษฐกิจ
2. ทำกลุ่มควบคุมสำหรับการทดลอง spike โดยตัดแถวปกติจำนวนเท่ากันออก เพื่อแยกผลของ spike ออกจากผลของจำนวนแถวและสัดส่วนคลาส

3. ทดลองเกณฑ์ spike แบบอื่นด้วยการเทรนโมเดลจริง ไม่ใช่เทียบเฉพาะจำนวนข้อมูลที่เหลือ
4. ใช้ walk-forward ในการเลือกโมเดลแทน Validation ช่วงเดียว
5. ใช้ข้อมูลความถี่สูงเพื่อวัดความผันผวนที่เกิดขึ้นจริงให้แม่นขึ้น ตามแนวทางของ Andersen และ Bollerslev (1998)
6. ทดสอบกับสินทรัพย์อื่นและช่วงเวลาอื่น

บรรณานุกรม

Andersen, T. G., & Bollerslev, T. (1998). Answering the skeptics: Yes, standard volatility models do provide accurate forecasts. International Economic Review, 39(4), 885–905.

Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. Journal of Econometrics, 31(3), 307–327.

Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5–32.

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (pp. 785–794). Association for Computing Machinery.

Christensen, K., Siggaard, M., & Veliyev, B. (2023). A machine learning approach to volatility forecasting. Journal of Financial Econometrics, 21(5), 1680–1727.

Cont, R. (2001). Empirical properties of asset returns: Stylized facts and statistical issues. Quantitative Finance, 1(2), 223–236.

Corsi, F. (2009). A simple approximate long-memory model of realized volatility. Journal of Financial Econometrics, 7(2), 174–196.

Cortes, C., & Vapnik, V. (1995). Support-vector networks. Machine Learning, 20(3), 273–297.

Davis, J., & Goadrich, M. (2006). The relationship between Precision-Recall and ROC curves. In Proceedings of the 23rd International Conference on Machine Learning (pp. 233–240). Association for Computing Machinery.

Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. Econometrica, 50(4), 987–1007.

Freund, Y., & Schapire, R. E. (1997). A decision-theoretic generalization of on-line learning and an application to boosting. Journal of Computer and System Sciences, 55(1), 119–139.

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. The Annals of Statistics, 29(5), 1189–1232.

Friedman, J., Hastie, T., & Tibshirani, R. (2000). Additive logistic regression: A statistical view of boosting. The Annals of Statistics, 28(2), 337–407.

Friedman, J., Hastie, T., & Tibshirani, R. (2010). Regularization paths for generalized linear models via coordinate descent. Journal of Statistical Software, 33(1), 1–22.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). The elements of statistical learning: Data mining, inference, and prediction (2nd ed.). Springer.

Hoerl, A. E., & Kennard, R. W. (1970). Ridge regression: Biased estimation for nonorthogonal problems. Technometrics, 12(1), 55–67.

Künsch, H. R. (1989). The jackknife and the bootstrap for general stationary observations. The Annals of Statistics, 17(3), 1217–1241.

López de Prado, M. (2018). Advances in financial machine learning. Wiley.

Nasdaq. (2026). Invesco QQQ Trust, Series 1 (QQQ) historical data [ชุดข้อมูลราคารายวัน 31 สิงหาคม 2016 ถึง 28 สิงหาคม 2026]. https://www.nasdaq.com/market-activity/etf/qqq/historical

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Poon, S.-H., & Granger, C. W. J. (2003). Forecasting volatility in financial markets: A review. Journal of Economic Literature, 41(2), 478–539.

Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. PLOS ONE, 10(3), e0118432.

Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. Journal of the Royal Statistical Society: Series B (Methodological), 58(1), 267–288.

Tukey, J. W. (1977). Exploratory data analysis. Addison-Wesley.

Wolpert, D. H. (1992). Stacked generalization. Neural Networks, 5(2), 241–259.

Zhu, J., Zou, H., Rosset, S., & Hastie, T. (2009). Multi-class AdaBoost. Statistics and Its Interface, 2(3), 349–360.

Zou, H., & Hastie, T. (2005). Regularization and variable selection via the elastic net. Journal of the Royal Statistical Society: Series B (Statistical Methodology), 67(2), 301–320.

ภาคผนวก ก การตั้งค่าที่ถูกเลือกของทุกโมเดล

`candidates` คือจำนวนการตั้งค่าที่ลอง · `reference` คือ class ของ library ที่ใช้ยืนยันผล · `params_*` คือการตั้งค่าที่ชนะบน Validation ของแต่ละแบบข้อมูล · `pca_*` คือจำนวน component ของ PCA (ว่างคือไม่ใช้)

ตารางที่ ก.1 รายการโมเดลและการตั้งค่าที่ถูกเลือก

model	task	candidates	reference	preprocess	params_with_spike	params_non_spike	pca_with_spike	pca_non_spike
adaboost	classification	6	AdaBoostClassifier	none	{"learning_rate": 0.5, "n_estimators": 100, "random_state": 42}	{"learning_rate": 0.5, "n_estimators": 100, "random_state": 42}	n/a	n/a
agglomerative	clustering	10	AgglomerativeClustering	standardize	{"k": 2, "linkage": "ward"}	{"k": 2, "linkage": "average"}	n/a	n/a
decision_tree	classification	6	DecisionTreeClassifier	none	{"max_depth": 2, "max_features": null, "min_samples_leaf": 5, "random_state": 42}	{"max_depth": 5, "max_features": null, "min_samples_leaf": 5, "random_state": 42}	n/a	n/a
elastic_net	regression	12	ElasticNet	standardize	{"alpha": 0.1, "l1_ratio": 0.25, "max_iter": 5000, "tol": 1e-06}	{"alpha": 0.1, "l1_ratio": 0.25, "max_iter": 5000, "tol": 1e-06}	n/a	n/a
gaussian_nb	classification	3	GaussianNB	none	{"var_smoothing": 1e-07}	{"var_smoothing": 1e-08}	n/a	n/a
gradient_boosting	classification	8	GradientBoostingClassifier	none	{"learning_rate": 0.1, "max_depth": 1, "min_samples_leaf": 5, "n_estimators": 50, "random_state": 42}	{"learning_rate": 0.03, "max_depth": 2, "min_samples_leaf": 5, "n_estimators": 50, "random_state": 42}	n/a	n/a
kmeans	clustering	5	KMeans	standardize	{"k": 2, "max_iter": 300, "n_init": 10, "random_state": 42, "tol": 1e-06}	{"k": 2, "max_iter": 300, "n_init": 10, "random_state": 42, "tol": 1e-06}	n/a	n/a
knn	classification	8	KNeighborsClassifier	standardize	{"k": 15, "weights": "distance"}	{"k": 9, "weights": "distance"}	n/a	n/a
logistic	classification	6	LogisticRegression	standardize	{"class_weight": null, "l2": 0.01, "learning_rate": 0.05, "max_iter": 5000, "tol": 1e-06}	{"class_weight": null, "l2": 0, "learning_rate": 0.05, "max_iter": 5000, "tol": 1e-06}	n/a	n/a
mlp	classification	12	MLPClassifier	standardize	{"activation": "relu", "batch": 32, "hidden_layers": [16], "l2": 0, "learning_rate": 0.001, "max_epochs": 1000, "min_delta": 1e-06, "momentum": 0.9, "patience": 50, "random_state": 42}	{"activation": "relu", "batch": 32, "hidden_layers": [16, 8], "l2": 0, "learning_rate": 0.01, "max_epochs": 1000, "min_delta": 1e-06, "momentum": 0.9, "patience": 50, "random_state": 42}	n/a	n/a
multiple_linear	regression	1	LinearRegression	standardize	{"fit_intercept": true}	{"fit_intercept": true}	n/a	n/a
perceptron	classification	3	Perceptron	standardize	{"learning_rate": 0.001, "max_epochs": 1000}	{"learning_rate": 0.001, "max_epochs": 1000}	n/a	n/a
polynomial	regression	16	Pipeline	standardize	{"degree": 3, "feature": "historical_volatility_20d", "standardize_before_powers": true}	{"degree": 2, "feature": "return_5d", "standardize_before_powers": true}	n/a	n/a
random_forest	classification	7	RandomForestClassifier	none	{"bootstrap": true, "max_depth": 3, "max_features": "sqrt", "min_samples_leaf": 5, "n_estimators": 100, "random_state": 42}	{"bootstrap": true, "max_depth": 5, "max_features": "sqrt", "min_samples_leaf": 5, "n_estimators": 50, "random_state": 42}	n/a	n/a
simple_linear	regression	8	LinearRegression	none	{"feature": "historical_volatility_20d"}	{"feature": "return_1d"}	n/a	n/a
slp	classification	8	LogisticRegression	standardize	{"batch": 32, "l2": 0, "learning_rate": 0.001, "max_epochs": 1000, "min_delta": 1e-06, "patience": 50, "random_state": 42}	{"batch": "full", "l2": 0, "learning_rate": 0.01, "max_epochs": 1000, "min_delta": 1e-06, "patience": 50, "random_state": 42}	n/a	n/a
stacking	classification	1	StackingClassifier	base_specific	{"folds": 4, "initial_fraction": 0.4, "purge": 5, "random_state": 42}	{"folds": 4, "initial_fraction": 0.4, "purge": 5, "random_state": 42}	n/a	n/a

model	task	candidates	reference	preprocess	params_with_spike	params_non_spike	pca_with_spike	pca_non_spike
svm	classification	12	SVC	standardize	{"C": 0.1, "fit_intercept": true, "max_iter": 20000, "random_state": 42}	{"C": 10, "fit_intercept": true, "max_iter": 20000, "random_state": 42}	4	4
xgboost	classification	8	XGBClassifier	none	{"gamma": 0, "learning_rate": 0.03, "max_depth": 1, "n_estimators": 100, "random_state": 42, "reg_lambda": 1}	{"gamma": 0.1, "learning_rate": 0.03, "max_depth": 2, "n_estimators": 100, "random_state": 42, "reg_lambda": 10}	n/a	n/a

ภาคผนวก ข ตารางเพิ่มเติม

ข.1 Validation ของแบบ non_spike

ตารางที่ ข.1 ผลของโมเดล classification บน Validation แบบ non_spike

model	kind	average_ precision_ci	roc_auc_ci	f1_ci	recall_ci	precision	specificity	accuracy	loss_name	loss	tied_ with_ leader	beats_best_ baseline
random_forest	model	0.3010 [0.0548, 0.5328]	0.6766 [0.4439, 0.8313]	0.2917 [0.0000, 0.5064]	0.2059 [0.0000, 0.4287]	0.5000	0.9792	0.9084	log_loss	0.3059	yes	yes
mlp	model	0.2808 [0.0534, 0.5184]	0.6992 [0.4716, 0.8426]	0.3077 [0.0000, 0.5435]	0.2353 [0.0000, 0.4545]	0.4444	0.9703	0.9030	binary_cross_ entropy	0.3166	yes	yes
xgboost	model	0.2652 [0.0600, 0.4730]	0.6853 [0.4608, 0.8256]	0.2800 [0.0000, 0.5000]	0.2059 [0.0000, 0.4255]	0.4375	0.9733	0.9030	binary_logistic_loss	0.3088	yes	yes
gradient_boosting	model	0.2525 [0.0625, 0.4477]	0.6732 [0.4577, 0.8152]	0.2667 [0.0000, 0.4533]	0.1765 [0.0000, 0.3674]	0.5455	0.9852	0.9111	binary_logistic_loss	0.2966	yes	yes
logistic	model	0.2513 [0.0538, 0.4557]	0.6824 [0.4529, 0.8310]	0.2553 [0.0000, 0.4445]	0.1765 [0.0000, 0.3674]	0.4615	0.9792	0.9057	binary_cross_ entropy	0.3014	yes	yes
svm	model	0.2501 [0.0520, 0.4672]	0.6804 [0.4367, 0.8413]	0.2727 [0.0000, 0.4667]	0.1765 [0.0000, 0.3674]	0.6000	0.9881	0.9137	hinge_loss	0.2539	yes	yes
baseline_ persistence	baseline	0.2474 [0.0545, 0.5002]	0.7214 [0.5384, 0.8407]	0.2899 [0.0000, 0.5589]	0.2941 [0.0000, 0.5601]	0.2857	0.9258	0.8679	n/a	n/a	yes	n/a
slp	model	0.2474 [0.0489, 0.4531]	0.6778 [0.4892, 0.8122]	0.2258 [0.0000, 0.4156]	0.2059 [0.0000, 0.4255]	0.2500	0.9377	0.8706	binary_cross_ entropy	0.3607	yes	no
adaboost	model	0.2407 [0.0556, 0.4722]	0.6409 [0.3618, 0.8209]	0.2353 [0.0000, 0.4444]	0.1765 [0.0000, 0.3674]	0.3529	0.9674	0.8949	exponential_loss	0.5875	yes	no
stacking	model	0.2311 [0.0582, 0.4204]	0.6650 [0.4550, 0.8061]	0.1961 [0.0000, 0.3509]	0.1471 [0.0000, 0.3077]	0.2941	0.9644	0.8895	log_loss	0.3304	yes	no
gaussian_nb	model	0.2292 [0.0485, 0.4434]	0.6789 [0.4426, 0.8273]	0.2381 [0.0000, 0.4355]	0.2941 [0.0000, 0.5371]	0.2000	0.8813	0.8275	log_loss	0.7534	yes	no
knn	model	0.2082 [0.0584, 0.3932]	0.6455 [0.4610, 0.7802]	0.2222 [0.0000, 0.3846]	0.1765 [0.0000, 0.3514]	0.3000	0.9585	0.8868	log_loss	1.2326	yes	no
decision_tree	model	0.1887 [0.0505, 0.4105]	0.6924 [0.4917, 0.8233]	0.1887 [0.0000, 0.3556]	0.1471 [0.0000, 0.2963]	0.2632	0.9585	0.8841	log_loss	0.5063	yes	no
baseline_majority	baseline	0.0916 [0.0350, 0.1779]	0.5000 [0.5000, 0.5000]	0.0000 [0.0000, 0.0000]	0.0000 [0.0000, 0.0000]	n/a	1.0000	0.9084	n/a	n/a	yes	n/a
perceptron	model	0.0742 [0.0343, 0.1688]	0.3383 [0.1803, 0.5693]	0.1159 [0.0000, 0.2571]	0.1176 [0.0000, 0.3125]	0.1143	0.9080	0.8356	perceptron_ criterion	0.0010	yes	no

ตัวเลขบน Validation เป็น selection score: hyperparameter ของทุกโมเดลถูกเลือกบนแถวชุดนี้ จึงมองโลกในแง่ดีเกินจริง และโมเดลที่ `tied_with_leader = yes` *แยกจากอันดับ 1 ไม่ได้ที่ระดับ 95% (moving-block bootstrap, block 20 วัน) ห้ามอ้างอันดับภายในกลุ่มนั้น*

13 จาก 13 โมเดลอยู่ในกลุ่มที่แยกจากอันดับ 1 ไม่ได้

ตารางที่ ข.2 ตัวชี้วัดครบทุกตัวที่โจทย์กำหนด บน Validation แบบ non_spike

model	loss_name	loss	tn	fp	fn	tp	accuracy	precision	sensitivity	specificity	tnr	f1	roc_auc	average_ precision
random_forest	log_loss	0.3059	330	7	27	7	0.9084	0.5000	0.2059	0.9792	0.9792	0.2917	0.6766	0.3010
mlp	binary_cross_entropy	0.3166	327	10	26	8	0.9030	0.4444	0.2353	0.9703	0.9703	0.3077	0.6992	0.2808
xgboost	binary_logistic_loss	0.3088	328	9	27	7	0.9030	0.4375	0.2059	0.9733	0.9733	0.2800	0.6853	0.2652
gradient_boosting	binary_logistic_loss	0.2966	332	5	28	6	0.9111	0.5455	0.1765	0.9852	0.9852	0.2667	0.6732	0.2525
logistic	binary_cross_entropy	0.3014	330	7	28	6	0.9057	0.4615	0.1765	0.9792	0.9792	0.2553	0.6824	0.2513
svm	hinge_loss	0.2539	333	4	28	6	0.9137	0.6000	0.1765	0.9881	0.9881	0.2727	0.6804	0.2501
baseline_persistence	n/a	n/a	312	25	24	10	0.8679	0.2857	0.2941	0.9258	0.9258	0.2899	0.7214	0.2474
slp	binary_cross_entropy	0.3607	316	21	27	7	0.8706	0.2500	0.2059	0.9377	0.9377	0.2258	0.6778	0.2474
adaboost	exponential_loss	0.5875	326	11	28	6	0.8949	0.3529	0.1765	0.9674	0.9674	0.2353	0.6409	0.2407
stacking	log_loss	0.3304	325	12	29	5	0.8895	0.2941	0.1471	0.9644	0.9644	0.1961	0.6650	0.2311
gaussian_nb	log_loss	0.7534	297	40	24	10	0.8275	0.2000	0.2941	0.8813	0.8813	0.2381	0.6789	0.2292
knn	log_loss	1.2326	323	14	28	6	0.8868	0.3000	0.1765	0.9585	0.9585	0.2222	0.6455	0.2082
decision_tree	log_loss	0.5063	323	14	29	5	0.8841	0.2632	0.1471	0.9585	0.9585	0.1887	0.6924	0.1887
baseline_majority	n/a	n/a	337	0	34	0	0.9084	n/a	0.0000	1.0000	1.0000	0.0000	0.5000	0.0916
perceptron	perceptron_criterion	0.0010	306	31	30	4	0.8356	0.1143	0.1176	0.9080	0.9080	0.1159	0.3383	0.0742

ตารางที่ ข.3 ผลของโมเดล clustering บน Validation แบบ non_spike

model	variant	k	silhouette	inertia	cluster_sizes
agglomerative	non_spike	2	0.4642	1844.8884	{"0": 359, "1": 12}
kmeans	non_spike	2	0.3298	1448.9259	{"0": 267, "1": 104}

silhouette/inertia คำนวณบน Validation ไม่มีช่วงความเชื่อมั่น

ข.2 ตัวชี้วัดครบทุกตัวบน Test

ตารางที่ ข.4 ตัวชี้วัดครบทุกตัวที่โจทย์กำหนด บน Test แบบ with_spike

model	tn	fp	fn	tp	accuracy	precision	sensitivity	specificity	tnr	f1	roc_auc	average_precision
mlp	283	17	37	36	0.8552	0.6792	0.4932	0.9433	0.9433	0.5714	0.7930	0.5991
random_forest	280	20	42	31	0.8338	0.6078	0.4247	0.9333	0.9333	0.5000	0.7866	0.5775
svm	283	17	44	29	0.8365	0.6304	0.3973	0.9433	0.9433	0.4874	0.7835	0.5716
gaussian_nb	263	37	28	45	0.8257	0.5488	0.6164	0.8767	0.8767	0.5806	0.7703	0.5538
slp	281	19	42	31	0.8365	0.6200	0.4247	0.9367	0.9367	0.5041	0.7798	0.5536
logistic	282	18	41	32	0.8418	0.6400	0.4384	0.9400	0.9400	0.5203	0.7822	0.5518
knn	281	19	38	35	0.8472	0.6481	0.4795	0.9367	0.9367	0.5512	0.7847	0.5472
gradient_boosting	277	23	46	27	0.8150	0.5400	0.3699	0.9233	0.9233	0.4390	0.7665	0.5332
xgboost	278	22	45	28	0.8204	0.5600	0.3836	0.9267	0.9267	0.4553	0.7716	0.5305
stacking	268	32	31	42	0.8311	0.5676	0.5753	0.8933	0.8933	0.5714	0.7902	0.5131
adaboost	270	30	40	33	0.8123	0.5238	0.4521	0.9000	0.9000	0.4853	0.7614	0.4858
decision_tree	259	41	37	36	0.7909	0.4675	0.4932	0.8633	0.8633	0.4800	0.7450	0.3792
perceptron	272	28	70	3	0.7373	0.0968	0.0411	0.9067	0.9067	0.0577	0.2749	0.1374

ตารางที่ ข.5 ตัวชี้วัดครบทุกตัวที่โจทย์กำหนด บน Test แบบ non_spike

model	tn	fp	fn	tp	accuracy	precision	sensitivity	specificity	tnr	f1	roc_auc	average_precision
gaussian_nb	244	56	20	53	0.7962	0.4862	0.7260	0.8133	0.8133	0.5824	0.7779	0.5884
xgboost	280	20	38	35	0.8445	0.6364	0.4795	0.9333	0.9333	0.5469	0.7887	0.5823
svm	289	11	48	25	0.8418	0.6944	0.3425	0.9633	0.9633	0.4587	0.7853	0.5805
gradient_boosting	291	9	54	19	0.8311	0.6786	0.2603	0.9700	0.9700	0.3762	0.7861	0.5653
mlp	278	22	41	32	0.8311	0.5926	0.4384	0.9267	0.9267	0.5039	0.7894	0.5639
logistic	281	19	42	31	0.8365	0.6200	0.4247	0.9367	0.9367	0.5041	0.7782	0.5510
stacking	270	30	40	33	0.8123	0.5238	0.4521	0.9000	0.9000	0.4853	0.7890	0.5499
adaboost	283	17	43	30	0.8391	0.6383	0.4110	0.9433	0.9433	0.5000	0.7735	0.5443
knn	280	20	48	25	0.8177	0.5556	0.3425	0.9333	0.9333	0.4237	0.8008	0.5389
random_forest	279	21	44	29	0.8257	0.5800	0.3973	0.9300	0.9300	0.4715	0.7814	0.5240
slp	268	32	38	35	0.8123	0.5224	0.4795	0.8933	0.8933	0.5000	0.7420	0.4963
decision_tree	282	18	48	25	0.8231	0.5814	0.3425	0.9400	0.9400	0.4310	0.6916	0.3844
perceptron	255	45	68	5	0.6971	0.1000	0.0685	0.8500	0.8500	0.0813	0.2626	0.1328

ข.3 Walk-forward และ feature importance ของแบบ non_spike

ตารางที่ ข.6 Average precision ของ walk-forward ภายใน Train แบบ non_spike

model	fold_0_ap	fold_1_ap	fold_2_ap	fold_3_ap	folds_used	positives	pooled_ap	pooled_low	pooled_high
stacking	n/a	0.5782	0.6482	0.4522	3	191	0.5666	0.4375	0.6853
gaussian_nb	0.3405	0.5518	0.6727	0.4235	4	211	0.5578	0.4271	0.6590
random_forest	0.3386	0.5408	0.6765	0.4222	4	211	0.5425	0.4098	0.6590
knn	0.3376	0.5442	0.7030	0.4203	4	211	0.5417	0.3957	0.6603
logistic	0.2622	0.4996	0.6770	0.4000	4	211	0.5399	0.4019	0.6477
xgboost	0.3175	0.5037	0.7020	0.3927	4	211	0.5238	0.3871	0.6469
gradient_boosting	0.3800	0.4836	0.6528	0.4287	4	211	0.5234	0.3883	0.6430
slp	0.3711	0.4578	0.6540	0.3513	4	211	0.5028	0.3635	0.6237
adaboost	0.2976	0.4025	0.6531	0.4130	4	211	0.5020	0.3604	0.6220
mlp	0.2944	0.4208	0.6439	0.3746	4	211	0.4761	0.3448	0.6136
decision_tree	0.1866	0.4120	0.5306	0.4232	4	211	0.4221	0.2996	0.5383
svm	0.1093	0.2361	0.3805	0.4177	4	211	0.2767	0.1913	0.3759
perceptron	0.0740	0.1586	0.4461	0.1975	4	211	0.2347	0.1619	0.3627

ตารางที่ ข.7 Permutation importance เฉลี่ยข้ามโมเดล แบบ non_spike

feature	drop_in_ap_mean	drop_in_ap_std_across_models	rise_in_rmse_mean	rise_in_rmse_std_across_models
return_1d	-0.0005	0.0119	0.0006	0.0011
return_5d	0.0020	0.0086	0.0021	0.0045
historical_volatility_5d	0.0193	0.0174	-0.0001	0.0005
historical_volatility_20d	0.0329	0.0238	0.0007	0.0008
intraday_range	0.0044	0.0165	-0.0002	0.0010
sma_ratio_5_20	0.0125	0.0133	-0.0000	0.0000
rsi_14	0.0261	0.0250	0.0001	0.0005
volume_zscore_20	0.0062	0.0113	-0.0002	0.0004

ภาคผนวก ค หลักฐานการเปิด Test และวิธีทำซ้ำ

ตารางที่ ค.1 ใบรับรองการเปิด Test (`outputs/modeling/finalize_receipt.json`)

รายการ	ค่า
เวลาที่รัน (UTC)	2026-10-11 14:02:01
git revision ขณะรัน	`cb12d22` (working tree สะอาด)
จำนวนแถวของ Test	373 (ช่วงปกติ 319, ช่วงรอบวัน spike 54)
จำนวนโมเดลที่ประเมิน	38
จำนวนรอบ bootstrap	2,000
รันซ้ำ	ไม่มี

วิธีทำซ้ำ ขั้นตอนเต็มอยู่ใน `docs/guides/RUNBOOK.md`

1. ติดตั้งตาม RUNBOOK ข้อ 2 ถึง 5
2. `python -m src.ml.run report --variant with_spike` และ `--variant non_spike`
3. `python -m src.ml.run compare`
4. `python -m src.ml.run analyze --variant with_spike` และ `--variant non_spike`
5. `python -m src.ml.docs_sync`
6. เปิด notebook 03, 04, 05 และ 06

ช่วงความเชื่อมั่นใช้ seed คงที่ จึงได้ค่าเดิมทุกครั้ง คำสั่ง `finalize --allow-test` จะปฏิเสธการรันซ้ำ เพราะ Test ถูกเปิดไปแล้ว

ภาคผนวก ง การทดลอง RBF Kernel Perceptron หลังส่งงาน

ภาคผนวกนี้เป็นผลติดตาม **หลัง** การส่งรายงานหลัก ไม่เปลี่ยนผล 19 โมเดลที่ล็อกไว้ก่อนเปิด Test และไม่ใช้ผล Test ใหม่เลือกค่า hyperparameter โมเดล Perceptron เดิมไม่ลู่เข้าเพราะข้อมูล Train แบ่งด้วยเส้นตรงไม่ได้ จึงเพิ่ม RBF Kernel Perceptron แบบ scratch เป็นการทดลองแยก ใช้ฟีเจอร์และ label เดิม เลือก `gamma` จาก Validation แล้วโหลดโมเดลที่บันทึกไว้เพื่อประเมิน Test โดยไม่ refit

ตารางที่ ง.1 ผล RBF Kernel Perceptron บน Train, Validation และ Test แยกตาม variant

variant	gamma	epoch ที่ไม่มีการอัปเดต	Train ถูก	split	AP	ROC-AUC	accuracy	precision	recall	specificity	F1	[[TN,FP],[FN,TP]]
with_spike	1.0	139	1733/1733	Validation	0.1732	0.6835	0.8140	0.1930	0.3235	0.8635	0.2418	[[291,46],[23,11]]
with_spike	1.0	139	1733/1733	Test	0.4416	0.7826	0.7962	0.4831	0.5890	0.8467	0.5309	[[254,46],[30,43]]
non_spike	0.75	142	1520/1520	Validation	0.1460	0.6533	0.8571	0.0870	0.0588	0.9377	0.0702	[[316,21],[32,2]]
non_spike	0.75	142	1520/1520	Test	0.3728	0.7469	0.7936	0.4000	0.1096	0.9600	0.1720	[[288,12],[65,8]]

ทุก candidate ที่ลองลู่เข้าบน Train และตัวที่เลือกโหลดกลับมาแล้วให้คำทำนาย Validation เหมือนเดิม การลู่เข้าหมายถึงจำแนก **Train** ถูกทุกแถว ไม่รับประกันผลบนข้อมูลใหม่ โดยเฉพาะ `non_spike` ที่จับ positive บน Test ได้เพียง 8 จาก 73 วัน ผล Test นี้เปิดหลังเห็นผลของโมเดลเดิมแล้ว จึงต้องอ่านเป็นการติดตามผลเชิงสำรวจ ไม่ใช่การเปรียบเทียบแบบ blind หรือหลักฐานนัยสำคัญทางสถิติ หลักฐานละเอียดและ receipt แยกอยู่ใน `docs/models/perceptron/KERNEL_EXPERIMENT.md`

ง.1 การตรวจความทนทานและความไม่แน่นอนเพิ่มเติม

ใช้ `gamma` ที่เลือกจาก Validation คงเดิม ทดสอบ expanding-window 4 fold ภายใน Train โดยเว้น 5 วันและ fit scaler เฉพาะประวัติในแต่ละ fold ทุก fold ลู่เข้า ผล pooled AP เท่ากับ 0.5127 [0.4049, 0.6249] สำหรับ `with_spike` และ 0.3987 [0.2899, 0.5231] สำหรับ `non_spike` ช่วง 95% ใช้ moving-block bootstrap 2,000 รอบ ก้อน 20 วัน และไม่ใช้ผล walk-forward เลือกค่า `gamma` ใหม่

บน Test ผลต่าง AP แบบ paired ระหว่าง Kernel กับ Perceptron เส้นตรงเท่ากับ +0.3042 [0.1030, 0.4360] และ +0.2400 [0.0784, 0.3730] ตามลำดับ แต่ผลต่างกับโมเดล headline เดิมยังมีช่วงที่คร่อมศูนย์ทั้งสอง variant จึงยังสรุปว่า Kernel ดีกว่า headline ไม่ได้ ผลแยกช่วง Test แสดงว่า `non_spike` recall ต่ำทั้งช่วง spike-affected (0.1053) และช่วงปกติ (0.1143) แม้ทุก fold บน Train ลู่เข้า

ทำ block-permutation importance บน Validation และตรวจคะแนนจาก support vectors ด้วย RBF kernel ของ scikit-learn แล้ว label ตรงกันทุกแถว การฝึกอิสระแบบคำนวณคะแนนใหม่ทุกครั้งก็ลู่เข้า แต่ `with_spike` หยุดที่ epoch 144 แทน 139 เพราะคะแนนใกล้ศูนย์ไวต่อลำดับการคำนวณ จึงไม่อ้างว่าการอัปเดตตรงกันทุกครั้ง ผลละเอียด, leaderboard เสริมพร้อมช่วงความเชื่อมั่น และกราฟอยู่ใน บันทึกการทดลอง กับ notebook 04/05 ผลนี้ยังเป็นการวิเคราะห์หลังส่งงาน ไม่เปลี่ยนผล 19 โมเดลหลักที่ล็อกไว้