การพยากรณ์ความผันผวนของกองทุน QQQ ล่วงหน้า 5 วันทำการ

QQQ Volatility Forecasting

รายงานโครงงานวิชา 01076641 ภาคเรียนที่ 1 ปีการศึกษา 2569

ผู้จัดทำ: [กรอกชื่อ–นามสกุล และรหัสนักศึกษาของสมาชิกทั้งสองคน]

วันที่จัดทำ: ตุลาคม 2569 (2026)

สารบัญ

สารบัญ 2
บทสรุปสำหรับผู้อ่านที่มีเวลาน้อย 4
1. บทนำและการตั้งปัญหา 4
1.1 ปัญหา 4
1.2 ทำไมเรื่องนี้สำคัญ 5
1.3 คำถามวิจัย 5
1.4 ขอบเขต 5
2. ฟีเจอร์และเหตุผลที่ต้องใช้ Machine Learning 5
2.1 ฟีเจอร์ 8 ตัว 5
2.2 สิ่งที่ข้อมูลบอกเกี่ยวกับฟีเจอร์ 5
2.3 ทำไมต้องใช้ Machine Learning 7
3. การเตรียมข้อมูล 8
3.1 แหล่งข้อมูลและการตรึงข้อมูล 8
3.2 ขั้นตอนเตรียมข้อมูล 8
3.3 การวิเคราะห์ spike 9
3.4 การตรวจสอบความถูกต้องของข้อมูล 10
4. ระเบียบวิธี 10
4.1 โมเดลทั้ง 19 ตัว 10
4.2 ทำไมเขียนเองทั้งหมด 11
4.3 ขั้นตอนการทดลอง 11
4.4 การวัดความไม่แน่นอน 11
4.5 เส้นฐานเปรียบเทียบ (baseline) 12
5. การ implement 12
5.1 Regression 12
5.2 Classification และ Clustering 12
5.3 การยืนยันผลเทียบกับ library 13
5.4 จำนวนรอบการเทรน 13
5.5 Save, load และทดสอบซ้ำ 13
6. โมเดลนอกห้องเรียน 14
6.1 Elastic Net (regression) 14
6.2 AdaBoost (classification) 15
7. ผลการทดลอง 15
7.1 Regression 16
7.2 Classification 17
7.3 ROC และ Precision-Recall 21
7.4 Performance curve 22
7.5 Clustering 23

7.6 ผลบน Test....23
8. Benchmarking และการอภิปราย....28
8.1 โมเดลใดดีที่สุด....28
8.2 คำถามวิจัย: ตัด spike ออกแล้วดีขึ้นหรือไม่....28
8.3 ดีกว่าโมเดลที่สอนในห้องเท่าไร....31
8.4 โมเดลพลาดตรงไหน....33
8.5 ความเสถียรของอันดับข้ามช่วงเวลา....33
9. ข้อจำกัดและงานต่อ....34
10. สรุป....34
ภาคผนวก ก การตั้งค่าที่ถูกเลือกของทุกโมเดล....35
ภาคผนวก ข ตารางเพิ่มเติม....38
ข.1 Validation ของแบบ non_spike....38
ข.2 Metric ครบทุกตัวบน Test....41
ข.3 Walk-forward และ feature importance ของแบบ non_spike....42
ภาคผนวก ค หลักฐานการเปิด Test และวิธีทำซ้ำ....42

บทสรุปสำหรับผู้อ่านที่มีเวลาน้อย

โจทย์ ใช้ข้อมูลราคารายวันของกองทุน QQQ ย้อนหลัง 10 ปี ทำนายว่าอีก 5 วันทำการข้างหน้าตลาดจะผันผวนแค่ไหน ทั้งแบบทำนายเป็นตัวเลข (regression) และแบบทำนายว่า "ผันผวนสูงหรือไม่" (classification)

สิ่งที่ทำ เขียนโมเดล machine learning 19 ตัวด้วย NumPy เองทั้งหมด ยืนยันความถูกต้องเทียบกับ scikit-learn และ XGBoost แล้วทดลองเทรนสองแบบ คือแบบใช้ข้อมูลทั้งหมด และแบบตัดช่วงที่ราคากระชากแรง (spike) ออก เพื่อตอบคำถามว่า spike ช่วยหรือทำร้ายการเรียนรู้ของโมเดล

ผลหลัก (วัดบน Test ซึ่งเปิดดูเพียงครั้งเดียว)

Locked headline models: Validation score, one-shot Test score and the best baseline

task	variant	headline	metric	validation	test	test_low	test_high	rank_on_test	best_baseline	baseline_test	beats_baseline
classification	with_spike	mlp	average_precision	0.2668	0.5991	0.2605	0.7603	1 of 13	baseline_persistence	0.5365	yes
classification	non_spike	random_forest	average_precision	0.3010	0.5240	0.2161	0.6796	10 of 13	baseline_persistence	0.5365	no
regression	with_spike	elastic_net	rmse	0.0668	0.1174	0.0709	0.1746	2 of 4	baseline_train_mean	0.1380	yes
regression	non_spike	elastic_net	rmse	0.0643	0.1230	0.0688	0.1859	3 of 4	baseline_train_mean	0.1400	yes

1. โมเดลทำนายได้ดีกว่าการเดาสุ่มชัดเจน แต่เหนือกว่ากฎง่าย ๆ ที่ไม่ต้องเทรนเพียงเล็กน้อย
2. ยังสรุปไม่ได้ว่าการตัด spike ช่วยหรือทำร้ายโมเดล ผลต่างเล็กกว่าความไม่แน่นอนของการวัด
3. โมเดลทำงานได้ในช่วงตลาดปกติ แต่ภายในช่วงปั่นป่วนแยกวันผันผวนสูงไม่ได้
4. โมเดลที่ซับซ้อนกว่าไม่ได้ดีกว่าโมเดลพื้นฐานที่สอนในห้องอย่างมีนัยสำคัญ

รายงานนี้ตั้งใจรายงานผลตามจริง รวมถึงผลที่ไม่เป็นไปตามที่คาดไว้ และระบุทุกครั้งว่าข้อสรุปใดมีหลักฐานทางสถิติรองรับ ข้อใดเป็นเพียงข้อสังเกต

1. บทนำและการตั้งปัญหา

1.1 ปัญหา

ความผันผวน (volatility) คือขนาดของการแกว่งตัวของราคา เราวัดจากส่วนเบี่ยงเบนมาตรฐานของผลตอบแทนรายวัน แล้วคูณ √252 เพื่อแปลงเป็นหน่วยต่อปี เช่น ค่า 0.20 หมายถึงราคาแกว่งราว 20% ต่อปี

โครงงานนี้พยากรณ์ความผันผวนของ **QQQ** (กองทุน ETF ที่ลงทุนตามดัชนี Nasdaq-100) ล่วงหน้า 5 วันทำการ ในสองรูปแบบ

- **Regression** ทำนายค่าความผันผวนของ 5 วันข้างหน้า (`target_volatility_5d`)
- **Classification** ทำนายว่า 5 วันข้างหน้าจะเป็นช่วง "ผันผวนสูง" หรือไม่ (`target_high_volatility`) โดยนิยามว่าผันผวนสูงเมื่อค่าเกินควอร์ไทล์ที่ 3 (Q75) ของข้อมูลเทรน

1.2 ทำไมเรื่องนี้สำคัญ

ความผันผวนเป็นตัวแปรที่ใช้ตรง ๆ ในงานการเงินสามอย่าง คือการตั้งราคา option การกำหนดขนาดการลงทุน และการบริหารความเสี่ยง การรู้ล่วงหน้าแม้เพียง 5 วันว่าตลาดกำลังเข้าสู่ช่วงปั่นป่วน ช่วยให้ลดขนาดการลงทุนหรือป้องกันความเสี่ยงได้ทัน

1.3 คำถามวิจัย

ตลาดหุ้นมีวันที่ราคากระชากแรงผิดปกติ เช่น ช่วงเดือนมีนาคม 2020 วันเหล่านี้มีจำนวนน้อยแต่มีค่าสุดโต่ง โครงงานนี้ตั้งคำถามว่า

> **การตัดช่วงที่ราคากระชากแรง (spike) ออกจากข้อมูลเทรน ทำให้โมเดลทำนายได้ดีขึ้นหรือแย่ลง**

เราตอบด้วยการทดลองแบบจับคู่: เทรนโมเดลทุกตัวสองครั้ง ครั้งหนึ่งด้วยข้อมูลเทรนเต็ม (`with_spike`) อีกครั้งด้วยข้อมูลเทรนที่ตัดช่วง spike ออก (`non_spike`) แล้ววัดผลบนข้อมูลชุดเดียวกันทุกประการ

1.4 ขอบเขต

ข้อมูลราคารายวัน (Open, High, Low, Close, Volume) ของ QQQ จำนวน 2,512 วันทำการ ตั้งแต่ 31 สิงหาคม 2016 ถึง 28 สิงหาคม 2026 โมเดลใช้เฉพาะข้อมูลราคาและปริมาณซื้อขายย้อนหลัง ไม่ใช้ข่าว ดัชนี VIX หรือปฏิทินเหตุการณ์

2. ฟีเจอร์และเหตุผลที่ต้องใช้ Machine Learning

2.1 ฟีเจอร์ 8 ตัว

ฟีเจอร์ (feature) คือข้อมูลที่ป้อนให้โมเดล ทุกตัวคำนวณจากข้อมูลถึงสิ้นวัน t เท่านั้น โมเดลจึงไม่เห็นอนาคต นิยามอยู่ใน `src/build_features.py`

ฟีเจอร์	นิยาม	เหตุผลที่เลือก
`return_1d`	ผลตอบแทนของวันนี้เทียบกับเมื่อวาน	วันที่ราคาร่วงแรงมักตามด้วยความผันผวน
`return_5d`	ผลตอบแทนสะสม 5 วัน	บอกทิศทางระยะสั้น ตลาดขาลงมักผันผวนกว่าขาขึ้น
`historical_volatility_5d`	ความผันผวนของ 5 วันที่ผ่านมา	ความผันผวนมักต่อเนื่อง ช่วงปั่นป่วนตามด้วยช่วงปั่นป่วน
`historical_volatility_20d`	ความผันผวนของ 20 วันที่ผ่านมา	บอกสภาพตลาดระยะกลาง นิ่งกว่าแบบ 5 วัน
`intraday_range`	(ราคาสูงสุด − ต่ำสุด) ÷ ราคาปิด ของวันนี้	วัดการแกว่งตัวภายในวัน ซึ่งผลตอบแทนรายวันมองไม่เห็น
`sma_ratio_5_20`	ค่าเฉลี่ยราคา 5 วัน ÷ ค่าเฉลี่ย 20 วัน	บอกว่าราคาอยู่เหนือหรือใต้แนวโน้ม
`rsi_14`	ดัชนี RSI 14 วัน	บอกภาวะซื้อมากหรือขายมากเกินไป
`volume_zscore_20`	ปริมาณซื้อขายวันนี้เทียบกับค่าเฉลี่ย 20 วัน	ปริมาณซื้อขายที่ผิดปกติมักมาพร้อมข่าวสำคัญ

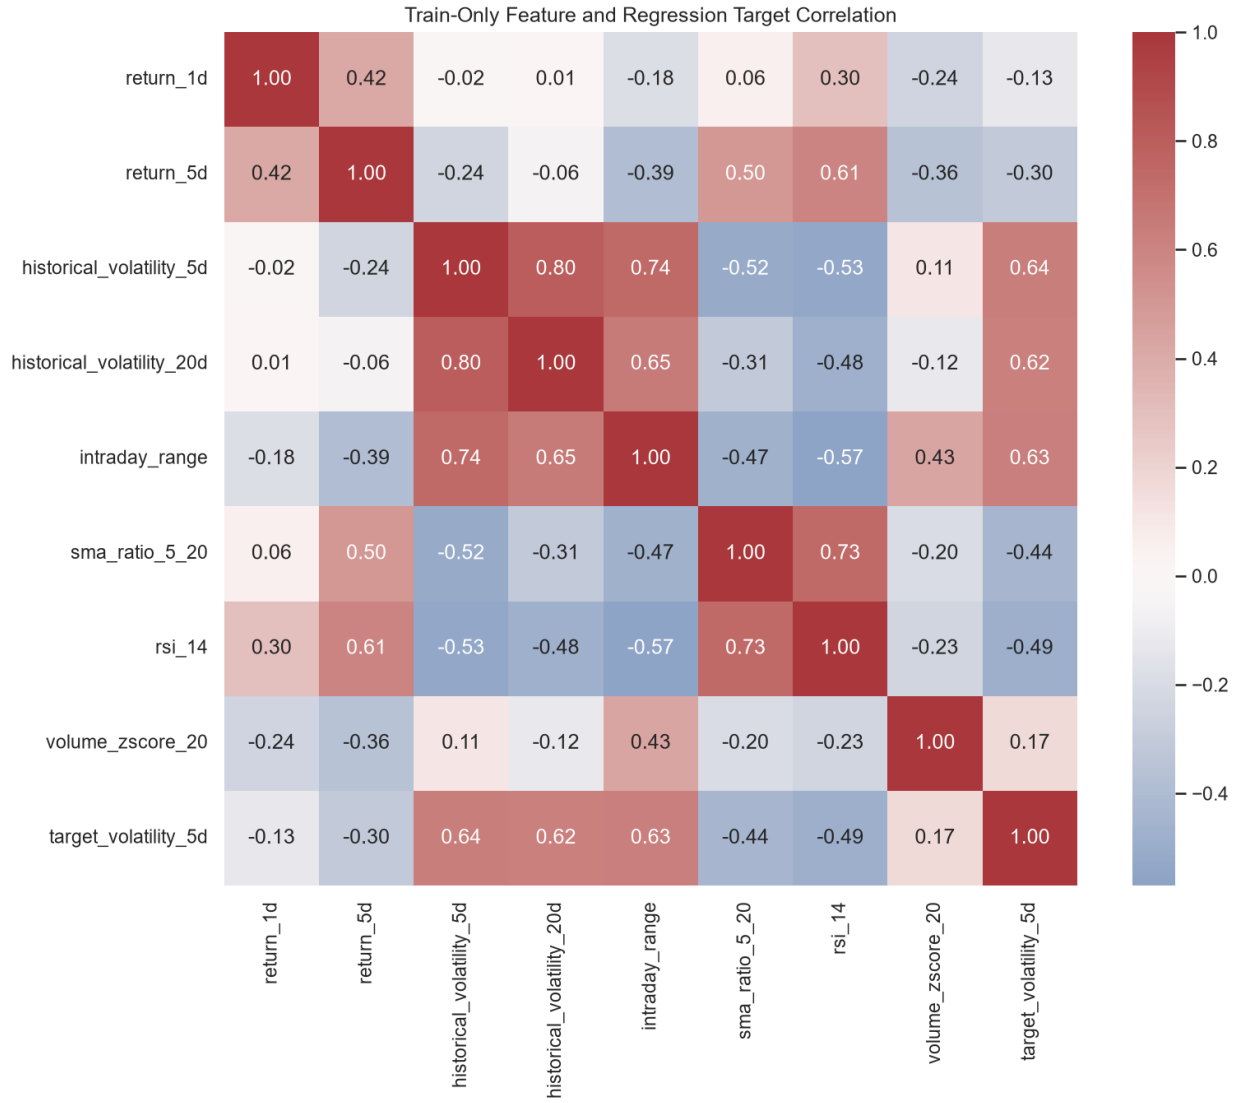
โจทย์กำหนดให้ใช้ฟีเจอร์อย่างน้อย 5 ตัว โครงงานนี้ใช้ 8 ตัว

2.2 สิ่งที่ข้อมูลบอกเกี่ยวกับฟีเจอร์

ความสัมพันธ์กับ target บนข้อมูลเทรน ฟีเจอร์กลุ่มความผันผวนย้อนหลังสัมพันธ์กับ target มากที่สุด: `historical_volatility_5d` (r = 0.64), `intraday_range` (0.63), `historical_volatility_20d` (0.62) รองลงมาคือ `rsi_14` (−0.49) และ `sma_ratio_5_20` (−0.44) ส่วน `return_1d` (−0.13) และ `volume_zscore_20`

(0.17) สัมพันธ์น้อย เครื่องหมายลบของ `rsi_14` และ `sma_ratio_5_20`
สอดคล้องกับข้อเท็จจริงที่ว่าตลาดขาลงผันผวนกว่าขาขึ้น

ฟีเจอร์ซ้ำซ้อนกัน `historical_volatility_5d` กับ `historical_volatility_20d` มีสหสัมพันธ์กัน 0.80 เพราะวัดสิ่งเดียวกันคนละช่วงเวลา ข้อนี้เป็นเหตุผลที่เลือก Elastic Net เป็นโมเดลนอกห้องเรียนฝั่ง regression (หัวข้อ 6.1)



รูปที่ 1 สหสัมพันธ์ระหว่างฟีเจอร์บนข้อมูลเทรน

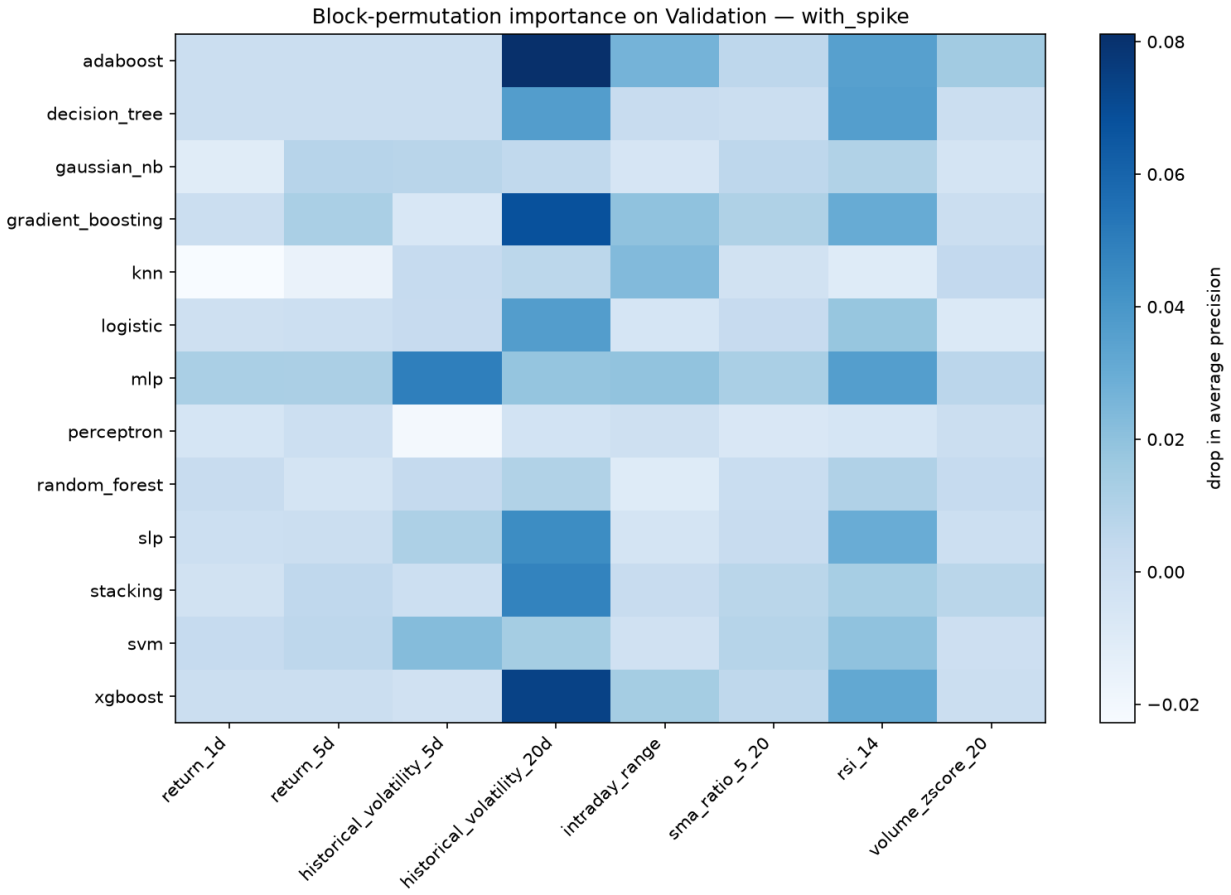
ฟีเจอร์ที่โมเดลใช้จริง เราวัดด้วย permutation importance: สลับลำดับค่าของฟีเจอร์หนึ่งตัวบน Validation เพื่อทำลายข้อมูลในฟีเจอร์นั้น แล้วดูว่าคะแนนของโมเดลแย่ลงเท่าไร ยิ่งแย่ลงมากฟีเจอร์นั้นยิ่งสำคัญ เราสลับเป็นก้อน 20 วันติดกันเพื่อรักษารูปแบบตามเวลา และทำซ้ำ 30 รอบ ตารางถัดไปเฉลี่ยผลข้ามโมเดล

Block-permutation importance averaged over models — with_spike

feature	drop_in_ap_mean	drop_in_ap_std_across_models	rise_in_rmse_mean	rise_in_rmse_std_across_models
return_1d	-0.0019	0.0081	0.0001	0.0001
return_5d	0.0017	0.0074	-0.0001	0.0003
historical_volatility_5d	0.0053	0.0165	-0.0004	0.0007

feature	drop_in_ap_mean	drop_in_ap_std_across_models	rise_in_rmse_mean	rise_in_rmse_std_across_models
historical_volatility_20d	0.0336	0.0282	0.0038	0.0034
intraday_range	0.0060	0.0127	-0.0005	0.0015
sma_ratio_5_20	0.0040	0.0054	0.0002	0.0003
rsi_14	0.0197	0.0155	0.0010	0.0019
volume_zscore_20	0.0017	0.0057	-0.0003	0.0007

`historical_volatility_20d` สำคัญที่สุด ตามด้วย `rsi_14` ส่วน `return_1d` และ `volume_zscore_20` แทบไม่มีผล ค่าในคอลัมน์ `std_across_models` ใหญ่พอ ๆ กับค่าเฉลี่ย แปลว่าโมเดลแต่ละตัวพึ่งฟีเจอร์ต่างกันมาก ข้อจำกัดของวิธีนี้คือ ฟีเจอร์ที่สัมพันธ์กันจะแบ่งความสำคัญกัน เมื่อสลับตัวหนึ่ง อีกตัวยังให้ข้อมูลเดิมได้



รูปที่ 2 Permutation importance ของ classifier แต่ละตัว (with_spike)

2.3 ทำไมต้องใช้ Machine Learning

1. **ความสัมพันธ์ไม่ใช่เส้นตรงและเปลี่ยนตามสภาพตลาด** ความผันผวนกระจุกตัวเป็นช่วง (volatility clustering) และการกระจายของ target เบ้ขวามาก (skewness 2.80, excess kurtosis 16.26)
   ซึ่งต่างจากสมมติฐานของวิธีทางสถิติพื้นฐาน
2. **มีฟีเจอร์หลายตัวที่ทำงานร่วมกัน** เช่น ราคาร่วงพร้อมปริมาณซื้อขายสูงให้ความหมายต่างจากราคาร่วงเฉย ๆ การเขียนกฎ if-then ด้วยมือให้ครอบคลุมทุกกรณีทำได้ยาก
3. **มีข้อมูลพอให้เรียนรู้** 1,733 วันสำหรับเทรน

อย่างไรก็ตาม ผลของโครงงานนี้ให้คำตอบที่ถ่อมตัวกว่าที่คาด: กฎง่าย ๆ ว่า "5 วันข้างหน้าจะผันผวนเท่ากับ 5 วันที่ผ่านมา" ทำได้ใกล้เคียงโมเดลส่วนใหญ่ในงาน classification (หัวข้อ 7 และ 8) ML จึงให้ประโยชน์เพิ่มจริง แต่ไม่มาก เมื่อใช้เพียงข้อมูลราคาย้อนหลัง

3. การเตรียมข้อมูล

3.1 แหล่งข้อมูลและการตรึงข้อมูล

ข้อมูลมาจาก Nasdaq ซึ่งให้ดาวน์โหลดย้อนหลังได้ 10 ปีแบบเลื่อนไปทุกวัน ถ้าดาวน์โหลดใหม่ทุกครั้งที่รัน ข้อมูลจะไม่เหมือนเดิมและทำซ้ำผลไม่ได้ เราจึง **ตรึงข้อมูลชุดเดียว** (snapshot) ไว้ใน repo ที่ `data/raw/qqq_daily.csv` พร้อมบันทึกค่า SHA-256 ใน `data/manifests/qqq_daily_snapshot.json` โปรแกรมจะปฏิเสธการเขียนทับไฟล์นี้

3.2 ขั้นตอนเตรียมข้อมูล

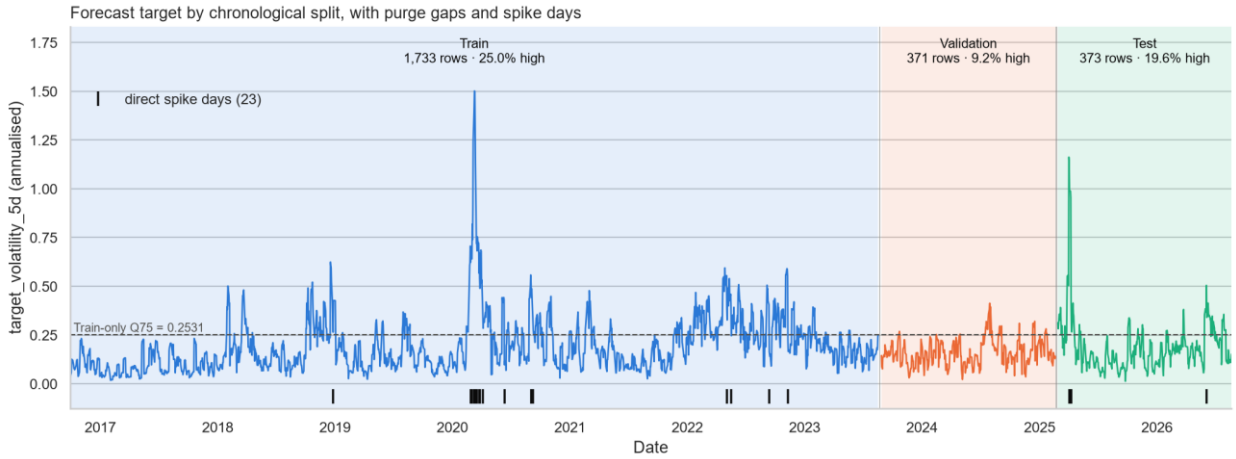
1. **ทำความสะอาด** ตรวจวันที่ซ้ำ ค่าว่าง และความสมเหตุสมผลของราคา
2. **สร้างฟีเจอร์** 8 ตัวจากข้อมูลถึงวัน t
3. **สร้าง target** จากผลตอบแทนของวัน t+1 ถึง t+5
4. **ตัดแถวที่คำนวณไม่ครบ** 20 แถวแรก (ฟีเจอร์ต้องใช้ข้อมูลย้อนหลัง 20 วัน) และ 5 แถวท้าย (target ต้องใช้ข้อมูลอนาคต 5 วัน) เหลือ 2,487 แถว
5. **แบ่งข้อมูลตามเวลา** 70% / 15% / 15%

ชุดข้อมูล	ช่วงวันที่	จำนวนแถว	วันผันผวนสูง	ใช้ทำอะไร
Train	29 ก.ย. 2016 – 18 ส.ค. 2023	1,733	433 (25.0%)	ให้โมเดลเรียนรู้
Validation	28 ส.ค. 2023 – 19 ก.พ. 2025	371	34 (9.2%)	เลือกการตั้งค่าของโมเดล
Test	27 ก.พ. 2025 – 21 ส.ค. 2026	373	73 (19.6%)	วัดผลสุดท้าย ครั้งเดียว

ที่มา: `outputs/reports/data_split_report.json` และ `docs/audit/DATA_FLOW.md`

ทำไมไม่สุ่มแบ่งข้อมูล ถ้าสุ่ม วันในอนาคตจะปนเข้าไปในข้อมูลเทรน โมเดลจะ "เห็นอนาคต" และได้คะแนนสูงเกินจริง (look-ahead leakage) เราจึงแบ่งตามลำดับเวลา และ **เว้นช่องว่าง 5 วันทำการ** (purge gap) ระหว่างชุด เพราะ target ของวันสุดท้ายในชุดหนึ่งใช้ข้อมูลของ 5 วันถัดไป ซึ่งมิฉะนั้นจะซ้อนกับชุดถัดไป

เส้นแบ่ง "ผันผวนสูง" คือ Q75 ของ target บน Train เท่านั้น ได้ค่า 0.2531 แล้วใช้เส้นเดียวกันกับ Validation และ Test สัดส่วนวันผันผวนสูงของสองชุดหลังจึงไม่ใช่ 25% และต่างกันเอง ซึ่งมีผลต่อการอ่านคะแนน (หัวข้อ 7.6)

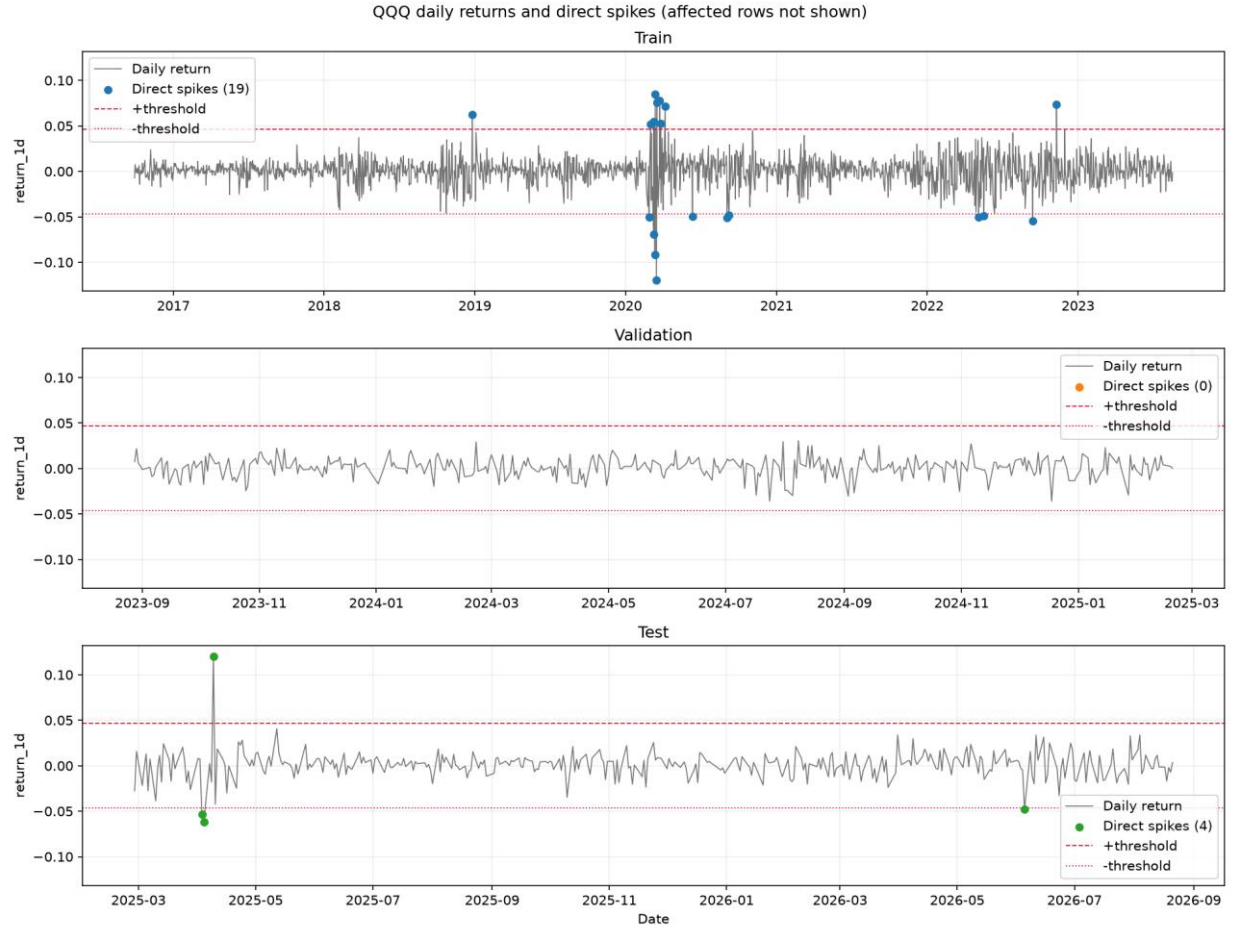


รูปที่ 3 ค่า target ตามเวลา การแบ่งข้อมูล ช่องว่างระหว่างชุด และวันที่เกิด spike

3.3 การวิเคราะห์ spike

นิยาม วันที่ขนาดของผลตอบแทนรายวันเกิน Q3 + 3 × IQR ของข้อมูลเทรน ได้เส้นแบ่งที่ 4.65% เส้นนี้คำนวณจาก Train เท่านั้น

ผลการตรวจ พบ spike 23 วัน: Train 19 วัน (11 วันอยู่ในช่วงกุมภาพันธ์ถึงเมษายน 2020), Validation 0 วัน, Test 4 วัน (3 วันในเดือนเมษายน 2025 และ 1 วันในเดือนมิถุนายน 2026) ที่มา: `outputs/reports/spike_event_audit.csv`

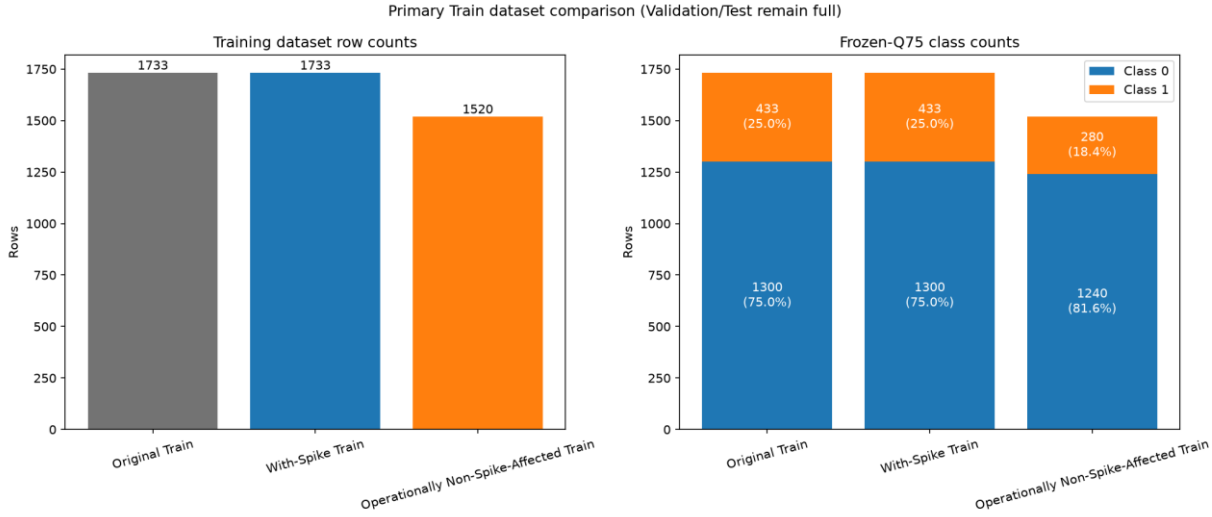


รูปที่ 4 ผลตอบแทนรายวันและวันที่ถูกจัดเป็น spike

การสร้างชุดข้อมูลแบบไม่มี spike spike หนึ่งวันกระทบแถวรอบข้างด้วย เพราะฟีเจอร์ย้อนหลัง 20 วันและ target ล่วงหน้า 5 วันของแถวใกล้เคียงใช้ผลตอบแทนของวันนั้น เราจึงตัดทั้งหน้าต่าง ตั้งแต่ 5 วันก่อนถึง 19 วันหลังวัน spike รวม 213 แถว ชุด `non_spike` จึงมีข้อมูลเทรน 1,520 แถว

สิ่งสำคัญสองข้อของการออกแบบ

- ตัดเฉพาะข้อมูล **เทรน** ส่วน Validation และ Test เหมือนกันทั้งสองแบบ จึงเทียบกันได้ตรง ๆ
- แถวที่ถูกตัด 213 แถว เป็นวันผันผวนสูงถึง 153 แถว (71.8%) การตัดจึงเปลี่ยนสามอย่างพร้อมกัน: จำนวนแถว (1,733 เป็น 1,520), สัดส่วนวันผันผวนสูง (25.0% เป็น 18.4%) และช่วงตลาดที่โมเดลได้เห็น ผลต่างระหว่างสองแบบจึงเป็นผลของ **นโยบายตัดแถวทั้งชุด** เราแยกไม่ได้ว่ามาจากตัว spike เอง หรือจากสองปัจจัยที่เหลือ



รูปที่ 5 เปรียบเทียบข้อมูลเทรนสองแบบ

3.4 การตรวจสอบความถูกต้องของข้อมูล

ก่อนสรุปผล เราตรวจสอบสายการเตรียมข้อมูลทั้งหมด (`docs/audit/DATA_PIPELINE_AUDIT.md`) ข้อสรุปคือข้อมูลใช้เทรนได้อย่างปลอดภัย ไม่มีการรั่วของข้อมูลอนาคต การตรวจที่สำคัญถูกเขียนเป็น test อัตโนมัติใน `tests/test_audit_guards.py` เช่น

- ตัดข้อมูลอนาคตออกแล้วคำนวณฟีเจอร์ใหม่ ค่าของวันในอดีตต้องไม่เปลี่ยน
- เส้นแบ่ง Q75 และเส้นแบ่ง spike ต้องคำนวณจาก Train เท่านั้น แม้จะแก้ค่าใน Validation หรือ Test
- ไม่มีโค้ดส่วนใดสุ่มสลับลำดับข้อมูล และมีเพียง 3 ไฟล์ที่อ้างถึง Test ได้

4. ระเบียบวิธี

4.1 โมเดลทั้ง 19 ตัว

งาน	โมเดล	จำนวน
Regression	Simple Linear, Multiple Linear, Polynomial, **Elastic Net ★**	4

งาน	โมเดล	จำนวน
Classification	Logistic Regression, Gaussian Naive Bayes, k-Nearest Neighbors, Perceptron, Single-Layer Perceptron, Multi-Layer Perceptron, Decision Tree, Random Forest, Gradient Boosting, XGBoost, **AdaBoost ★**, Stacking, Support Vector Machine	13
Clustering	k-Means, Agglomerative	2

★ คือโมเดลนอกเนื้อหาที่สอน ซึ่งอธิบายกลไกอย่างละเอียดในหัวข้อ 6 การตั้งค่าที่ถูกเลือกของทุกโมเดลอยู่ในภาคผนวก ก

4.2 ทำไมเขียนเองทั้งหมด

โจทย์กำหนดให้เขียนโมเดลเอง (from scratch) และอนุญาตให้ใช้ library เพื่อยืนยันผลเท่านั้น โมเดลทั้ง 19 ตัวจึงเขียนด้วย NumPy ล้วนใต้ `src/ml/` ทุกตัวมี interface เดียวกัน (`fit`, `predict`, `state_dict`, `load_state`, `reference`) เพื่อให้เทรน บันทึก โหลด และเทียบกับ library ได้ด้วยโค้ดชุดเดียว

4.3 ขั้นตอนการทดลอง

1. **เทรนบน Train** ของแต่ละแบบ (`with_spike` หรือ `non_spike`) การปรับสเกลข้อมูล (standardize) และ PCA คำนวณจาก Train เท่านั้น
2. **เลือกการตั้งค่าบน Validation** ลองทุกค่าใน grid แล้วเลือกชุดที่ได้คะแนนดีที่สุด: regression ใช้ RMSE, classification ใช้ average precision (AP)
3. **ไม่ปรับ threshold** classifier ตัดสินที่ความน่าจะเป็น 0.5 คงที่ เพื่อไม่เพิ่มการเลือกบน Validation อีกชั้น
4. **ล็อกก่อนเปิด Test** บันทึก hash ของไฟล์โมเดลทั้ง 38 ชุดและชื่อ "โมเดลตัวแทน" (headline) ของแต่ละงานลง `outputs/modeling/selection_lock.json` แล้ว commit
5. **เปิด Test ครั้งเดียว** ไม่เทรนใหม่บน Train+Validation และไม่เปลี่ยนอะไรหลังเห็นผล โปรแกรมบันทึกใบรับรอง `outputs/modeling/finalize_receipt.json` และปฏิเสธการรันซ้ำ

metric หลัก

- **RMSE** (regression): ขนาดความผิดพลาดเฉลี่ย ยิ่งต่ำยิ่งดี
- **Average precision หรือ AP** (classification): คุณภาพของการจัดอันดับวันที่น่าจะผันผวนสูง ยิ่งสูงยิ่งดี ค่าของการเดาสุ่มเท่ากับสัดส่วนวันผันผวนสูงของชุดนั้น เราใช้ AP แทน accuracy เพราะคลาสไม่สมดุล (หัวข้อ 7.2)

4.4 การวัดความไม่แน่นอน

target ของวันติดกันใช้ผลตอบแทนช่วงเดียวกัน 4 ใน 5 วัน ค่าของวันติดกันจึงคล้ายกันมาก (autocorrelation ที่ lag 1 เท่ากับ 0.92) ข้อมูล 371 แถวจึงมีข้อมูลจริงเทียบเท่าตัวอย่างอิสระเพียงราว 50 ถึง 200 ตัว

เราจึงคำนวณช่วงความเชื่อมั่น 95% ด้วย **moving-block bootstrap**: สุ่มข้อมูลซ้ำเป็นก้อน 20 วันติดกัน 2,000 รอบ แทนการสุ่มทีละวันซึ่งจะให้ช่วงแคบเกินจริง

การเปรียบเทียบสองโมเดลใช้แบบ **จับคู่ (paired)**: คำนวณผลต่างบนแถวที่สุ่มชุดเดียวกันทุกรอบ ถ้าช่วง 95% ของผลต่าง **คร่อมศูนย์** ถือว่ายังบอกไม่ได้ว่าโมเดลใดดีกว่า กฎข้อนี้ใช้ตลอดทั้งรายงาน

4.5 เส้นฐานเปรียบเทียบ (baseline)

ตัวเลขคะแนนเดี่ยว ๆ บอกไม่ได้ว่าดีหรือแย่ เราจึงเทียบกับกฎที่ไม่ต้องเทรน

ชื่อ	งาน	กฎ
`baseline_train_mean`	regression	ทายค่าเฉลี่ยของ target ใน Train ทุกวัน
`baseline_persistence`	regression	ทายว่า 5 วันข้างหน้าจะผันผวนเท่ากับ 5 วันที่ผ่านมา
`baseline_majority`	classification	ทายว่า "ไม่ผันผวนสูง" ทุกวัน
`baseline_persistence`	classification	ใช้ความผันผวน 5 วันที่ผ่านมาเป็นคะแนนโดยตรง

5. การ implement

5.1 Regression

- **Simple Linear** เส้นตรงจากฟีเจอร์เดียว แก้ด้วยสูตรปิด โปรแกรมลองทั้ง 8 ฟีเจอร์แล้วเลือกตัวที่ดีที่สุด
- **Multiple Linear** เส้นตรงจากทั้ง 8 ฟีเจอร์ แก้ด้วย least squares
- **Polynomial** ยกกำลังฟีเจอร์เดียว (ดีกรี 2 หรือ 3) แล้วทำ linear regression
- **Elastic Net ★** linear regression ที่มีค่าปรับ L1 และ L2 (หัวข้อ 6.1)

5.2 Classification และ Clustering

- **Logistic Regression** แปลงผลรวมถ่วงน้ำหนักเป็นความน่าจะเป็นด้วย sigmoid เทรนด้วย gradient descent
- **Gaussian Naive Bayes** สมมติว่าแต่ละฟีเจอร์กระจายแบบปกติและอิสระต่อกันภายในคลาส แล้วใช้กฎของ Bayes
- **k-Nearest Neighbors** ดูคลาสของเพื่อนบ้านที่ใกล้ที่สุด k ตัว ถ่วงน้ำหนักด้วยระยะทาง
- **Perceptron** ปรับน้ำหนักเมื่อทายผิด ลู่เข้าเฉพาะเมื่อข้อมูลแยกด้วยเส้นตรงได้
- **Single-Layer Perceptron (SLP)** โหนด sigmoid หนึ่งชั้น เทรนแบบ mini-batch
- **Multi-Layer Perceptron (MLP)** โครงข่ายประสาทที่มีชั้นซ่อน ใช้ ReLU และ backpropagation
- **Decision Tree** แบ่งข้อมูลด้วยคำถามทีละข้อ เลือกคำถามที่ลด Gini impurity มากที่สุด
- **Random Forest** ต้นไม้หลายต้นจากข้อมูลที่สุ่มซ้ำและสุ่มฟีเจอร์ แล้วเฉลี่ยผล (ทดลองร่วมกับ PCA ตามโจทย์)
- **Gradient Boosting** ต้นไม้ต่อกันทีละต้น แต่ละต้นแก้ความผิดพลาดของต้นก่อนหน้า
- **XGBoost** gradient boosting ที่ใช้อนุพันธ์อันดับสองและมี regularization
- **AdaBoost ★** โมเดลอ่อนต่อกัน โดยเพิ่มน้ำหนักให้ตัวอย่างที่ทายผิด (หัวข้อ 6.2)
- **Stacking** ใช้คำทำนายของโมเดลฐานหลายตัวเป็น input ของโมเดลชั้นบน โดยสร้างคำทำนายแบบ out-of-fold ตามลำดับเวลาเพื่อกันข้อมูลรั่ว
- **Support Vector Machine** หาเส้นแบ่งที่มีระยะขอบกว้างที่สุด (linear kernel ทดลองร่วมกับ PCA ตามโจทย์)
- **k-Means** และ **Agglomerative** จัดกลุ่มวันที่มีฟีเจอร์คล้ายกันโดยไม่ใช้ label

5.3 การยืนยันผลเทียบกับ library

ทุกโมเดลมีเมธอด `reference()` ที่สร้างโมเดลของ scikit-learn หรือ XGBoost ด้วยการตั้งค่าเดียวกัน test ของแต่ละโมเดลเทรนทั้งสองฝั่งบนข้อมูลเดียวกันแล้วเทียบคำทำนายทีละแถว

กลุ่มโมเดล	ผลต่างจาก library บน Validation
`simple_linear`, `multiple_linear`, `polynomial`, `gaussian_nb`, `knn`, `adaboost`, `mlp`	ไม่เกิน 2e-15 (ตรงกันถึงทศนิยมสุดท้ายของ float64)
`perceptron`, `decision_tree`, `random_forest`, `gradient_boosting`, `xgboost`	0 (ตรงกันทุกแถว)
`kmeans`, `agglomerative`	แบ่งกลุ่มตรงกัน 100%
`elastic_net`	ไม่เกิน 3e-06 (ใช้กฎหยุดวนรอบต่างจาก scikit-learn)
`svm`	ค่า objective ต่างไม่เกิน 3e-06
`logistic`	ไม่เกิน 1e-03 (หยุดที่ 5,000 รอบ ก่อนลู่เข้าสมบูรณ์)
`slp`	0.07 ถึง 0.29 (หยุดที่โควตา 1,000 รอบ ขณะที่โมเดลอ้างอิงลู่เข้าแล้ว)
`stacking`	ไม่มี library ที่ทำแบบเดียวกัน ตรวจด้วยการสร้าง fold ซ้ำทีละ fold และ test กันข้อมูลรั่ว

ที่มา: `docs/tasks/claude-model-progress.md` และ test ใต้ `tests/ml/`

รายละเอียดที่ทำให้ผลตรงกันได้คือ โมเดลที่มีการสุ่มต้องใช้ตัวสุ่มชนิดเดียวกับ scikit-learn (`numpy.random.RandomState`) และเรียกใช้ตามลำดับเดียวกัน

สามโมเดลที่ผลขึ้นกับโควตาการเทรน `slp`, `perceptron` และ `logistic` หยุดเพราะครบจำนวนรอบที่กำหนด ไม่ใช่เพราะลู่เข้า โดยเฉพาะ `perceptron` ซึ่งไม่มีวันลู่เข้าเมื่อข้อมูลแยกด้วยเส้นตรงไม่ได้ คะแนนของสามตัวนี้จึงเป็นคะแนนของ "อัลกอริทึมภายใต้โควตาที่กำหนด"

5.4 จำนวนรอบการเทรน

แต่ละโมเดลถูกลองหลายการตั้งค่า (grid search) รวม 140 การตั้งค่าต่อแบบข้อมูล หรือ 280 ครั้งของการเทรนสำหรับทั้งสองแบบ เหลือผู้ชนะ 38 ชุด (19 โมเดล × 2 แบบ) ทั้งหมดสั่งรันได้ด้วยคำสั่งเดียว `python -m src.ml.run train --all --variant <variant>` รายการค่าที่ลองอยู่ใน `configs/modeling.json`

5.5 Save, load และทดสอบซ้ำ

โจทย์กำหนดให้บันทึกโมเดล โหลดกลับ แล้วทดสอบซ้ำ เราพิสูจน์สามชั้น

1. ตอนเทรน โปรแกรมบันทึกโมเดลเป็น `model.npz` โหลดกลับทันที แล้วเทียบคำทำนายกับก่อนบันทึก ผลอยู่ใน `load_verification.json` ซึ่งผ่านครบ 38 ชุด
2. test `tests/ml/core/test_artifacts.py` โหลดโมเดลทั้ง 38 ชุดจากดิสก์แล้วทำนาย Validation ใหม่ ต้องได้ค่าเดียวกับที่บันทึกไว้
3. notebook 03 และ 04 ทำซ้ำขั้นตอนเดียวกันให้เห็นเป็นตาราง

ผลบน Test ทั้งหมดในรายงานนี้มาจากโมเดลที่ **โหลดจากไฟล์** ไม่ใช่โมเดลที่ค้างอยู่ในหน่วยความจำ

6. โมเดลนอกห้องเรียน

6.1 Elastic Net (regression)

แนวคิด linear regression ธรรมดาหาน้ำหนัก (coefficient) ที่ทำให้ความผิดพลาดต่ำที่สุดเพียงอย่างเดียว เมื่อฟีเจอร์ซ้ำซ้อนกัน น้ำหนักจะไม่นิ่ง: ขยับข้อมูลเล็กน้อย น้ำหนักเปลี่ยนมาก Elastic Net แก้ด้วยการเพิ่ม "ค่าปรับ" เมื่อน้ำหนักมีขนาดใหญ่

สิ่งที่โมเดลทำให้ต่ำที่สุด

$$J(w) = (1/2n)\cdot\|y - Xw\|^2 + \alpha\cdot\rho\cdot\|w\|_1 + \alpha\cdot(1-\rho)/2\cdot\|w\|^2$$

- พจน์แรกคือความผิดพลาดกำลังสองเฉลี่ย
- α (alpha) คือความแรงของค่าปรับ ยิ่งมากน้ำหนักยิ่งถูกบีบเข้าหาศูนย์
- ρ (l1_ratio) คือสัดส่วนของค่าปรับแบบ L1
- **L1** ($\|w\|_1$ = ผลรวมค่าสัมบูรณ์ของน้ำหนัก) ทำให้น้ำหนักบางตัว **เป็นศูนย์พอดี** เท่ากับคัดฟีเจอร์นั้นทิ้ง
- **L2** ($\|w\|^2$ = ผลรวมกำลังสองของน้ำหนัก) ทำให้น้ำหนักทุกตัวเล็กลงแต่ไม่เป็นศูนย์ และทำให้ฟีเจอร์ที่ซ้ำซ้อนกันแบ่งน้ำหนักกันอย่างนิ่ง

วิธีหาคำตอบ: coordinate descent พจน์ L1 หาอนุพันธ์ที่ศูนย์ไม่ได้ จึงใช้ gradient descent ธรรมดาไม่ได้ เราปรับน้ำหนักทีละตัวโดยตรึงตัวอื่นไว้ ซึ่งมีคำตอบแบบสูตรปิดสำหรับแต่ละตัว

1. คำนวณ ρ_j = ความสัมพันธ์ระหว่างฟีเจอร์ j กับส่วนที่โมเดลยังอธิบายไม่ได้เมื่อไม่นับฟีเจอร์ j
2. ผ่าน **soft-threshold**: $S(v, \gamma) = \text{sign}(v)\cdot\max(|v| - \gamma, 0)$ ถ้า $|\rho_j|$ เล็กกว่า $\alpha\cdot\rho$ น้ำหนักจะกลายเป็นศูนย์ นี่คือกลไกที่คัดฟีเจอร์ทิ้ง
3. หารด้วย $(z_j + \alpha\cdot(1-\rho))$ โดย z_j คือขนาดของฟีเจอร์ j ตัวหารนี้คือจุดที่ L2 ทำงาน
4. วนทุกฟีเจอร์ซ้ำจนน้ำหนักเปลี่ยนน้อยกว่าค่าที่กำหนด

รวมเป็นสูตร: $w_j = S(\rho_j, \alpha\cdot\rho) / (z_j + \alpha\cdot(1-\rho))$ โค้ดอยู่ที่ `src/ml/regression/elastic_net.py`

ทำไมเหมาะกับข้อมูลนี้ ฟีเจอร์ความผันผวนย้อนหลัง 5 วันกับ 20 วันมีสหสัมพันธ์ 0.80 (หัวข้อ 2.2)

ผลที่ได้ การตั้งค่าที่ถูกเลือกคือ α = 0.1 และ l1_ratio = 0.25 ทั้งสองแบบข้อมูล โมเดลดันน้ำหนักเป็นศูนย์ 3 จาก 8 ฟีเจอร์ (`with_spike`) และ 4 จาก 8 (`non_spike`) ที่มา: `outputs/modeling/report/with_spike/linear_coefficients.csv` และ notebook 03 หัวข้อ 5 เมื่อเทียบกับ `ElasticNet` ของ scikit-learn คำทำนายต่างกันไม่เกิน 9e-07 (`with_spike`) และ 3e-06 (`non_spike`)

ผลจริงของ `elastic_net`

variant	split	params	rmse	mae	r2
with_spike	validation (selection score)	{"alpha": 0.1, "l1_ratio": 0.25, "max_iter": 5000, "tol": 1e-06}	0.0668	0.0539	0.0169
with_spike	test (one-shot)	{"alpha": 0.1, "l1_ratio": 0.25, "max_iter": 5000, "tol": 1e-06}	0.1174	0.0731	0.2758
non_spike	validation (selection score)	{"alpha": 0.1, "l1_ratio": 0.25, "max_iter": 5000, "tol": 1e-06}	0.0643	0.0510	0.0906
non_spike	test (one-shot)	{"alpha": 0.1, "l1_ratio": 0.25, "max_iter": 5000, "tol": 1e-06}	0.1230	0.0736	0.2059

6.2 AdaBoost (classification)

แนวคิด AdaBoost สร้างโมเดลอ่อน (weak learner) ต่อกันทีละตัว โดย **ตัวถัดไปตั้งใจแก้จุดที่ตัวก่อนหน้าทำผิด** โมเดลอ่อนที่ใช้คือ decision stump หรือต้นไม้ที่ถามคำถามเดียว เช่น "ความผันผวน 20 วันเกิน 0.25 หรือไม่"

ขั้นตอน (อัลกอริทึม SAMME)

1. ให้น้ำหนักทุกตัวอย่างเท่ากัน `w_i = 1/n`
2. ในรอบที่ m เทรน stump บนข้อมูลที่ถ่วงน้ำหนัก
3. คำนวณความผิดพลาดแบบถ่วงน้ำหนัก `ε_m` = ผลรวมน้ำหนักของตัวอย่างที่ stump ทายผิด
4. คำนวณสิทธิ์ออกเสียงของ stump: `α_m = learning_rate · ln((1 − ε_m) / ε_m)` ยิ่งผิดน้อย สิทธิ์ออกเสียงยิ่งมาก ถ้า `ε_m` เท่ากับ 0.5 (ไม่ดีกว่าเดาสุ่ม) สิทธิ์ออกเสียงจะเป็นศูนย์
5. ปรับน้ำหนักตัวอย่าง: ตัวที่ทายผิดถูกคูณด้วย `exp(α_m)` แล้วปรับให้ผลรวมเป็น 1 stump ตัวถัดไปจึงให้ความสนใจกับตัวอย่างที่ยากมากขึ้น
6. คำตอบสุดท้ายคือผลโหวตถ่วงน้ำหนัก `α_m` ของ stump ทั้งหมด

ทำไมเลือกโมเดลนี้ AdaBoost เทียบเท่ากับการลด exponential loss ซึ่งลงโทษตัวอย่างที่ทายผิดหนัก ๆ แบบทวีคูณ ตัวอย่างสุดโต่งจึงถูกเพิ่มน้ำหนักซ้ำแล้วซ้ำอีก เราตั้งสมมติฐานไว้ก่อนทดลองว่า **AdaBoost น่าจะเป็นโมเดลที่ได้ประโยชน์มากที่สุดเมื่อตัด spike ออก** (ผลอยู่ในหัวข้อ 8.2)

ผลที่ได้ การตั้งค่าที่ถูกเลือกคือ stump 100 ตัว และ learning_rate 0.5 stump ตัวแรกมีความผิดพลาด 0.25 (`with_spike`) ส่วนตัวท้าย ๆ มีความผิดพลาดใกล้ 0.5 และมีสิทธิ์ออกเสียงเล็กมาก เพราะตัวอย่างที่เหลือให้แก้คือตัวอย่างที่ยากจริง ๆ (กราฟอยู่ใน notebook 04 หัวข้อ 8) คำทำนายตรงกับ `AdaBoostClassifier` ของ scikit-learn ทุกแถว

ผลจริงของ `adaboost`

variant	split	params	average_precision	roc_auc	f1	recall	precision	specificity	accuracy
with_spike	validation (selection score)	{"learning_rate": 0.5, "n_estimators": 100, "random_state": 42}	0.2363	0.6768	0.2222	0.1765	0.3000	0.9585	0.8868
with_spike	test (one-shot)	{"learning_rate": 0.5, "n_estimators": 100, "random_state": 42}	0.4858	0.7614	0.4853	0.4521	0.5238	0.9000	0.8123
non_spike	validation (selection score)	{"learning_rate": 0.5, "n_estimators": 100, "random_state": 42}	0.2407	0.6409	0.2353	0.1765	0.3529	0.9674	0.8949
non_spike	test (one-shot)	{"learning_rate": 0.5, "n_estimators": 100, "random_state": 42}	0.5443	0.7735	0.5000	0.4110	0.6383	0.9433	0.8391

7. ผลการทดลอง

หัวข้อ 7.1 ถึง 7.5 เป็นผลบน **Validation** ซึ่งเป็น **selection score** คือการตั้งค่าของทุกโมเดลถูกเลือกบนข้อมูลชุดนี้เอง ตัวเลขจึงดูดีกว่าความเป็นจริงเล็กน้อย ผลที่ไม่ลำเอียงคือผลบน Test ในหัวข้อ 7.6

วิธีอ่านตาราง คอลัมน์ที่ลงท้ายด้วย `_ci` เขียนเป็น ค่า `[ต่ำ, สูง]` คือค่าที่วัดได้และช่วงความเชื่อมั่น 95% · `tied_with_leader = yes` คือแยกจากอันดับหนึ่งไม่ได้ทางสถิติ · `beats_best_baseline` คือคะแนนดีกว่า baseline ตัวที่ดีที่สุดหรือไม่

7.1 Regression

Validation leaderboard — regression — with_spike

model	kind	rmse_ci	mae	r2_ci	tied_with_leader	beats_best_baseline
elastic_net	model	0.0668 [0.0610, 0.0739]	0.0539	0.0169 [-0.2649, 0.2159]	yes	yes
multiple_linear	model	0.0689 [0.0617, 0.0779]	0.0542	-0.0446 [-0.3994, 0.2085]	yes	yes
simple_linear	model	0.0690 [0.0609, 0.0789]	0.0557	-0.0498 [-0.2829, 0.0997]	yes	yes
polynomial	model	0.0691 [0.0606, 0.0797]	0.0552	-0.0507 [-0.2579, 0.0879]	yes	yes
baseline_train_mean	baseline	0.0751 [0.0673, 0.0837]	0.0623	-0.2430 [-0.6975, -0.0225]	no	n/a
baseline_persistence	baseline	0.0826 [0.0750, 0.0901]	0.0673	-0.5032 [-1.0576, -0.0677]	no	n/a

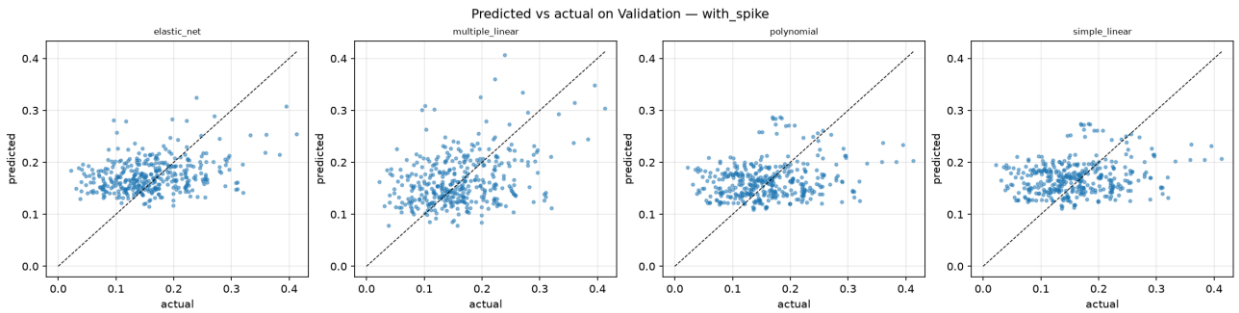
ตัวเลขบน Validation เป็น selection score: hyperparameter ของทุกโมเดลถูกเลือกบนแถวชุดนี้ จึงมองโลกในแง่ดีเกินจริง และโมเดลที่ `tied_with_leader = yes` แยกจากอันดับ 1 ไม่ได้ที่ระดับ 95% (moving-block bootstrap, block 20 วัน) ห้ามอ้างอันดับภายในกลุ่มนั้น 4 จาก 4 โมเดลอยู่ในกลุ่มที่แยกจากอันดับ 1 ไม่ได้

Validation leaderboard — regression — non_spike

model	kind	rmse_ci	mae	r2_ci	tied_with_leader	beats_best_baseline
elastic_net	model	0.0643 [0.0572, 0.0741]	0.0510	0.0906 [-0.0841, 0.2010]	yes	yes
polynomial	model	0.0661 [0.0596, 0.0755]	0.0509	0.0389 [-0.1903, 0.1745]	yes	yes
simple_linear	model	0.0665 [0.0582, 0.0783]	0.0527	0.0265 [-0.1099, 0.0616]	yes	yes
multiple_linear	model	0.0668 [0.0597, 0.0761]	0.0530	0.0165 [-0.2942, 0.2361]	yes	yes
baseline_train_mean	baseline	0.0676 [0.0585, 0.0805]	0.0535	-0.0076 [-0.1436, -0.0000]	yes	n/a
baseline_persistence	baseline	0.0826 [0.0750, 0.0901]	0.0673	-0.5032 [-1.0576, -0.0677]	no	n/a

ตัวเลขบน Validation เป็น selection score: hyperparameter ของทุกโมเดลถูกเลือกบนแถวชุดนี้ จึงมองโลกในแง่ดีเกินจริง และโมเดลที่ `tied_with_leader = yes` แยกจากอันดับ 1 ไม่ได้ที่ระดับ 95% (moving-block bootstrap, block 20 วัน) ห้ามอ้างอันดับภายในกลุ่มนั้น 4 จาก 4 โมเดลอยู่ในกลุ่มที่แยกจากอันดับ 1 ไม่ได้

- โมเดลทั้ง 4 ตัวได้ RMSE ต่ำกว่า baseline ทั้งสองตัว
- ทั้ง 4 ตัวอยู่ในกลุ่มที่แยกจากอันดับหนึ่งไม่ได้ จึงไม่อ้างว่าโมเดลใดดีที่สุด
- **R^2** อยู่ใกล้ศูนย์หรือติดลบ R^2 ติดลบแปลว่าแย่กว่าการทายค่าเฉลี่ยของ Validation เอง สาเหตุคือ Validation สงบกว่า Train มาก (ส่วนเบี่ยงเบนมาตรฐานของ target 0.068 เทียบกับ 0.144) เมื่อค่าจริงแกว่งน้อย การทายค่าเฉลี่ยก็ผิดไม่มาก



รูปที่ 6 ค่าทำนายเทียบค่าจริงบน Validation (with_spike)

7.2 Classification

ทำไมไม่ใช้ accuracy เป็นหลัก Validation มีวันผันผวนสูงเพียง 34 จาก 371 วัน ถ้าทายว่า "ไม่ผันผวนสูง" ทุกวันจะได้ accuracy 90.8% ทั้งที่จับวันผันผวนสูงไม่ได้เลย (แถว `baseline_majority`) เราจึงรายงาน accuracy คู่กับ AP, ROC-AUC, F1 และ recall เสมอ

Validation leaderboard — classification — with_spike

model	kind	average_ precision_ci	roc_auc_ci	f1_ci	recall_ci	precision	specificity	accuracy	loss_name	loss	tied_ with_ leader	beats_best_ baseline
mlp	model	0.2668 [0.0579, 0.4724]	0.6757 [0.3961, 0.8474]	0.3200 [0.0000, 0.5556]	0.2353 [0.0000, 0.4889]	0.5000	0.9763	0.9084	binary_cross_ entropy	0.3359	yes	yes
random_forest	model	0.2548 [0.0603, 0.4586]	0.6862 [0.4634, 0.8323]	0.2917 [0.0000, 0.5051]	0.2059 [0.0000, 0.4255]	0.5000	0.9792	0.9084	log_loss	0.3131	yes	yes
gradient_boosting	model	0.2531 [0.0548, 0.4746]	0.6754 [0.4075, 0.8409]	0.2449 [0.0000, 0.4330]	0.1765 [0.0000, 0.3674]	0.4000	0.9733	0.9003	binary_logistic_loss	0.3075	yes	yes
svm	model	0.2514 [0.0514, 0.4651]	0.6786 [0.4339, 0.8404]	0.2553 [0.0000, 0.4445]	0.1765 [0.0000, 0.3674]	0.4615	0.9792	0.9057	hinge_loss	0.2688	yes	yes
xgboost	model	0.2508 [0.0559, 0.4681]	0.6693 [0.4080, 0.8368]	0.2449 [0.0000, 0.4424]	0.1765 [0.0000, 0.3674]	0.4000	0.9733	0.9003	binary_logistic_loss	0.3263	yes	yes
baseline_ persistence	baseline	0.2474 [0.0545, 0.5002]	0.7214 [0.5384, 0.8407]	0.2899 [0.0000, 0.5589]	0.2941 [0.0000, 0.5601]	0.2857	0.9258	0.8679	n/a	n/a	yes	n/a
slp	model	0.2427 [0.0545, 0.4432]	0.6803 [0.4458, 0.8289]	0.2609 [0.0000, 0.4615]	0.1765 [0.0000, 0.3674]	0.5000	0.9822	0.9084	binary_cross_ entropy	0.3046	yes	no
adaboost	model	0.2363 [0.0626, 0.4381]	0.6768 [0.4602, 0.8196]	0.2222 [0.0000, 0.4226]	0.1765 [0.0000, 0.3674]	0.3000	0.9585	0.8868	exponential_loss	0.5771	yes	no
logistic	model	0.2330 [0.0526, 0.4301]	0.6732 [0.4224, 0.8305]	0.2609 [0.0000, 0.4615]	0.1765 [0.0000, 0.3674]	0.5000	0.9822	0.9084	binary_cross_ entropy	0.3089	yes	no
stacking	model	0.2262 [0.0551, 0.4176]	0.6641 [0.4218, 0.8155]	0.2353 [0.0000, 0.4000]	0.1765 [0.0000, 0.3674]	0.3529	0.9674	0.8949	log_loss	0.3455	yes	no
gaussian_nb	model	0.2218 [0.0464, 0.4333]	0.6665 [0.4217, 0.8214]	0.2812 [0.0000, 0.5001]	0.2647 [0.0000, 0.5228]	0.3000	0.9377	0.8760	log_loss	0.6203	yes	no
knn	model	0.2037 [0.0610, 0.4015]	0.6987 [0.5068, 0.8179]	0.2000 [0.0000, 0.3509]	0.1471 [0.0000, 0.3077]	0.3125	0.9674	0.8922	log_loss	0.6345	yes	no
decision_tree	model	0.1732 [0.0494, 0.3562]	0.6418 [0.4752, 0.7795]	0.3099 [0.0000, 0.5094]	0.3235 [0.0000, 0.5610]	0.2973	0.9228	0.8679	log_loss	0.3350	yes	no
baseline_majority	baseline	0.0916 [0.0350, 0.1779]	0.5000 [0.5000, 0.5000]	0.0000 [0.0000, 0.0000]	0.0000 [0.0000, 0.0000]	n/a	1.0000	0.9084	n/a	n/a	no	n/a
perceptron	model	0.0648 [0.0310, 0.1334]	0.2993 [0.1807, 0.4718]	0.0000 [0.0000, 0.0000]	0.0000 [0.0000, 0.0000]	0.0000	0.9644	0.8760	perceptron_ criterion	0.0008	yes	no

ตัวเลขบน Validation เป็น selection score: hyperparameter ของทุกโมเดลถูกเลือกบนแถวชุดนี้ จึงมองโลกในแง่ดีเกินจริง และโมเดลที่ `tied_with_leader = yes` แยกจากอันดับ 1 ไม่ได้ที่ระดับ 95% (moving-block bootstrap, block 20 วัน) ห้ามอ้างอันดับภายในกลุ่มนั้น

13 จาก 13 โมเดลอยู่ในกลุ่มที่แยกจากอันดับ 1 ไม่ได้

ตารางถัดไปแสดง metric ครบทุกตัวที่โจทย์ระบุ โดย `sensitivity` คือค่าเดียวกับ recall และ `specificity` คือค่าเดียวกับ `tnr` (true negative rate) โจทย์ระบุสองชื่อนี้แยกกัน จึงแสดงทั้งสองคอลัมน์ คอลัมน์ `loss` เทียบข้ามโมเดลที่ใช้ loss ต่างชนิดไม่ได้ (ดู `loss_name`) ค่าของ `adaboost` คือ exponential loss ตัวเดียวกับที่โมเดลลดระหว่างเทรน (เส้นในรูปที่ 10) วัดบน Validation

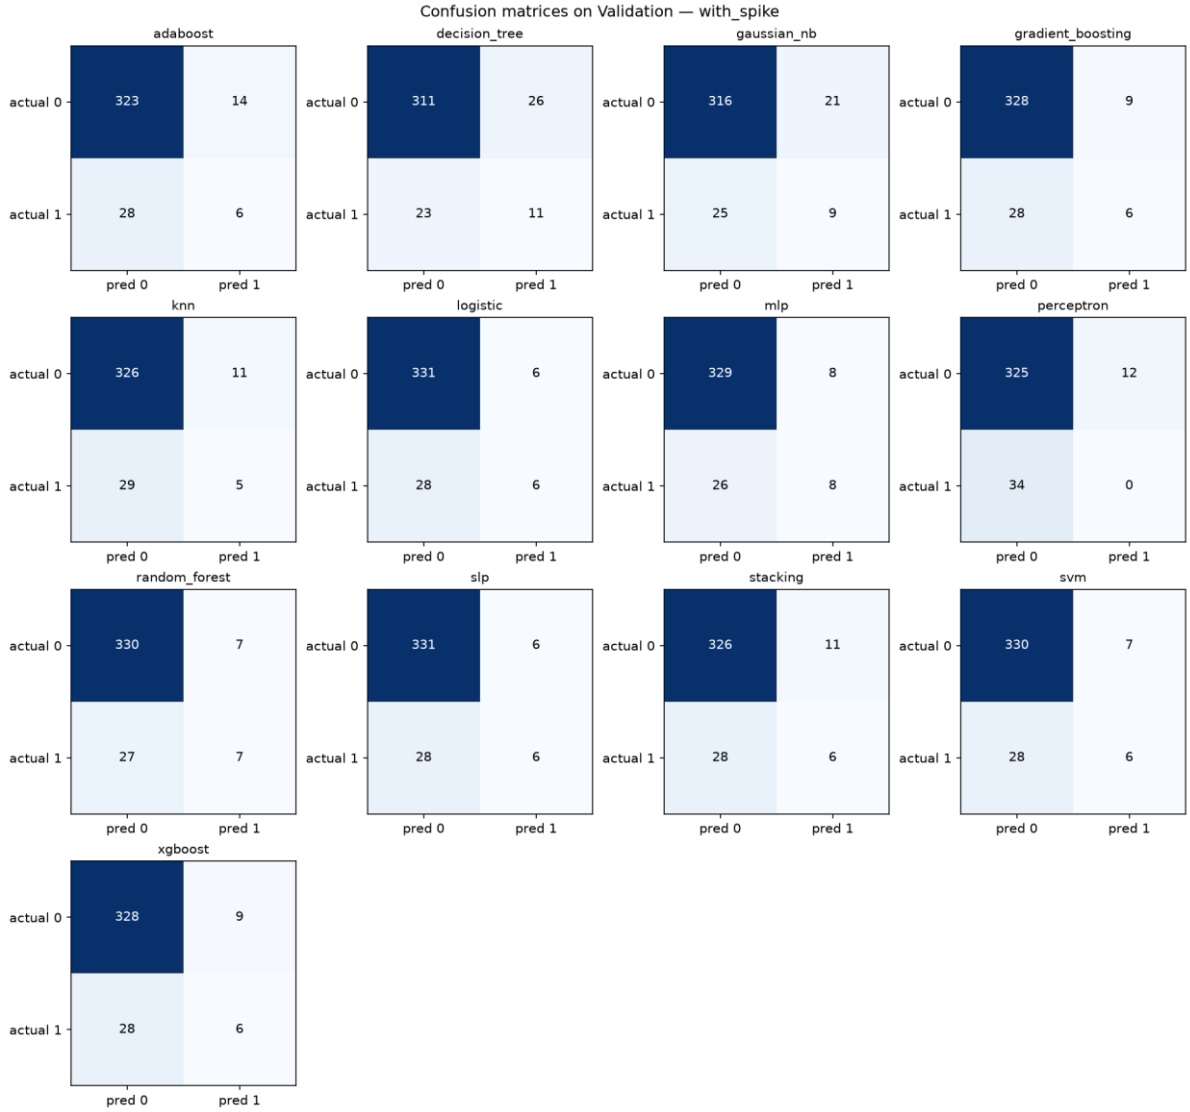
Every metric the assignment lists — Validation — with_spike

model	loss_name	loss	tn	fp	fn	tp	accuracy	precision	sensitivity	specificity	tnr	f1	roc_auc	average_ precision
mlp	binary_cross_entropy	0.3359	329	8	26	8	0.9084	0.5000	0.2353	0.9763	0.9763	0.3200	0.6757	0.2668
random_forest	log_loss	0.3131	330	7	27	7	0.9084	0.5000	0.2059	0.9792	0.9792	0.2917	0.6862	0.2548
gradient_boosting	binary_logistic_loss	0.3075	328	9	28	6	0.9003	0.4000	0.1765	0.9733	0.9733	0.2449	0.6754	0.2531
svm	hinge_loss	0.2688	330	7	28	6	0.9057	0.4615	0.1765	0.9792	0.9792	0.2553	0.6786	0.2514
xgboost	binary_logistic_loss	0.3263	328	9	28	6	0.9003	0.4000	0.1765	0.9733	0.9733	0.2449	0.6693	0.2508
baseline_persistence	n/a	n/a	312	25	24	10	0.8679	0.2857	0.2941	0.9258	0.9258	0.2899	0.7214	0.2474
slp	binary_cross_entropy	0.3046	331	6	28	6	0.9084	0.5000	0.1765	0.9822	0.9822	0.2609	0.6803	0.2427
adaboost	exponential_loss	0.5771	323	14	28	6	0.8868	0.3000	0.1765	0.9585	0.9585	0.2222	0.6768	0.2363
logistic	binary_cross_entropy	0.3089	331	6	28	6	0.9084	0.5000	0.1765	0.9822	0.9822	0.2609	0.6732	0.2330
stacking	log_loss	0.3455	326	11	28	6	0.8949	0.3529	0.1765	0.9674	0.9674	0.2353	0.6641	0.2262
gaussian_nb	log_loss	0.6203	316	21	25	9	0.8760	0.3000	0.2647	0.9377	0.9377	0.2812	0.6665	0.2218
knn	log_loss	0.6345	326	11	29	5	0.8922	0.3125	0.1471	0.9674	0.9674	0.2000	0.6987	0.2037
decision_tree	log_loss	0.3350	311	26	23	11	0.8679	0.2973	0.3235	0.9228	0.9228	0.3099	0.6418	0.1732
baseline_majority	n/a	n/a	337	0	34	0	0.9084	n/a	0.0000	1.0000	1.0000	0.0000	0.5000	0.0916
perceptron	perceptron_criterion	0.0008	325	12	34	0	0.8760	0.0000	0.0000	0.9644	0.9644	0.0000	0.2993	0.0648

สิ่งที่ตารางบอก

- classifier ส่วนใหญ่ได้ AP ราว 0.20 ถึง 0.27 สูงกว่าการเดาสุ่ม (0.092) แต่ช่วงความเชื่อมั่นกว้างมาก (ราว 0.05 ถึง 0.47) เพราะมีวันผันผวนสูงให้วัดเพียง 34 วัน
- **ทั้ง 13 โมเดลแยกจากอันดับหนึ่งไม่ได้** Validation จึงตัดสินผู้ชนะไม่ได้
- `baseline_persistence` ซึ่งไม่ได้เทรนอะไร อยู่กลางตารางด้าน AP และได้ ROC-AUC สูงกว่าทุกโมเดล มีเพียง 5 จาก 13 โมเดลที่ AP สูงกว่า baseline นี้
- โมเดลส่วนใหญ่ทำนายว่าผันผวนสูงน้อยเกินไป (recall 0.15 ถึง 0.32) เพราะเรียนจาก Train ที่ผันผวนกว่า Validation
- `perceptron` ได้ ROC-AUC ต่ำกว่า 0.5 เพราะไม่ลู่เข้า (หัวข้อ 5.3)

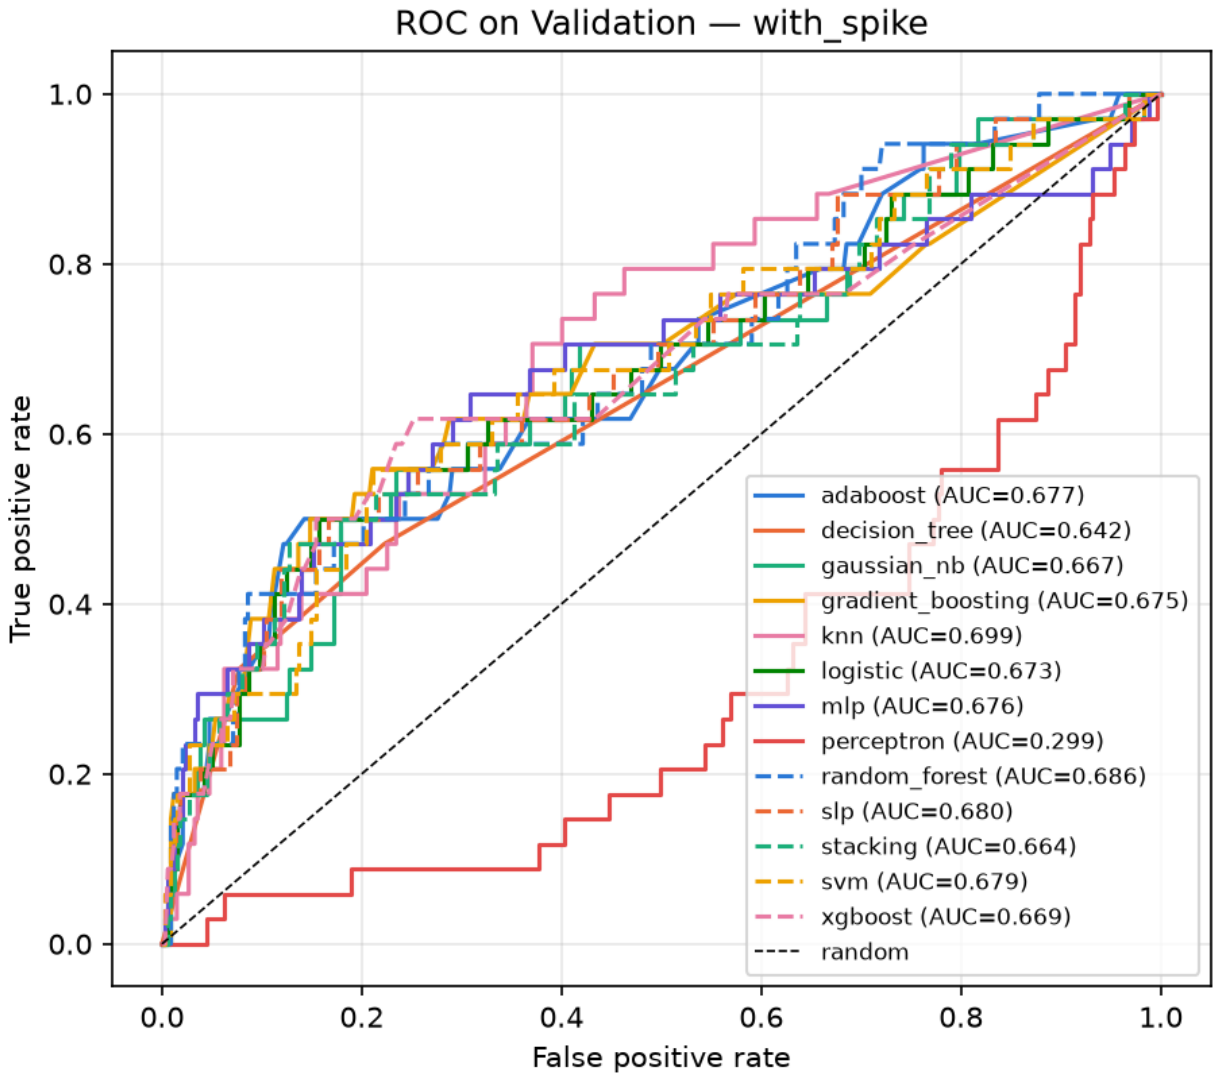
ตารางของแบบ `non_spike` อยู่ในภาคผนวก ข



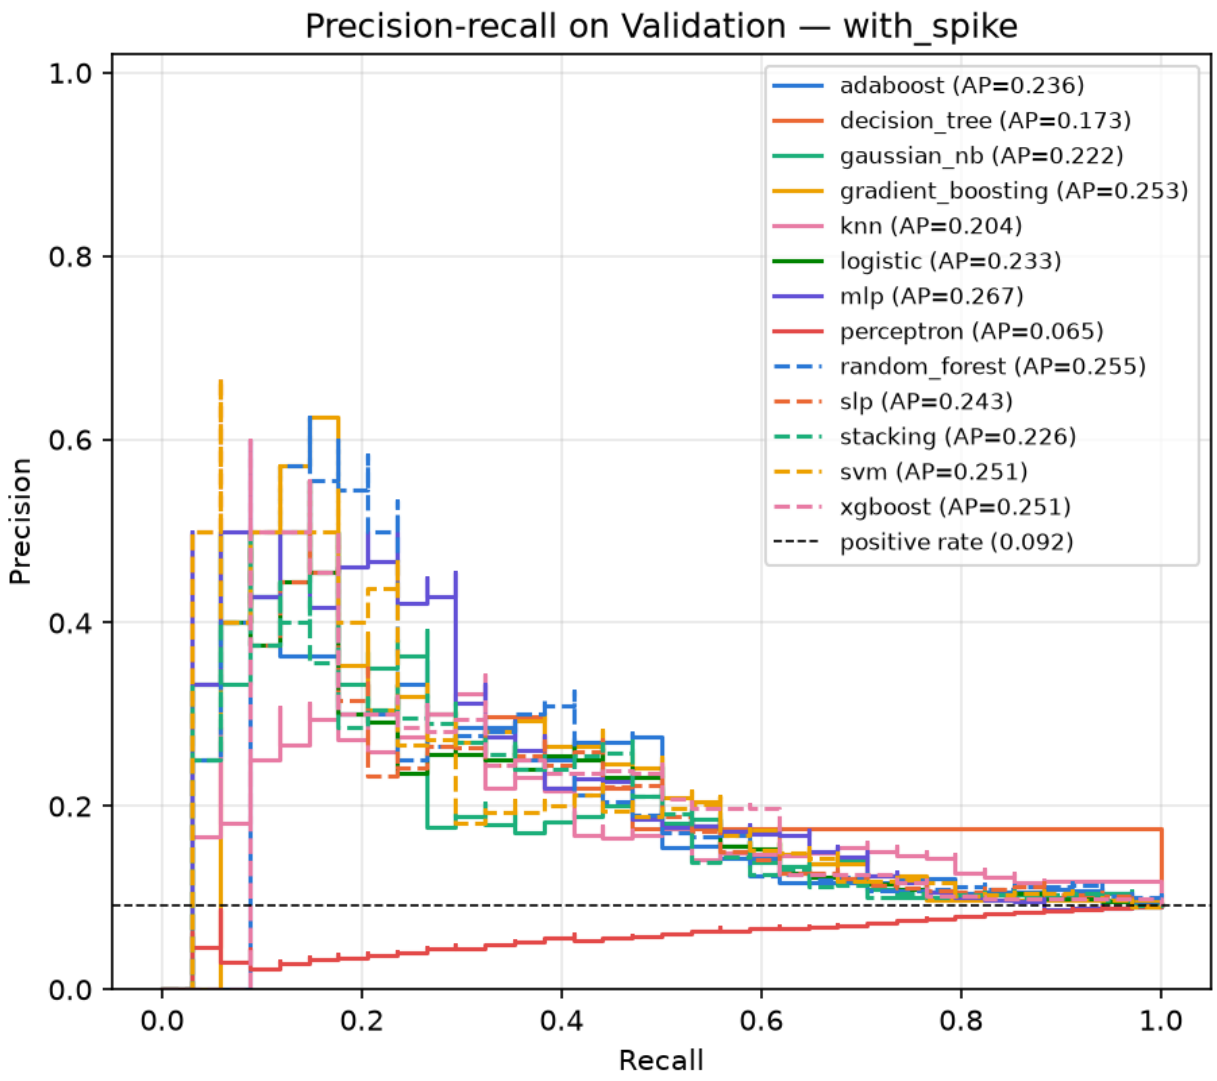
รูปที่ 7 Confusion matrix ของ classifier ทั้ง 13 ตัวบน Validation (with_spike)

7.3 ROC และ Precision-Recall

ROC curve พล็อตอัตราจับได้เทียบกับอัตราเตือนผิดเมื่อไล่ threshold เส้นทแยงคือการเดาสุ่ม พื้นที่ใต้กราฟคือ ROC-AUC **Precision-recall curve** เหมาะกับข้อมูลที่คลาสไม่สมดุลมากกว่า เพราะการเตือนผิดหลายสิบครั้งดูเล็กใน ROC แต่ทำให้ precision ตกชัดเจน



รูปที่ 8 ROC ของ classifier ทั้ง 13 ตัวบน Validation (with_spike)

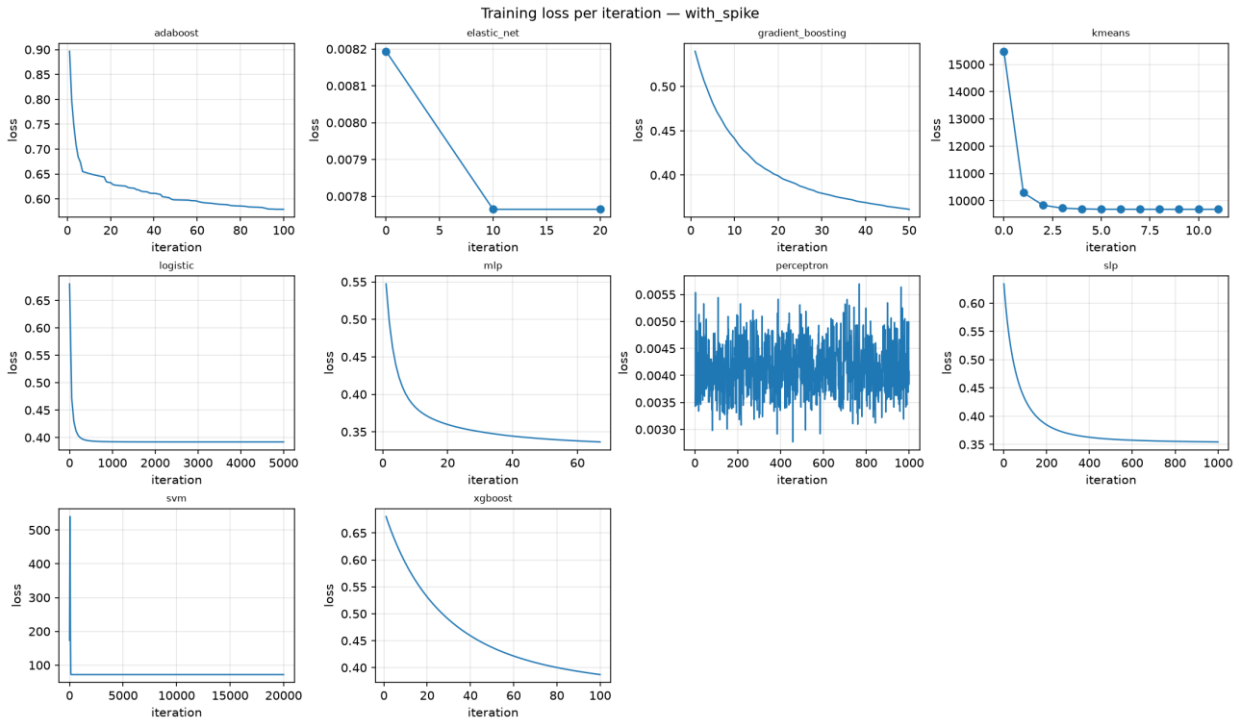


รูปที่ 9 Precision-recall ของ classifier ทั้ง 13 ตัวบน Validation (with_spike)

เส้นของโมเดลส่วนใหญ่เกาะกลุ่มกัน สอดคล้องกับตารางที่ว่าแยกอันดับไม่ได้

7.4 Performance curve

กราฟ loss ระหว่างเทรนของโมเดลที่เรียนแบบวนรอบ เส้นที่ลดลงแล้วราบแปลว่าลู่เข้าแล้ว ส่วน `perceptron` แกว่งไม่ลู่เข้า โมเดลที่ไม่ได้เทรนด้วยการลด loss ทีละรอบ (`knn`, `decision_tree`, `gaussian_nb`, `random_forest`, `stacking`) ไม่มีกราฟ



รูปที่ 10 Loss ระหว่างเทรน (with_spike)

7.5 Clustering

Validation clustering metrics — with_spike

model	variant	k	silhouette	inertia	cluster_sizes
agglomerative	with_spike	2	0.3602	1070.4207	{"0": 293, "1": 78}
kmeans	with_spike	2	0.3666	1075.1372	{"0": 73, "1": 298}

silhouette/inertia คำนวณบน Validation ไม่มีช่วงความเชื่อมั่น

ทั้งสองวิธีเลือกจำนวนกลุ่ม k = 2 และได้ silhouette ราว 0.36 (ค่าอยู่ระหว่าง −1 ถึง 1 ยิ่งสูงกลุ่มยิ่งแยกชัด)
เมื่อเทียบกลุ่มที่ได้กับ label จริงใน notebook 04 หัวข้อ 10 กลุ่มหนึ่งมีสัดส่วนวันผันผวนสูงราว 20% อีกกลุ่มราว 6%
แปลว่าฟีเจอร์เพียงอย่างเดียวแยกสภาพตลาดได้ระดับหนึ่งโดยไม่ต้องมี label ข้อจำกัดคือ Agglomerative
ไม่มีขั้นตอนทำนายข้อมูลใหม่โดยธรรมชาติ เราจึงจัดวันใน Validation เข้ากลุ่มที่จุดศูนย์กลางใกล้ที่สุด

7.6 ผลบน Test

Test ถูกเปิด **ครั้งเดียว** เมื่อ 11 ตุลาคม 2026 หลัง commit ไฟล์ล็อกแล้ว โมเดลทั้งหมดเทรนจาก Train และเลือกบน Validation ไม่มีการเทรนใหม่ ใบรับรองอยู่ในภาคผนวก ค

โมเดลตัวแทนที่ล็อกไว้ คือผู้ที่ได้คะแนนสูงสุดบน Validation ของแต่ละงาน (ตารางในบทสรุป)
การล็อกชื่อไว้ก่อนมีไว้เพื่อไม่ให้เลือกโมเดลย้อนหลังจากผล Test ได้

Test leaderboard — classification — with_spike

model	kind	headline	validation_average_precision	average_precision_ci	roc_auc_ci	f1_ci	recall_ci	tied_with_leader	beats_best_baseline
mlp	model	yes	0.2668	0.5991 [0.2605, 0.7603]	0.7930 [0.6103, 0.9031]	0.5714 [0.2104, 0.6929]	0.4932 [0.1429, 0.6505]	yes	yes

model	kind	headline	validation_average_precision	average_precision_ci	roc_auc_ci	f1_ci	recall_ci	tied_with_leader	beats_best_baseline
random_forest	model	no	0.2548	0.5775 [0.2366, 0.7393]	0.7866 [0.5922, 0.8920]	0.5000 [0.1764, 0.6047]	0.4247 [0.1333, 0.5424]	yes	yes
svm	model	no	0.2514	0.5716 [0.2402, 0.7438]	0.7835 [0.5935, 0.8955]	0.4874 [0.1176, 0.6102]	0.3973 [0.0789, 0.5536]	yes	yes
gaussian_nb	model	no	0.2218	0.5538 [0.2390, 0.7289]	0.7703 [0.5749, 0.8838]	0.5806 [0.3055, 0.6892]	0.6164 [0.3158, 0.7444]	yes	yes
slp	model	no	0.2427	0.5536 [0.2473, 0.7470]	0.7798 [0.5865, 0.8954]	0.5041 [0.1665, 0.6480]	0.4247 [0.1052, 0.6186]	yes	yes
logistic	model	no	0.2330	0.5518 [0.2482, 0.7452]	0.7822 [0.5936, 0.8978]	0.5203 [0.2083, 0.6564]	0.4384 [0.1351, 0.6211]	yes	yes
knn	model	no	0.2037	0.5472 [0.2187, 0.7309]	0.7847 [0.6241, 0.8634]	0.5512 [0.1886, 0.6804]	0.4795 [0.1350, 0.6579]	yes	yes
baseline_persistence	baseline	no	n/a	0.5365 [0.1589, 0.7246]	0.7255 [0.5280, 0.8308]	0.4933 [0.1599, 0.6335]	0.5068 [0.1633, 0.6552]	yes	n/a
gradient_boosting	model	no	0.2531	0.5332 [0.2223, 0.7096]	0.7665 [0.5798, 0.8803]	0.4390 [0.1591, 0.6000]	0.3699 [0.1190, 0.5539]	yes	no
xgboost	model	no	0.2508	0.5305 [0.2021, 0.7067]	0.7716 [0.5844, 0.8839]	0.4553 [0.1795, 0.6078]	0.3836 [0.1333, 0.5582]	yes	no
stacking	model	no	0.2262	0.5131 [0.2395, 0.7154]	0.7902 [0.6082, 0.8877]	0.5714 [0.2898, 0.6842]	0.5753 [0.2439, 0.7385]	yes	no
adaboost	model	no	0.2363	0.4858 [0.2145, 0.6807]	0.7614 [0.5710, 0.8785]	0.4853 [0.2268, 0.6555]	0.4521 [0.1852, 0.6775]	no	no
decision_tree	model	no	0.1732	0.3792 [0.1524, 0.5643]	0.7450 [0.6021, 0.8449]	0.4800 [0.2000, 0.6667]	0.4932 [0.1621, 0.7527]	no	no
baseline_majority	baseline	no	n/a	0.1957 [0.0885, 0.3003]	0.5000 [0.5000, 0.5000]	0.0000 [0.0000, 0.0000]	0.0000 [0.0000, 0.0000]	no	n/a
perceptron	model	no	0.0648	0.1374 [0.0657, 0.2463]	0.2749 [0.1567, 0.4688]	0.0577 [0.0000, 0.1840]	0.0411 [0.0000, 0.1690]	no	no

ประเมินบน Test ครั้งเดียวด้วยโมเดลที่เทรนจาก Train และเลือกบน Validation (ไม่ refit) โมเดลเด่นของแต่ละ task ถูกระบุไว้ใน selection_lock.json ก่อนเปิด Test แถวอื่นในตารางเป็นข้อมูลประกอบ ห้ามเลือกโมเดลจากตารางนี้

Test leaderboard — classification — non_spike

model	kind	headline	validation_average_precision	average_precision_ci	roc_auc_ci	f1_ci	recall_ci	tied_with_leader	beats_best_baseline
gaussian_nb	model	no	0.2292	0.5884 [0.2441, 0.7462]	0.7779 [0.5735, 0.8913]	0.5824 [0.3299, 0.6817]	0.7260 [0.4210, 0.8530]	yes	yes
xgboost	model	no	0.2652	0.5823 [0.2509, 0.7436]	0.7887 [0.6017, 0.8948]	0.5469 [0.2034, 0.7000]	0.4795 [0.1463, 0.6812]	yes	yes
svm	model	no	0.2501	0.5805 [0.2446, 0.7504]	0.7853 [0.5967, 0.8990]	0.4587 [0.0974, 0.5922]	0.3425 [0.0588, 0.5048]	yes	yes
gradient_boosting	model	no	0.2525	0.5653 [0.2460, 0.7310]	0.7861 [0.6087, 0.8920]	0.3762 [0.1290, 0.5264]	0.2603 [0.0789, 0.4000]	yes	yes
mlp	model	no	0.2808	0.5639 [0.2507, 0.7235]	0.7894 [0.5922, 0.8906]	0.5039 [0.2127, 0.6449]	0.4384 [0.1578, 0.6165]	yes	yes
logistic	model	no	0.2513	0.5510 [0.2472, 0.7391]	0.7782 [0.5841, 0.8940]	0.5041 [0.1785, 0.6269]	0.4247 [0.1111, 0.5943]	yes	yes
stacking	model	no	0.2311	0.5499 [0.2440, 0.7150]	0.7890 [0.6135, 0.8828]	0.4853 [0.2432, 0.6016]	0.4521 [0.2057, 0.5843]	yes	yes
adaboost	model	no	0.2407	0.5443 [0.2261, 0.7297]	0.7735 [0.5788, 0.8899]	0.5000 [0.2051, 0.6348]	0.4110 [0.1470, 0.5758]	yes	yes
knn	model	no	0.2082	0.5389 [0.2514, 0.7067]	0.8008 [0.6595, 0.8698]	0.4237 [0.0894, 0.5658]	0.3425 [0.0606, 0.4943]	yes	yes

model	kind	headline	validation_ average_ precision	average_ precision_ci	roc_auc_ci	f1_ci	recall_ci	tied_ with_ leader	beats_ best_ baseline
baseline_ persistence	baseline	no	n/a	0.5365 [0.1589, 0.7246]	0.7255 [0.5280, 0.8308]	0.4933 [0.1599, 0.6335]	0.5068 [0.1633, 0.6552]	yes	n/a
random_forest	model	yes	0.3010	0.5240 [0.2161, 0.6796]	0.7814 [0.5879, 0.8807]	0.4715 [0.1667, 0.5556]	0.3973 [0.1249, 0.4923]	yes	no
slp	model	no	0.2474	0.4963 [0.2080, 0.6769]	0.7420 [0.5497, 0.8583]	0.5000 [0.2564, 0.6053]	0.4795 [0.2143, 0.6164]	no	no
decision_tree	model	no	0.1887	0.3844 [0.1761, 0.5137]	0.6916 [0.5598, 0.7827]	0.4310 [0.2142, 0.5246]	0.3425 [0.1579, 0.4272]	no	no
baseline_ majority	baseline	no	n/a	0.1957 [0.0885, 0.3003]	0.5000 [0.5000, 0.5000]	0.0000 [0.0000, 0.0000]	0.0000 [0.0000, 0.0000]	no	n/a
perceptron	model	no	0.0742	0.1328 [0.0624, 0.2276]	0.2626 [0.1410, 0.4434]	0.0813 [0.0000, 0.2460]	0.0685 [0.0000, 0.2817]	no	no

ประเมินบน Test ครั้งเดียวด้วยโมเดลที่เทรนจาก Train และเลือกบน Validation (ไม่ refit) โมเดลเด่นของแต่ละ task ถูกระบุไว้ใน selection_lock.json ก่อนเปิด Test แถวอื่นในตารางเป็นข้อมูลประกอบ ห้ามเลือกโมเดลจากตารางนี้

Test leaderboard — regression — with_spike

model	kind	headline	validation_ rmse	rmse_ci	r2_ci	tied_ with_ leader	beats_ best_ baseline
multiple_linear	model	no	0.0689	0.1158 [0.0711, 0.1680]	0.2959 [-0.1971, 0.3897]	yes	yes
elastic_net	model	yes	0.0668	0.1174 [0.0709, 0.1746]	0.2758 [-0.0402, 0.3258]	yes	yes
simple_linear	model	no	0.0690	0.1356 [0.0754, 0.1985]	0.0347 [-0.7702, 0.2310]	no	yes
baseline_train_ mean	baseline	no	n/a	0.1380 [0.0806, 0.2060]	-0.0006 [-0.2998, -0.0000]	yes	n/a
polynomial	model	no	0.0691	0.1401 [0.0754, 0.2037]	-0.0314 [-1.1539, 0.2401]	no	no
baseline_ persistence	baseline	no	n/a	0.1502 [0.0919, 0.2222]	-0.1855 [-1.2071, 0.1280]	no	n/a

ประเมินบน Test ครั้งเดียวด้วยโมเดลที่เทรนจาก Train และเลือกบน Validation (ไม่ refit) โมเดลเด่นของแต่ละ task ถูกระบุไว้ใน selection_lock.json ก่อนเปิด Test แถวอื่นในตารางเป็นข้อมูลประกอบ ห้ามเลือกโมเดลจากตารางนี้

Test leaderboard — regression — non_spike

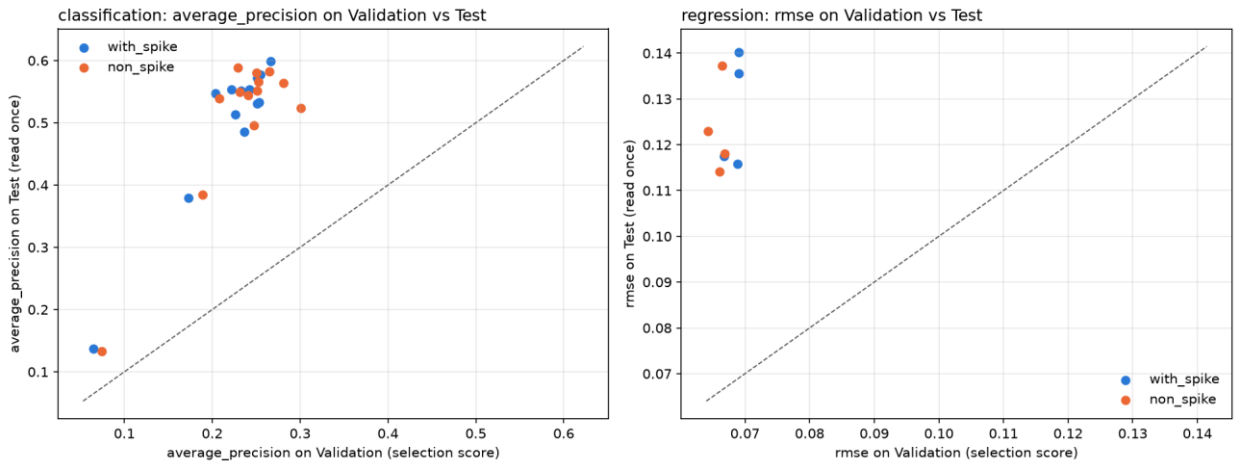
model	kind	headline	validation_ rmse	rmse_ci	r2_ci	tied_ with_ leader	beats_ best_ baseline
polynomial	model	no	0.0661	0.1142 [0.0720, 0.1641]	0.3155 [-0.0360, 0.4224]	yes	yes
multiple_linear	model	no	0.0668	0.1180 [0.0705, 0.1732]	0.2684 [-0.1829, 0.3623]	yes	yes
elastic_net	model	yes	0.0643	0.1230 [0.0688, 0.1859]	0.2059 [0.0554, 0.2619]	yes	yes
simple_linear	model	no	0.0665	0.1372 [0.0733, 0.2087]	0.0114 [-0.1001, 0.0488]	yes	yes

model	kind	headline	validation_rmse	rmse_ci	r2_ci	tied_with_leader	beats_best_baseline
baseline_train_mean	baseline	no	n/a	0.1400 [0.0745, 0.2132]	-0.0298 [-0.1430, -0.0001]	yes	n/a
baseline_persistence	baseline	no	n/a	0.1502 [0.0919, 0.2222]	-0.1855 [-1.2071, 0.1280]	no	n/a

ประเมินบน Test ครั้งเดียวด้วยโมเดลที่เทรนจาก Train และเลือกบน Validation (ไม่ refit) โมเดลเด่นของแต่ละ task ถูกระบุไว้ใน selection_lock.json ก่อนเปิด Test แถวอื่นในตารางเป็นข้อมูลประกอบ ห้ามเลือกโมเดลจากตารางนี้

อ่านผล

1. **Classification** โมเดลตัวแทนของ `with_spike` คือ `mlp` ได้ AP 0.599 และยังเป็นอันดับหนึ่งบน Test เทียบกับการเดาสุ่ม 0.196 และ `baseline_persistence` 0.536 แต่โมเดลตัวแทนของ `non_spike` คือ `random_forest` ได้ AP 0.524 ต่ำกว่า baseline และตกจากอันดับ 1 บน Validation ไปอยู่อันดับ 10 จาก 13 โมเดล นี่คือตัวอย่างของ selection bias: ผู้นำบน Validation ที่มีวันผันผวนสูงเพียง 34 วัน ไม่จำเป็นต้องเป็นผู้นำบนข้อมูลใหม่
2. **Regression** `elastic_net` ได้ RMSE 0.117 และ 0.123 ดีกว่า baseline ที่ทายค่าเฉลี่ย (0.138 และ 0.140) R^2 อยู่ที่ราว 0.2 ถึง 0.3 สูงกว่าบน Validation เพราะ Test มีช่วงผันผวนแรงให้โมเดลอธิบาย
3. **AP บน Test สูงกว่า Validation มาก** (0.6 เทียบกับ 0.27) ข้อนี้ไม่ได้แปลว่าโมเดลเก่งขึ้น AP ขึ้นกับสัดส่วนวันผันผวนสูง ซึ่ง Test มี 19.6% ส่วน Validation มี 9.2% จึงต้องเทียบกับ baseline ของชุดเดียวกันเสมอ



รูปที่ 11 คะแนนของโมเดลเดียวกันบน Validation เทียบกับบน Test

แยกผลตามช่วงตลาด Test มี 54 แถวที่อยู่ในหน้าต่างรอบวัน spike (เดือนเมษายน 2025 และมิถุนายน 2026) และ 319 แถวที่เป็นช่วงปกติ

Test metrics by diagnostic segment — classification

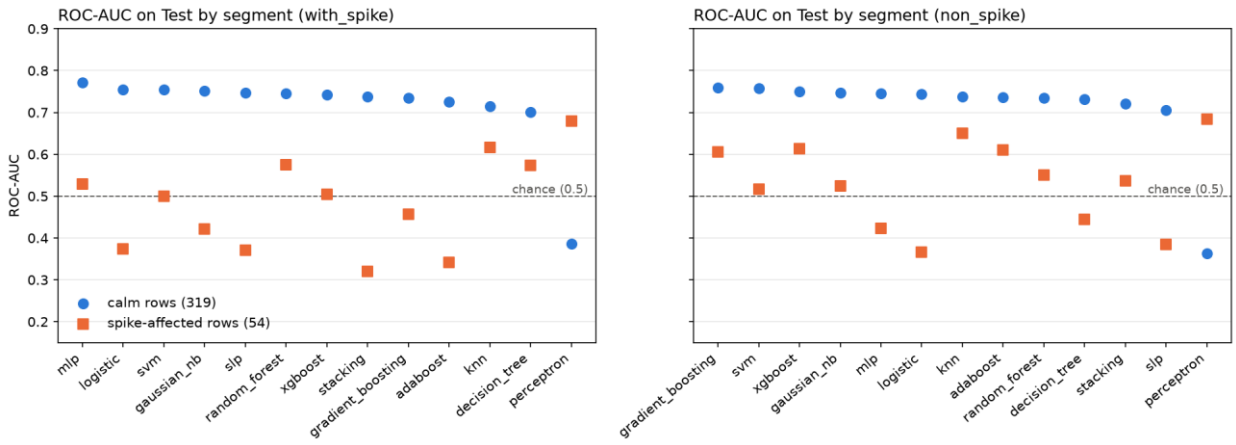
model	variant	segment	rows	positives	average_precision	roc_auc	recall	precision	f1
adaboost	non_spike	non_spike	319	35	0.3372	0.7370	0.3714	0.5200	0.4333
adaboost	non_spike	spike_affected	54	38	0.8281	0.6102	0.4474	0.7727	0.5667
adaboost	with_spike	non_spike	319	35	0.3212	0.7251	0.3429	0.4138	0.3750

model	variant	segment	rows	positives	average_ precision	roc_auc	recall	precision	f1
adaboost	with_spike	spike_affected	54	38	0.6804	0.3413	0.5526	0.6176	0.5833
logistic	non_spike	non_spike	319	35	0.3639	0.7444	0.2000	0.5385	0.2917
logistic	non_spike	spike_affected	54	38	0.7200	0.3668	0.6316	0.6486	0.6400
logistic	with_spike	non_spike	319	35	0.3882	0.7545	0.2286	0.6154	0.3333
logistic	with_spike	spike_affected	54	38	0.7168	0.3734	0.6316	0.6486	0.6400
mlp	non_spike	non_spike	319	35	0.4048	0.7454	0.2857	0.5263	0.3704
mlp	non_spike	spike_affected	54	38	0.7310	0.4227	0.5789	0.6286	0.6027
mlp	with_spike	non_spike	319	35	0.4451	0.7709	0.3429	0.5714	0.4286
mlp	with_spike	spike_affected	54	38	0.7837	0.5296	0.6316	0.7500	0.6857
random_forest	non_spike	non_spike	319	35	0.3898	0.7344	0.3714	0.4815	0.4194
random_forest	non_spike	spike_affected	54	38	0.7664	0.5510	0.4211	0.6957	0.5246
random_forest	with_spike	non_spike	319	35	0.3782	0.7455	0.3429	0.4800	0.4000
random_forest	with_spike	spike_affected	54	38	0.8011	0.5757	0.5000	0.7308	0.5938

Test metrics by diagnostic segment — regression

model	variant	segment	rows	rmse	mae	r2
elastic_net	non_spike	non_spike	319	0.0692	0.0550	0.1752
elastic_net	non_spike	spike_affected	54	0.2759	0.1838	-0.3351
elastic_net	with_spike	non_spike	319	0.0707	0.0564	0.1395
elastic_net	with_spike	spike_affected	54	0.2564	0.1722	-0.1526
multiple_linear	non_spike	non_spike	319	0.0683	0.0525	0.1972
multiple_linear	non_spike	spike_affected	54	0.2620	0.1880	-0.2042
multiple_linear	with_spike	non_spike	319	0.0694	0.0536	0.1714
multiple_linear	with_spike	spike_affected	54	0.2533	0.1819	-0.1253

- **ช่วงปกติ** (วันผันผวนสูง 35 จาก 319 วัน หรือ 11%): classifier ได้ ROC-AUC ราว 0.72 ถึง 0.77 และ AP ราว 0.32 ถึง 0.45 สูงกว่าการเดาสุ่ม (0.11) ซัดเจน regression ได้ RMSE ราว 0.07 ใกล้เคียงกับบน Validation
- **ช่วงรอบวัน spike** (วันผันผวนสูง 38 จาก 54 วัน หรือ 70%): ROC-AUC ของ classifier ในตารางอยู่ระหว่าง 0.34 ถึง 0.61 คือใกล้หรือต่ำกว่าการเดาสุ่ม **ภายในช่วงปั่นป่วน โมเดลแยกไม่ได้ว่าวันไหนจะผันผวนสูง** AP ที่ดูสูง (0.7 ถึง 0.8) มาจากการที่วันส่วนใหญ่ในช่วงนี้ผันผวนสูงอยู่แล้ว ส่วน regression ได้ RMSE ราว 0.25 ถึง 0.28 และ R^2 ติดลบ



รูปที่ 12 ROC-AUC บน Test แยกตามช่วงตลาด

สรุปคือ โมเดลรู้ว่า "ตอนนี้ตลาดกำลังปั่นป่วน" ซึ่งเป็นสิ่งที่ `baseline_persistence` ก็รู้
แต่ไม่รู้ว่าความปั่นป่วนจะเริ่มเมื่อไรหรือจะจบวันไหน ตาราง metric ครบทุกตัวบน Test อยู่ในภาคผนวก ข

8. Benchmarking และการอภิปราย

8.1 โมเดลใดดีที่สุด

คำตอบที่ซื่อตรงคือ **ข้อมูลไม่พอจะบอก** บน Validation ทั้ง 13 classifier และทั้ง 4 โมเดล regression
อยู่ในกลุ่มที่แยกจากอันดับหนึ่งไม่ได้ บน Test กลุ่มนำของ classification ยังมี 10 จาก 13 โมเดลในทั้งสองแบบข้อมูล
สิ่งที่บอกได้คือ

- `perceptron` และ `decision_tree` อยู่ท้ายตารางอย่างสม่ำเสมอ ทั้งบน Validation, Test และ walk-forward
- โมเดลที่เหลือ ตั้งแต่ `logistic` ที่เรียบง่าย ไปจนถึง `xgboost` และ `mlp`
  ทำได้ใกล้เคียงกันในระดับที่ข้อมูลชุดนี้แยกไม่ออก

เหตุผลที่น่าจะเป็นคือ ข้อมูลที่ทำนายได้อยู่ในฟีเจอร์ความผันผวนย้อนหลังไม่กี่ตัว และความสัมพันธ์ค่อนข้างเรียบง่าย
โมเดลที่ซับซ้อนจึงไม่มีอะไรให้เรียนรู้เพิ่มมากนัก

8.2 คำถามวิจัย: ตัด spike ออกแล้วดีขึ้นหรือไม่

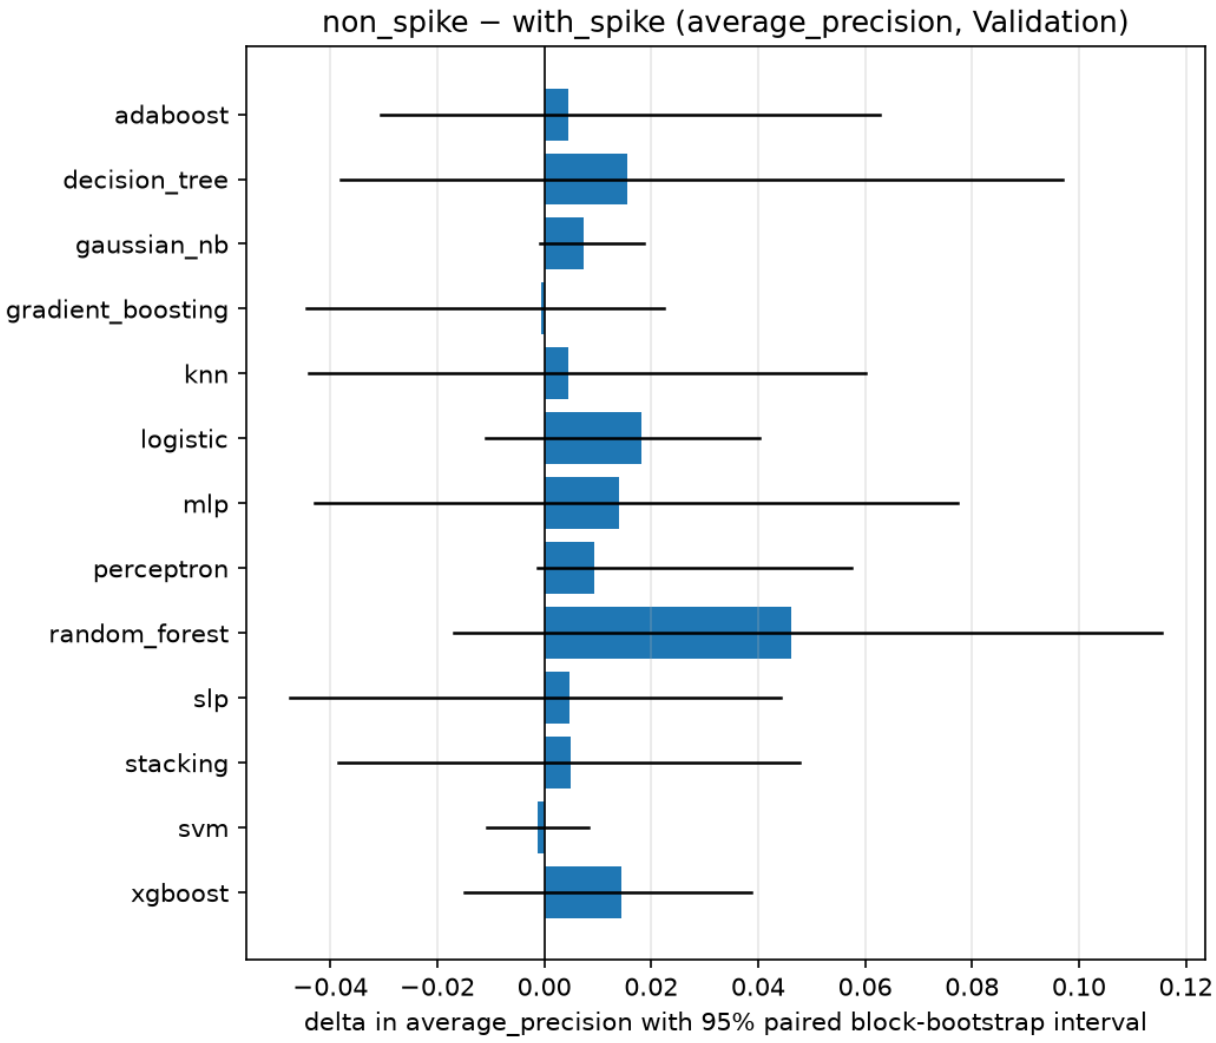
บน Validation `delta = non_spike − with_spike` สำหรับ AP ค่าบวกคือดีขึ้นเมื่อตัด spike สำหรับ RMSE
ค่าลบคือดีขึ้น

Paired comparison: non_spike − with_spike (Validation)

model	task	metric	with_spike	non_spike	delta	delta_95	verdict
elastic_net	regression	rmse	0.0668	0.0643	-0.0026	[-0.0053, +0.0019]	inconclusive
multiple_linear	regression	rmse	0.0689	0.0668	-0.0020	[-0.0036, -0.0000]	non_spike better
polynomial	regression	rmse	0.0691	0.0661	-0.0030	[-0.0073, +0.0016]	inconclusive
simple_linear	regression	rmse	0.0690	0.0665	-0.0026	[-0.0066, +0.0026]	inconclusive
adaboost	classification	average_precision	0.2363	0.2407	0.0044	[-0.0307, +0.0627]	inconclusive
decision_tree	classification	average_precision	0.1732	0.1887	0.0155	[-0.0380, +0.0970]	inconclusive
gaussian_nb	classification	average_precision	0.2218	0.2292	0.0074	[-0.0007, +0.0187]	inconclusive

model	task	metric	with_ spike	non_ spike	delta	delta_95	verdict
gradient_boosting	classification	average_precision	0.2531	0.2525	-0.0006	[-0.0445, +0.0223]	inconclusive
knn	classification	average_precision	0.2037	0.2082	0.0045	[-0.0441, +0.0601]	inconclusive
logistic	classification	average_precision	0.2330	0.2513	0.0183	[-0.0110, +0.0401]	inconclusive
mlp	classification	average_precision	0.2668	0.2808	0.0139	[-0.0429, +0.0772]	inconclusive
perceptron	classification	average_precision	0.0648	0.0742	0.0094	[-0.0012, +0.0575]	inconclusive
random_forest	classification	average_precision	0.2548	0.3010	0.0462	[-0.0168, +0.1155]	inconclusive
slp	classification	average_precision	0.2427	0.2474	0.0047	[-0.0477, +0.0441]	inconclusive
stacking	classification	average_precision	0.2262	0.2311	0.0049	[-0.0386, +0.0477]	inconclusive
svm	classification	average_precision	0.2514	0.2501	-0.0013	[-0.0108, +0.0082]	inconclusive
xgboost	classification	average_precision	0.2508	0.2652	0.0144	[-0.0148, +0.0386]	inconclusive
agglomerative	clustering	silhouette	0.3602	0.4642	0.1040	n/a	no interval
kmeans	clustering	silhouette	0.3666	0.3298	-0.0367	n/a	no interval

*ผลต่างในตารางนี้คือผลของ **นโยบายตัดแถวทั้งชุด** ไม่ใช่ผลของ spike เพียงอย่างเดียว: การตัด 213 แถวทำให้ class prior ของ Train เปลี่ยนจาก 25.0% เป็น 18.4%, จำนวนแถวลดจาก 1,733 เป็น 1,520 และ regime ที่ผันผวนสูงหายไปจาก Train พร้อมกัน ทั้งสาม confound นี้แยกจากกันไม่ได้ด้วยการทดลองนี้ delta = non_spike − with_spike บน Validation 371 แถวชุดเดียวกัน ช่วง 95% จาก paired moving-block bootstrap (block 20 วัน) และเมื่อเทียบ 17 โมเดลพร้อมกัน ควรคาดว่าจะมีราว 1 แถวที่ช่วงไม่คร่อมศูนย์โดยบังเอิญ*



รูปที่ 13 ผลต่างของ AP เมื่อตัด spike ออก พร้อมช่วงความเชื่อมั่น 95% (Validation)

โมเดลส่วนใหญ่ได้คะแนนดีขึ้นเล็กน้อยเมื่อตัด spike แต่ 16 จาก 17 โมเดลได้คำตัดสิน `inconclusive` มีเพียง `multiple_linear` ที่ช่วงไม่คร่อมศูนย์ ซึ่งเมื่อเทียบ 17 โมเดลพร้อมกัน การเจอราว 1 โมเดลโดยบังเอิญเป็นเรื่องที่คาดได้ นอกจากนี้ Validation ไม่มีวัน spike เลย จึงทดสอบไม่ได้ว่าโมเดลแต่ละแบบรับมือ spike ได้ดีแค่ไหน

บน Test ใช้คำทำนายที่บันทึกไว้ตอน finalize และวิธี paired block bootstrap เดียวกัน

Same model with and without spike rows, on Test (paired block bootstrap)

task	model	metric	with_spike	non_spike	delta	delta_low	delta_high	direction	interval_excludes_zero
classification	adaboost	average_precision	0.4858	0.5443	0.0585	-0.0324	0.1168	non_spike better	no
classification	decision_tree	average_precision	0.3792	0.3844	0.0052	-0.1502	0.1190	non_spike better	no
classification	gaussian_nb	average_precision	0.5538	0.5884	0.0346	-0.0064	0.0632	non_spike better	no
classification	gradient_boosting	average_precision	0.5332	0.5653	0.0322	-0.0254	0.0891	non_spike better	no
classification	knn	average_precision	0.5472	0.5389	-0.0083	-0.1005	0.0946	with_spike better	no
classification	logistic	average_precision	0.5518	0.5510	-0.0008	-0.0184	0.0156	with_spike better	no
classification	mlp	average_precision	0.5991	0.5639	-0.0352	-0.0792	0.0276	with_spike better	no
classification	perceptron	average_precision	0.1374	0.1328	-0.0046	-0.0313	-0.0001	with_spike better	yes
classification	random_forest	average_precision	0.5775	0.5240	-0.0534	-0.1284	0.0106	with_spike better	no
classification	slp	average_precision	0.5536	0.4963	-0.0573	-0.1184	-0.0038	with_spike better	yes
classification	stacking	average_precision	0.5131	0.5499	0.0368	-0.0721	0.1233	non_spike better	no
classification	svm	average_precision	0.5716	0.5805	0.0088	-0.0015	0.0184	non_spike better	no
classification	xgboost	average_precision	0.5305	0.5823	0.0518	0.0163	0.0931	non_spike better	yes
regression	elastic_net	rmse	0.1174	0.1230	0.0055	-0.0045	0.0122	with_spike better	no
regression	multiple_linear	rmse	0.1158	0.1180	0.0022	-0.0017	0.0051	with_spike better	no
regression	polynomial	rmse	0.1401	0.1142	-0.0260	-0.0575	0.0041	non_spike better	no
regression	simple_linear	rmse	0.1356	0.1372	0.0016	-0.0288	0.0198	with_spike better	no

- ทิศทางบน Test **ไม่ตรงกับ Validation**: classifier 7 ตัวดีขึ้นและ 6 ตัวแย่ลงเมื่อตัด spike ส่วน regression 3 จาก 4 ตัวแย่ลงเล็กน้อย
- ช่วงความเชื่อมั่นคร่อมศูนย์ใน 14 จาก 17 โมเดล อีก 3 โมเดลชี้ไปคนละทาง: `slp` และ `perceptron` ดีกว่าเมื่อเก็บ spike ไว้ ส่วน `xgboost` ดีกว่าเมื่อตัดออก
- ข้อสังเกตจากตารางแยกช่วงในหัวข้อ 7.6 (ไม่มีช่วงความเชื่อมั่น): โมเดลเชิงเส้นที่เทรนแบบไม่มี spike ทำได้ดีกว่าเล็กน้อยในช่วงปกติ แต่แย่กว่าในช่วงรอบวัน spike ซึ่งสมเหตุสมผล เพราะไม่เคยเห็นตัวอย่างแบบนั้นตอนเทรน

สมมติฐานเรื่อง AdaBoost บน Validation `adaboost` แทบไม่เปลี่ยน (+0.004) บน Test
เป็นโมเดลที่ดีขึ้นมากที่สุดเมื่อตัด spike (AP 0.486 เป็น 0.544) ซึ่งสอดคล้องกับสมมติฐานในหัวข้อ 6.2
แต่ช่วงความเชื่อมั่นยังคร่อมศูนย์ จึงเป็นเพียงข้อสังเกตที่ไปในทิศทางเดียวกับสมมติฐาน ยังไม่ใช่ข้อพิสูจน์

คำตอบของคำถามวิจัย ข้อมูลชุดนี้ **ไม่สนับสนุน** ว่านโยบายตัดแถวรอบวัน spike
ออกจากข้อมูลเทรนทำให้โมเดลทำนายดีขึ้น และไม่สนับสนุนว่าทำให้แย่ลงเช่นกัน
ผลต่างที่วัดได้เล็กกว่าความไม่แน่นอนของการวัด ทั้งบน Validation และ Test และทิศทางของสองชุดไม่ตรงกัน

8.3 ดีกว่าโมเดลที่สอนในห้องเท่าไร

เราเทียบโมเดลตัวแทนกับโมเดลพื้นฐานที่สอนในห้อง คือ `logistic` สำหรับ classification และ `multiple_linear` สำหรับ regression แบบจับคู่ คอลัมน์ `improvement_percent` เป็นบวกเมื่อโมเดลตัวแทนดีกว่า

Headline vs classroom model on Validation (paired block bootstrap)

task	variant	metric	classroom_model	classroom_score	headline	headline_score	delta	delta_low	delta_high	improvement_percent	interval_excludes_zero
classification	with_spike	average_precision	logistic	0.2330	mlp	0.2668	0.0338	-0.0038	0.0699	14.5214	no
classification	non_spike	average_precision	logistic	0.2513	random_forest	0.3010	0.0497	-0.0174	0.1004	19.7965	no
regression	with_spike	rmse	multiple_linear	0.0689	elastic_net	0.0668	-0.0021	-0.0059	0.0014	2.9883	no
regression	non_spike	rmse	multiple_linear	0.0668	elastic_net	0.0643	-0.0026	-0.0068	0.0020	3.8380	no

Headline vs classroom model on Test (paired block bootstrap)

task	variant	metric	classroom_model	classroom_score	headline	headline_score	delta	delta_low	delta_high	improvement_percent	interval_excludes_zero
classification	with_spike	average_precision	logistic	0.5518	mlp	0.5991	0.0473	-0.0137	0.0766	8.5643	no
classification	non_spike	average_precision	logistic	0.5510	random_forest	0.5240	-0.0270	-0.1678	0.0793	-4.8974	no
regression	with_spike	rmse	multiple_linear	0.1158	elastic_net	0.1174	0.0016	-0.0092	0.0089	-1.4215	no
regression	non_spike	rmse	multiple_linear	0.1180	elastic_net	0.1230	0.0049	-0.0119	0.0158	-4.1832	no

บน Validation โมเดลตัวแทนดีกว่าโมเดลพื้นฐาน 3% ถึง 20% แต่ช่วงความเชื่อมั่นคร่อมศูนย์ทุกแถว บน Test มีเพียง `mlp` ที่ยังดีกว่า `logistic` (ราว 8.6% และช่วงยังคร่อมศูนย์) ส่วน `random_forest` และ `elastic_net` ทำได้แย่กว่าโมเดลพื้นฐานเล็กน้อย

เราจึง **ไม่อ้าง** ว่าโมเดลที่ซับซ้อนกว่าดีกว่าโมเดลที่สอนในห้องอย่างมีนัยสำคัญ ข้อค้นพบที่มีหลักฐานรองรับมากกว่าคือ บนโจทย์นี้ โมเดลเรียบง่ายอย่าง `logistic` และ `multiple_linear` ทำได้ดีพอ ๆ กับโมเดลที่ซับซ้อนที่สุดที่เราเขียน

8.4 โมเดลพลาดตรงไหน

จากคำทำนายของโมเดลตัวแทนบน Validation (notebook 05 หัวข้อ 7) วันผันผวนสูง 20 จาก 34 วันอยู่ในไตรมาส 3 ปี 2024 ซึ่งตลาดปรับฐานแรงต้นเดือนสิงหาคม โมเดลจับได้ 7 ถึง 8 วัน ทั้งหมดอยู่ในไตรมาสนั้น ส่วนอีก 14 วันที่กระจายอยู่ในไตรมาสอื่นพลาดทั้งหมด

คะแนนของโมเดลขึ้นตาม **หลัง** ความผันผวนเริ่มแล้ว เพราะฟีเจอร์ทั้งหมดมองย้อนหลัง โมเดลจึงจับช่วงกลางและท้ายของเหตุการณ์ใหญ่ได้ แต่พลาดวันแรก ๆ และพลาดเหตุการณ์สั้น ๆ ผลบน Test (หัวข้อ 7.6) ยืนยันภาพเดียวกัน

8.5 ความเสถียรของอันดับข้ามช่วงเวลา

เพื่อดูว่าอันดับของโมเดลขึ้นกับช่วงเวลาที่วัดมากแค่ไหน เราทำ **walk-forward** ภายในข้อมูลเทรน: เทรนด้วยข้อมูลช่วงต้น ทดสอบกับช่วงถัดไป แล้วขยายหน้าต่างไปเรื่อย ๆ 4 รอบ ครอบคลุมปี 2019 ถึง 2023 และมีวันผันผวนสูงรวม 353 วัน ใช้การตั้งค่าเดิมของแต่ละโมเดล **ไม่มีการเลือกโมเดลใหม่** จากผลนี้

Walk-forward average precision inside Train — with_spike

model	fold_0_ap	fold_1_ap	fold_2_ap	fold_3_ap	folds_used	positives	pooled_ap	pooled_low	pooled_high
gaussian_nb	0.8282	0.6361	0.7775	0.4436	4	353	0.7124	0.5717	0.8151
gradient_boosting	0.8117	0.5722	0.8168	0.5522	4	353	0.7120	0.5857	0.8059
logistic	0.8173	0.6103	0.7847	0.4511	4	353	0.7030	0.5548	0.8083
random_forest	0.8079	0.6003	0.8018	0.5108	4	353	0.6833	0.5582	0.7797
svm	0.7946	0.6118	0.7839	0.4556	4	353	0.6718	0.5280	0.7842
slp	0.7946	0.5278	0.7658	0.4313	4	353	0.6717	0.5205	0.7813
adaboost	0.7998	0.5650	0.8330	0.4458	4	353	0.6708	0.5383	0.7772
xgboost	0.7604	0.5602	0.8042	0.5628	4	353	0.6690	0.5514	0.7645
mlp	0.7662	0.5310	0.8070	0.4385	4	353	0.6663	0.5203	0.7738
stacking	n/a	0.5861	0.8200	0.4417	3	273	0.6473	0.5119	0.7693
knn	0.7504	0.6400	0.7724	0.4553	4	353	0.6406	0.5153	0.7510
decision_tree	0.5803	0.4013	0.7242	0.3880	4	353	0.5750	0.4401	0.6958
perceptron	0.1852	0.5271	0.6226	0.2144	4	353	0.3337	0.2478	0.4690

คะแนนของโมเดลเดียวกันต่างกันระหว่างรอบมากกว่าที่ต่างกันระหว่างโมเดลในรอบเดียวกัน (เช่น รอบที่ 0 ได้ AP ราว 0.8 ส่วนรอบที่ 3 ได้ราว 0.45) สภาพตลาดจึงมีผลต่อคะแนนมากกว่าชนิดของโมเดล อันดับจาก walk-forward สัมพันธ์กับอันดับบน Validation เพียงบางส่วน (Spearman 0.49 สำหรับ `with_spike` และ 0.17 สำหรับ `non_spike` คำนวณใน notebook 05 หัวข้อ 5)

หมายเหตุ: `stacking` ไม่มีผลในรอบที่ 0 เพราะ 275 วันแรกของข้อมูลเทรนไม่มีวันผันผวนสูงเลย
โมเดลซึ่งต้องแบ่งข้อมูลภายในอีกชั้นจึงเทรนบนประวัติที่สั้นที่สุดไม่ได้

9. ข้อจำกัดและงานต่อ

1. **ตัวอย่างไม่อิสระต่อกัน** ข้อมูลจริงมีน้อยกว่าจำนวนแถวมาก ช่วงความเชื่อมั่นจึงกว้าง
   และข้อสรุปส่วนใหญ่ของรายงานนี้คือ "ยังสรุปไม่ได้"
2. **Validation เป็นสภาพตลาดแบบเดียว** สงบ ไม่มี spike และมีวันผันผวนสูง 34 วัน จึงเลือกโมเดลได้ไม่แม่น
3. **การเทียบสองแบบข้อมูลถูก confound** จำนวนแถว สัดส่วนคลาส และสภาพตลาดเปลี่ยนพร้อมกัน การแยกผลของ spike ต้องใช้การทดลองเพิ่ม เช่น ตัดแถวปกติจำนวนเท่ากันออกเป็นกลุ่มควบคุม
4. **ช่วงรอบวัน spike ใน Test มีเพียง 54 แถวจากสองเหตุการณ์** ผลแยกช่วงจึงเป็นข้อสังเกต
5. **threshold คงที่ 0.5** ทำให้ recall ต่ำเมื่อสภาพตลาดเปลี่ยน การปรับ threshold หรือปรับเทียบความน่าจะเป็น (calibration) อาจช่วยได้ แต่ต้องมีข้อมูลแยกสำหรับเลือก
6. **ไม่มีฟีเจอร์ที่มองไปข้างหน้า** เช่น implied volatility (VIX) หรือปฏิทินประกาศตัวเลขเศรษฐกิจ
   ซึ่งน่าจะเป็นสิ่งที่ช่วยทำนายจุดเริ่มของความผันผวนได้
7. **สินทรัพย์เดียว ช่วงเวลาเดียว** ผลอาจไม่ใช้กับสินทรัพย์อื่น
8. **ค่า SHA-256 ของไฟล์ข้อมูลที่สร้างขึ้นผูกกับ Windows**
   เพราะรูปแบบการขึ้นบรรทัดใหม่ของไฟล์ต่างกันตามระบบปฏิบัติการ (`docs/audit/PATH_AUDIT.md`)

งานต่อที่น่าทำ เพิ่มฟีเจอร์ที่มองไปข้างหน้า, ทำกลุ่มควบคุมสำหรับการทดลอง spike, ใช้ walk-forward
ในการเลือกโมเดลแทน Validation ช่วงเดียว และทดสอบกับสินทรัพย์อื่น

10. สรุป

ตอบคำถามวิจัย การตัดช่วงราคากระชากแรงออกจากข้อมูลเทรนไม่ได้ทำให้โมเดลดีขึ้นหรือแย่ลงอย่างที่วัดได้
ผลต่างเล็กกว่าความไม่แน่นอนของการวัด และทิศทางบน Validation กับ Test ไม่ตรงกัน

ข้อค้นพบหลัก

1. จากข้อมูลราคาย้อนหลังเพียงอย่างเดียว โมเดลทำนายความผันผวน 5 วันข้างหน้าได้ดีกว่าการเดาสุ่มชัดเจน
   แต่เหนือกว่ากฎ "เท่ากับ 5 วันที่ผ่านมา" เพียงเล็กน้อย
2. โมเดลทำงานได้ในช่วงตลาดปกติ แต่ภายในช่วงปั่นป่วนแยกวันผันผวนสูงไม่ได้
   ซึ่งเป็นช่วงที่การเตือนล่วงหน้ามีค่ามากที่สุด
3. โมเดลเรียบง่ายทำได้ดีพอ ๆ กับโมเดลซับซ้อน และผู้นำบน Validation ไม่ได้เป็นผู้นำบน Test เสมอไป

สิ่งที่ได้เรียนรู้จากการเขียนโมเดลเองทั้งหมด

- การทำให้ผลตรงกับ library ถึงทศนิยมสุดท้าย บังคับให้เข้าใจรายละเอียดที่ตำราข้ามไป เช่น ลำดับการสุ่ม กฎการหยุดวนรอบ และการตัดสินเมื่อคะแนนเท่ากัน
- กับข้อมูลอนุกรมเวลา ความถูกต้องของขั้นตอน (แบ่งตามเวลา เว้นช่องว่าง คำนวณทุกอย่างจาก Train ล็อกก่อนเปิด Test) สำคัญกว่าการเลือกโมเดล

- ช่วงความเชื่อมั่นเปลี่ยนข้อสรุปได้มาก ถ้าดูเฉพาะค่าที่วัดได้ เราคงสรุปว่า "ตัด spike แล้วดีขึ้น" และ "MLP ดีกว่า logistic 14%" ซึ่งทั้งสองข้อไม่มีหลักฐานรองรับเพียงพอ

ภาคผนวก ก การตั้งค่าที่ถูกเลือกของทุกโมเดล

`candidates` คือจำนวนการตั้งค่าที่ลอง · `reference` คือ class ของ library ที่ใช้ยืนยันผล · `params_*` คือการตั้งค่าที่ชนะบน Validation ของแต่ละแบบข้อมูล · `pca_*` คือจำนวน component ของ PCA (ว่างคือไม่ใช้)

Model inventory and selected settings

model	task	candidates	reference	preprocess	params_with_spike	params_non_spike	pca_with_spike	pca_non_spike
adaboost	classification	6	AdaBoostClassifier	none	{"learning_rate": 0.5, "n_estimators": 100, "random_state": 42}	{"learning_rate": 0.5, "n_estimators": 100, "random_state": 42}	n/a	n/a
agglomerative	clustering	10	AgglomerativeClustering	standardize	{"k": 2, "linkage": "ward"}	{"k": 2, "linkage": "average"}	n/a	n/a
decision_tree	classification	6	DecisionTreeClassifier	none	{"max_depth": 2, "max_features": null, "min_samples_leaf": 5, "random_state": 42}	{"max_depth": 5, "max_features": null, "min_samples_leaf": 5, "random_state": 42}	n/a	n/a
elastic_net	regression	12	ElasticNet	standardize	{"alpha": 0.1, "l1_ratio": 0.25, "max_iter": 5000, "tol": 1e-06}	{"alpha": 0.1, "l1_ratio": 0.25, "max_iter": 5000, "tol": 1e-06}	n/a	n/a
gaussian_nb	classification	3	GaussianNB	none	{"var_smoothing": 1e-07}	{"var_smoothing": 1e-08}	n/a	n/a
gradient_boosting	classification	8	GradientBoostingClassifier	none	{"learning_rate": 0.1, "max_depth": 1, "min_samples_leaf": 5, "n_estimators": 50, "random_state": 42}	{"learning_rate": 0.03, "max_depth": 2, "min_samples_leaf": 5, "n_estimators": 50, "random_state": 42}	n/a	n/a
kmeans	clustering	5	KMeans	standardize	{"k": 2, "max_iter": 300, "n_init": 10, "random_state": 42, "tol": 1e-06}	{"k": 2, "max_iter": 300, "n_init": 10, "random_state": 42, "tol": 1e-06}	n/a	n/a
knn	classification	8	KNeighborsClassifier	standardize	{"k": 15, "weights": "distance"}	{"k": 9, "weights": "distance"}	n/a	n/a
logistic	classification	6	LogisticRegression	standardize	{"class_weight": null, "l2": 0.01, "learning_rate": 0.05, "max_iter": 5000, "tol": 1e-06}	{"class_weight": null, "l2": 0, "learning_rate": 0.05, "max_iter": 5000, "tol": 1e-06}	n/a	n/a
mlp	classification	12	MLPClassifier	standardize	{"activation": "relu", "batch": 32, "hidden_layers": [16], "l2": 0, "learning_rate": 0.001, "max_epochs": 1000, "min_delta": 1e-06, "momentum": 0.9, "patience": 50, "random_state": 42}	{"activation": "relu", "batch": 32, "hidden_layers": [16, 8], "l2": 0, "learning_rate": 0.01, "max_epochs": 1000, "min_delta": 1e-06, "momentum": 0.9, "patience": 50, "random_state": 42}	n/a	n/a
multiple_linear	regression	1	LinearRegression	standardize	{"fit_intercept": true}	{"fit_intercept": true}	n/a	n/a
perceptron	classification	3	Perceptron	standardize	{"learning_rate": 0.001, "max_epochs": 1000}	{"learning_rate": 0.001, "max_epochs": 1000}	n/a	n/a
polynomial	regression	16	Pipeline	standardize	{"degree": 3, "feature": "historical_volatility_20d", "standardize_before_powers": true}	{"degree": 2, "feature": "return_5d", "standardize_before_powers": true}	n/a	n/a
random_forest	classification	7	RandomForestClassifier	none	{"bootstrap": true, "max_depth": 3, "max_features": "sqrt", "min_samples_leaf": 5, "n_estimators": 100, "random_state": 42}	{"bootstrap": true, "max_depth": 5, "max_features": "sqrt", "min_samples_leaf": 5, "n_estimators": 50, "random_state": 42}	n/a	n/a
simple_linear	regression	8	LinearRegression	none	{"feature": "historical_volatility_20d"}	{"feature": "return_1d"}	n/a	n/a
slp	classification	8	LogisticRegression	standardize	{"batch": 32, "l2": 0, "learning_rate": 0.001, "max_epochs": 1000, "min_delta": 1e-06, "patience": 50, "random_state": 42}	{"batch": "full", "l2": 0, "learning_rate": 0.01, "max_epochs": 1000, "min_delta": 1e-06, "patience": 50, "random_state": 42}	n/a	n/a
stacking	classification	1	StackingClassifier	base_specific	{"folds": 4, "initial_fraction": 0.4, "purge": 5, "random_state": 42}	{"folds": 4, "initial_fraction": 0.4, "purge": 5, "random_state": 42}	n/a	n/a

model	task	candidates	reference	preprocess	params_with_spike	params_non_spike	pca_with_spike	pca_non_spike
svm	classification	12	SVC	standardize	{"C": 0.1, "fit_intercept": true, "max_iter": 20000, "random_state": 42}	{"C": 10, "fit_intercept": true, "max_iter": 20000, "random_state": 42}	4	4
xgboost	classification	8	XGBClassifier	none	{"gamma": 0, "learning_rate": 0.03, "max_depth": 1, "n_estimators": 100, "random_state": 42, "reg_lambda": 1}	{"gamma": 0.1, "learning_rate": 0.03, "max_depth": 2, "n_estimators": 100, "random_state": 42, "reg_lambda": 10}	n/a	n/a

ภาคผนวก ข ตารางเพิ่มเติม

ข.1 Validation ของแบบ non_spike

Validation leaderboard — classification — non_spike

model	kind	average_ precision_ci	roc_auc_ci	f1_ci	recall_ci	precision	specificity	accuracy	loss_name	loss	tied_ with_ leader	beats_best_ baseline
random_forest	model	0.3010 [0.0548, 0.5328]	0.6766 [0.4439, 0.8313]	0.2917 [0.0000, 0.5064]	0.2059 [0.0000, 0.4287]	0.5000	0.9792	0.9084	log_loss	0.3059	yes	yes
mlp	model	0.2808 [0.0534, 0.5184]	0.6992 [0.4716, 0.8426]	0.3077 [0.0000, 0.5435]	0.2353 [0.0000, 0.4545]	0.4444	0.9703	0.9030	binary_cross_ entropy	0.3166	yes	yes
xgboost	model	0.2652 [0.0600, 0.4730]	0.6853 [0.4608, 0.8256]	0.2800 [0.0000, 0.5000]	0.2059 [0.0000, 0.4255]	0.4375	0.9733	0.9030	binary_logistic_loss	0.3088	yes	yes
gradient_boosting	model	0.2525 [0.0625, 0.4477]	0.6732 [0.4577, 0.8152]	0.2667 [0.0000, 0.4533]	0.1765 [0.0000, 0.3674]	0.5455	0.9852	0.9111	binary_logistic_loss	0.2966	yes	yes
logistic	model	0.2513 [0.0538, 0.4557]	0.6824 [0.4529, 0.8310]	0.2553 [0.0000, 0.4445]	0.1765 [0.0000, 0.3674]	0.4615	0.9792	0.9057	binary_cross_ entropy	0.3014	yes	yes
svm	model	0.2501 [0.0520, 0.4672]	0.6804 [0.4367, 0.8413]	0.2727 [0.0000, 0.4667]	0.1765 [0.0000, 0.3674]	0.6000	0.9881	0.9137	hinge_loss	0.2539	yes	yes
baseline_ persistence	baseline	0.2474 [0.0545, 0.5002]	0.7214 [0.5384, 0.8407]	0.2899 [0.0000, 0.5589]	0.2941 [0.0000, 0.5601]	0.2857	0.9258	0.8679	n/a	n/a	yes	n/a
slp	model	0.2474 [0.0489, 0.4531]	0.6778 [0.4892, 0.8122]	0.2258 [0.0000, 0.4156]	0.2059 [0.0000, 0.4255]	0.2500	0.9377	0.8706	binary_cross_ entropy	0.3607	yes	no
adaboost	model	0.2407 [0.0556, 0.4722]	0.6409 [0.3618, 0.8209]	0.2353 [0.0000, 0.4444]	0.1765 [0.0000, 0.3674]	0.3529	0.9674	0.8949	exponential_loss	0.5875	yes	no
stacking	model	0.2311 [0.0582, 0.4204]	0.6650 [0.4550, 0.8061]	0.1961 [0.0000, 0.3509]	0.1471 [0.0000, 0.3077]	0.2941	0.9644	0.8895	log_loss	0.3304	yes	no
gaussian_nb	model	0.2292 [0.0485, 0.4434]	0.6789 [0.4426, 0.8273]	0.2381 [0.0000, 0.4355]	0.2941 [0.0000, 0.5371]	0.2000	0.8813	0.8275	log_loss	0.7534	yes	no
knn	model	0.2082 [0.0584, 0.3932]	0.6455 [0.4610, 0.7802]	0.2222 [0.0000, 0.3846]	0.1765 [0.0000, 0.3514]	0.3000	0.9585	0.8868	log_loss	1.2326	yes	no
decision_tree	model	0.1887 [0.0505, 0.4105]	0.6924 [0.4917, 0.8233]	0.1887 [0.0000, 0.3556]	0.1471 [0.0000, 0.2963]	0.2632	0.9585	0.8841	log_loss	0.5063	yes	no
baseline_majority	baseline	0.0916 [0.0350, 0.1779]	0.5000 [0.5000, 0.5000]	0.0000 [0.0000, 0.0000]	0.0000 [0.0000, 0.0000]	n/a	1.0000	0.9084	n/a	n/a	yes	n/a
perceptron	model	0.0742 [0.0343, 0.1688]	0.3383 [0.1803, 0.5693]	0.1159 [0.0000, 0.2571]	0.1176 [0.0000, 0.3125]	0.1143	0.9080	0.8356	perceptron_ criterion	0.0010	yes	no

ตัวเลขบน Validation เป็น selection score: hyperparameter ของทุกโมเดลถูกเลือกบนแถวชุดนี้ จึงมองโลกในแง่ดีเกินจริง และโมเดลที่ `tied_with_leader = yes` แยกจากอันดับ 1 ไม่ได้ที่ระดับ 95% (moving-block bootstrap, block 20 วัน) ห้ามอ้างอันดับภายในกลุ่มนั้น

13 จาก 13 โมเดลอยู่ในกลุ่มที่แยกจากอันดับ 1 ไม่ได้

Every metric the assignment lists — Validation — non_spike

model	loss_name	loss	tn	fp	fn	tp	accuracy	precision	sensitivity	specificity	tnr	f1	roc_auc	average_ precision
random_forest	log_loss	0.3059	330	7	27	7	0.9084	0.5000	0.2059	0.9792	0.9792	0.2917	0.6766	0.3010
mlp	binary_cross_entropy	0.3166	327	10	26	8	0.9030	0.4444	0.2353	0.9703	0.9703	0.3077	0.6992	0.2808
xgboost	binary_logistic_loss	0.3088	328	9	27	7	0.9030	0.4375	0.2059	0.9733	0.9733	0.2800	0.6853	0.2652
gradient_boosting	binary_logistic_loss	0.2966	332	5	28	6	0.9111	0.5455	0.1765	0.9852	0.9852	0.2667	0.6732	0.2525
logistic	binary_cross_entropy	0.3014	330	7	28	6	0.9057	0.4615	0.1765	0.9792	0.9792	0.2553	0.6824	0.2513
svm	hinge_loss	0.2539	333	4	28	6	0.9137	0.6000	0.1765	0.9881	0.9881	0.2727	0.6804	0.2501
baseline_persistence	n/a	n/a	312	25	24	10	0.8679	0.2857	0.2941	0.9258	0.9258	0.2899	0.7214	0.2474
slp	binary_cross_entropy	0.3607	316	21	27	7	0.8706	0.2500	0.2059	0.9377	0.9377	0.2258	0.6778	0.2474
adaboost	exponential_loss	0.5875	326	11	28	6	0.8949	0.3529	0.1765	0.9674	0.9674	0.2353	0.6409	0.2407
stacking	log_loss	0.3304	325	12	29	5	0.8895	0.2941	0.1471	0.9644	0.9644	0.1961	0.6650	0.2311
gaussian_nb	log_loss	0.7534	297	40	24	10	0.8275	0.2000	0.2941	0.8813	0.8813	0.2381	0.6789	0.2292
knn	log_loss	1.2326	323	14	28	6	0.8868	0.3000	0.1765	0.9585	0.9585	0.2222	0.6455	0.2082
decision_tree	log_loss	0.5063	323	14	29	5	0.8841	0.2632	0.1471	0.9585	0.9585	0.1887	0.6924	0.1887
baseline_majority	n/a	n/a	337	0	34	0	0.9084	n/a	0.0000	1.0000	1.0000	0.0000	0.5000	0.0916
perceptron	perceptron_criterion	0.0010	306	31	30	4	0.8356	0.1143	0.1176	0.9080	0.9080	0.1159	0.3383	0.0742

Validation clustering metrics — non_spike

model	variant	k	silhouette	inertia	cluster_sizes
agglomerative	non_spike	2	0.4642	1844.8884	{"0": 359, "1": 12}
kmeans	non_spike	2	0.3298	1448.9259	{"0": 267, "1": 104}

silhouette/inertia คำนวณบน Validation ไม่มีช่วงความเชื่อมั่น

ข.2 Metric ครบทุกตัวบน Test

Every metric the assignment lists — Test — with_spike

model	tn	fp	fn	tp	accuracy	precision	sensitivity	specificity	tnr	f1	roc_auc	average_precision
mlp	283	17	37	36	0.8552	0.6792	0.4932	0.9433	0.9433	0.5714	0.7930	0.5991
random_forest	280	20	42	31	0.8338	0.6078	0.4247	0.9333	0.9333	0.5000	0.7866	0.5775
svm	283	17	44	29	0.8365	0.6304	0.3973	0.9433	0.9433	0.4874	0.7835	0.5716
gaussian_nb	263	37	28	45	0.8257	0.5488	0.6164	0.8767	0.8767	0.5806	0.7703	0.5538
slp	281	19	42	31	0.8365	0.6200	0.4247	0.9367	0.9367	0.5041	0.7798	0.5536
logistic	282	18	41	32	0.8418	0.6400	0.4384	0.9400	0.9400	0.5203	0.7822	0.5518
knn	281	19	38	35	0.8472	0.6481	0.4795	0.9367	0.9367	0.5512	0.7847	0.5472
gradient_boosting	277	23	46	27	0.8150	0.5400	0.3699	0.9233	0.9233	0.4390	0.7665	0.5332
xgboost	278	22	45	28	0.8204	0.5600	0.3836	0.9267	0.9267	0.4553	0.7716	0.5305
stacking	268	32	31	42	0.8311	0.5676	0.5753	0.8933	0.8933	0.5714	0.7902	0.5131
adaboost	270	30	40	33	0.8123	0.5238	0.4521	0.9000	0.9000	0.4853	0.7614	0.4858
decision_tree	259	41	37	36	0.7909	0.4675	0.4932	0.8633	0.8633	0.4800	0.7450	0.3792
perceptron	272	28	70	3	0.7373	0.0968	0.0411	0.9067	0.9067	0.0577	0.2749	0.1374

Every metric the assignment lists — Test — non_spike

model	tn	fp	fn	tp	accuracy	precision	sensitivity	specificity	tnr	f1	roc_auc	average_precision
gaussian_nb	244	56	20	53	0.7962	0.4862	0.7260	0.8133	0.8133	0.5824	0.7779	0.5884
xgboost	280	20	38	35	0.8445	0.6364	0.4795	0.9333	0.9333	0.5469	0.7887	0.5823
svm	289	11	48	25	0.8418	0.6944	0.3425	0.9633	0.9633	0.4587	0.7853	0.5805
gradient_boosting	291	9	54	19	0.8311	0.6786	0.2603	0.9700	0.9700	0.3762	0.7861	0.5653
mlp	278	22	41	32	0.8311	0.5926	0.4384	0.9267	0.9267	0.5039	0.7894	0.5639
logistic	281	19	42	31	0.8365	0.6200	0.4247	0.9367	0.9367	0.5041	0.7782	0.5510
stacking	270	30	40	33	0.8123	0.5238	0.4521	0.9000	0.9000	0.4853	0.7890	0.5499
adaboost	283	17	43	30	0.8391	0.6383	0.4110	0.9433	0.9433	0.5000	0.7735	0.5443
knn	280	20	48	25	0.8177	0.5556	0.3425	0.9333	0.9333	0.4237	0.8008	0.5389
random_forest	279	21	44	29	0.8257	0.5800	0.3973	0.9300	0.9300	0.4715	0.7814	0.5240
slp	268	32	38	35	0.8123	0.5224	0.4795	0.8933	0.8933	0.5000	0.7420	0.4963
decision_tree	282	18	48	25	0.8231	0.5814	0.3425	0.9400	0.9400	0.4310	0.6916	0.3844
perceptron	255	45	68	5	0.6971	0.1000	0.0685	0.8500	0.8500	0.0813	0.2626	0.1328

ข.3 Walk-forward และ feature importance ของแบบ non_spike

Walk-forward average precision inside Train — non_spike

model	fold_0_ap	fold_1_ap	fold_2_ap	fold_3_ap	folds_used	positives	pooled_ap	pooled_low	pooled_high
stacking	n/a	0.5782	0.6482	0.4522	3	191	0.5666	0.4375	0.6853
gaussian_nb	0.3405	0.5518	0.6727	0.4235	4	211	0.5578	0.4271	0.6590
random_forest	0.3386	0.5408	0.6765	0.4222	4	211	0.5425	0.4098	0.6590
knn	0.3376	0.5442	0.7030	0.4203	4	211	0.5417	0.3957	0.6603
logistic	0.2622	0.4996	0.6770	0.4000	4	211	0.5399	0.4019	0.6477
xgboost	0.3175	0.5037	0.7020	0.3927	4	211	0.5238	0.3871	0.6469
gradient_boosting	0.3800	0.4836	0.6528	0.4287	4	211	0.5234	0.3883	0.6430
slp	0.3711	0.4578	0.6540	0.3513	4	211	0.5028	0.3635	0.6237
adaboost	0.2976	0.4025	0.6531	0.4130	4	211	0.5020	0.3604	0.6220
mlp	0.2944	0.4208	0.6439	0.3746	4	211	0.4761	0.3448	0.6136
decision_tree	0.1866	0.4120	0.5306	0.4232	4	211	0.4221	0.2996	0.5383
svm	0.1093	0.2361	0.3805	0.4177	4	211	0.2767	0.1913	0.3759
perceptron	0.0740	0.1586	0.4461	0.1975	4	211	0.2347	0.1619	0.3627

Block-permutation importance averaged over models — non_spike

feature	drop_in_ap_mean	drop_in_ap_std_across_models	rise_in_rmse_mean	rise_in_rmse_std_across_models
return_1d	-0.0005	0.0119	0.0006	0.0011
return_5d	0.0020	0.0086	0.0021	0.0045
historical_volatility_5d	0.0193	0.0174	-0.0001	0.0005
historical_volatility_20d	0.0329	0.0238	0.0007	0.0008
intraday_range	0.0044	0.0165	-0.0002	0.0010
sma_ratio_5_20	0.0125	0.0133	-0.0000	0.0000
rsi_14	0.0261	0.0250	0.0001	0.0005
volume_zscore_20	0.0062	0.0113	-0.0002	0.0004

ภาคผนวก ค หลักฐานการเปิด Test และวิธีทำซ้ำ

ใบรับรองการเปิด Test (`outputs/modeling/finalize_receipt.json`)

รายการ	ค่า
เวลาที่รัน (UTC)	2026-10-11 14:02:01
git revision ขณะรัน	`cb12d22` (working tree สะอาด)
จำนวนแถวของ Test	373 (ช่วงปกติ 319, ช่วงรอบวัน spike 54)
จำนวนโมเดลที่ประเมิน	38

รายการ	ค่า
จำนวนรอบ bootstrap	2,000
รันซ้ำ	ไม่มี

วิธีทำซ้ำ ขั้นตอนเต็มอยู่ใน `docs/guides/RUNBOOK.md`

1. ติดตั้งตาม RUNBOOK ข้อ 2 ถึง 5
2. `python -m src.ml.run report --variant with_spike` และ `--variant non_spike`
3. `python -m src.ml.run compare`
4. `python -m src.ml.run analyze --variant with_spike` และ `--variant non_spike`
5. `python -m src.ml.docs_sync`
6. เปิด notebook 03, 04 และ 05

ช่วงความเชื่อมั่นใช้ seed คงที่ จึงได้ค่าเดิมทุกครั้ง คำสั่ง `finalize --allow-test` จะปฏิเสธการรันซ้ำ เพราะ Test ถูกเปิดไปแล้ว